PONTIFICIA UNIVERSIDAD CATÓLICA DEL PERÚ

1INF03 - Análisis de datos
2026-2

SEMANA 1:

STEP 2
"SELECCIÓN Y ENTENDIMIENTO DEL LOS DATOS"

Profesora: Stéfany Neciosup Vera
stefany.neciosup@pucp.edu.pe

9 STEPS

Fuente: Fayyad, Piatetsky-Shapiro, & Smyth (1996)

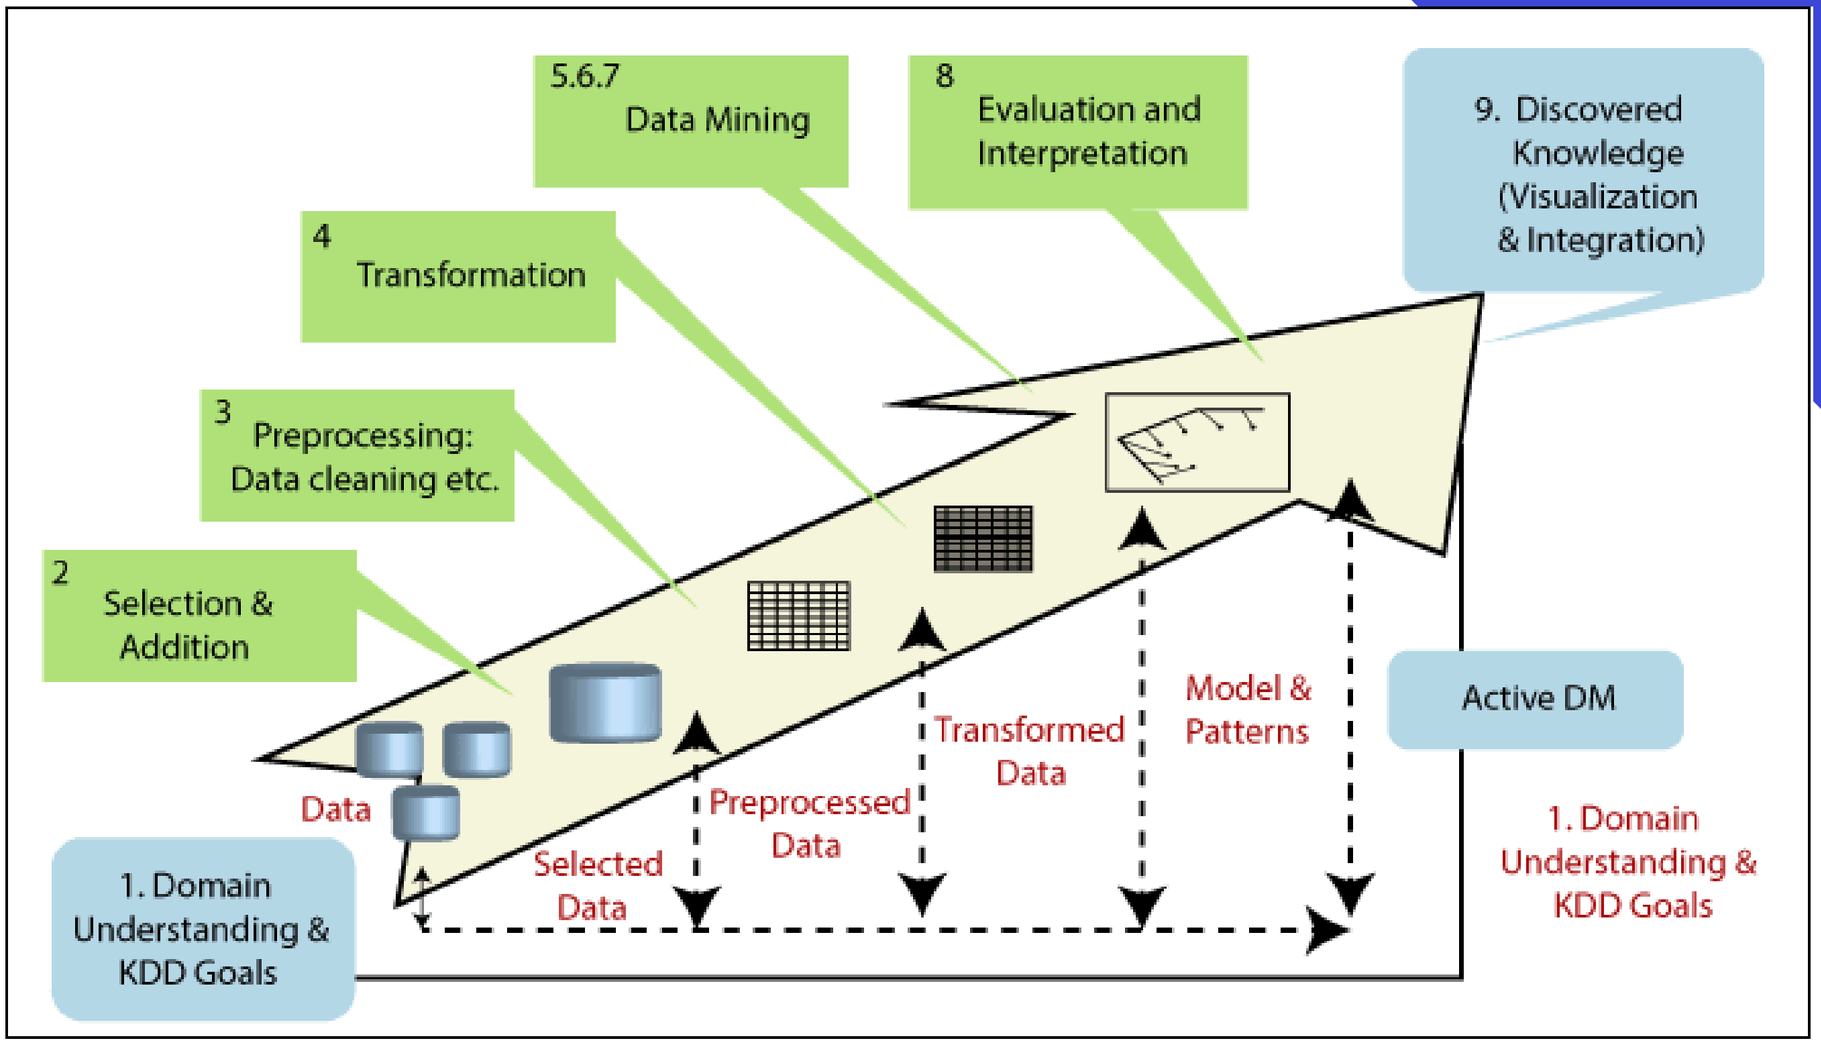


Imagen: https://www.javatpoint.com/kdd-process-in-data-mining

9 STEPS

Fuente: Fayyad, Piatetsky-Shapiro, & Smyth (1996)

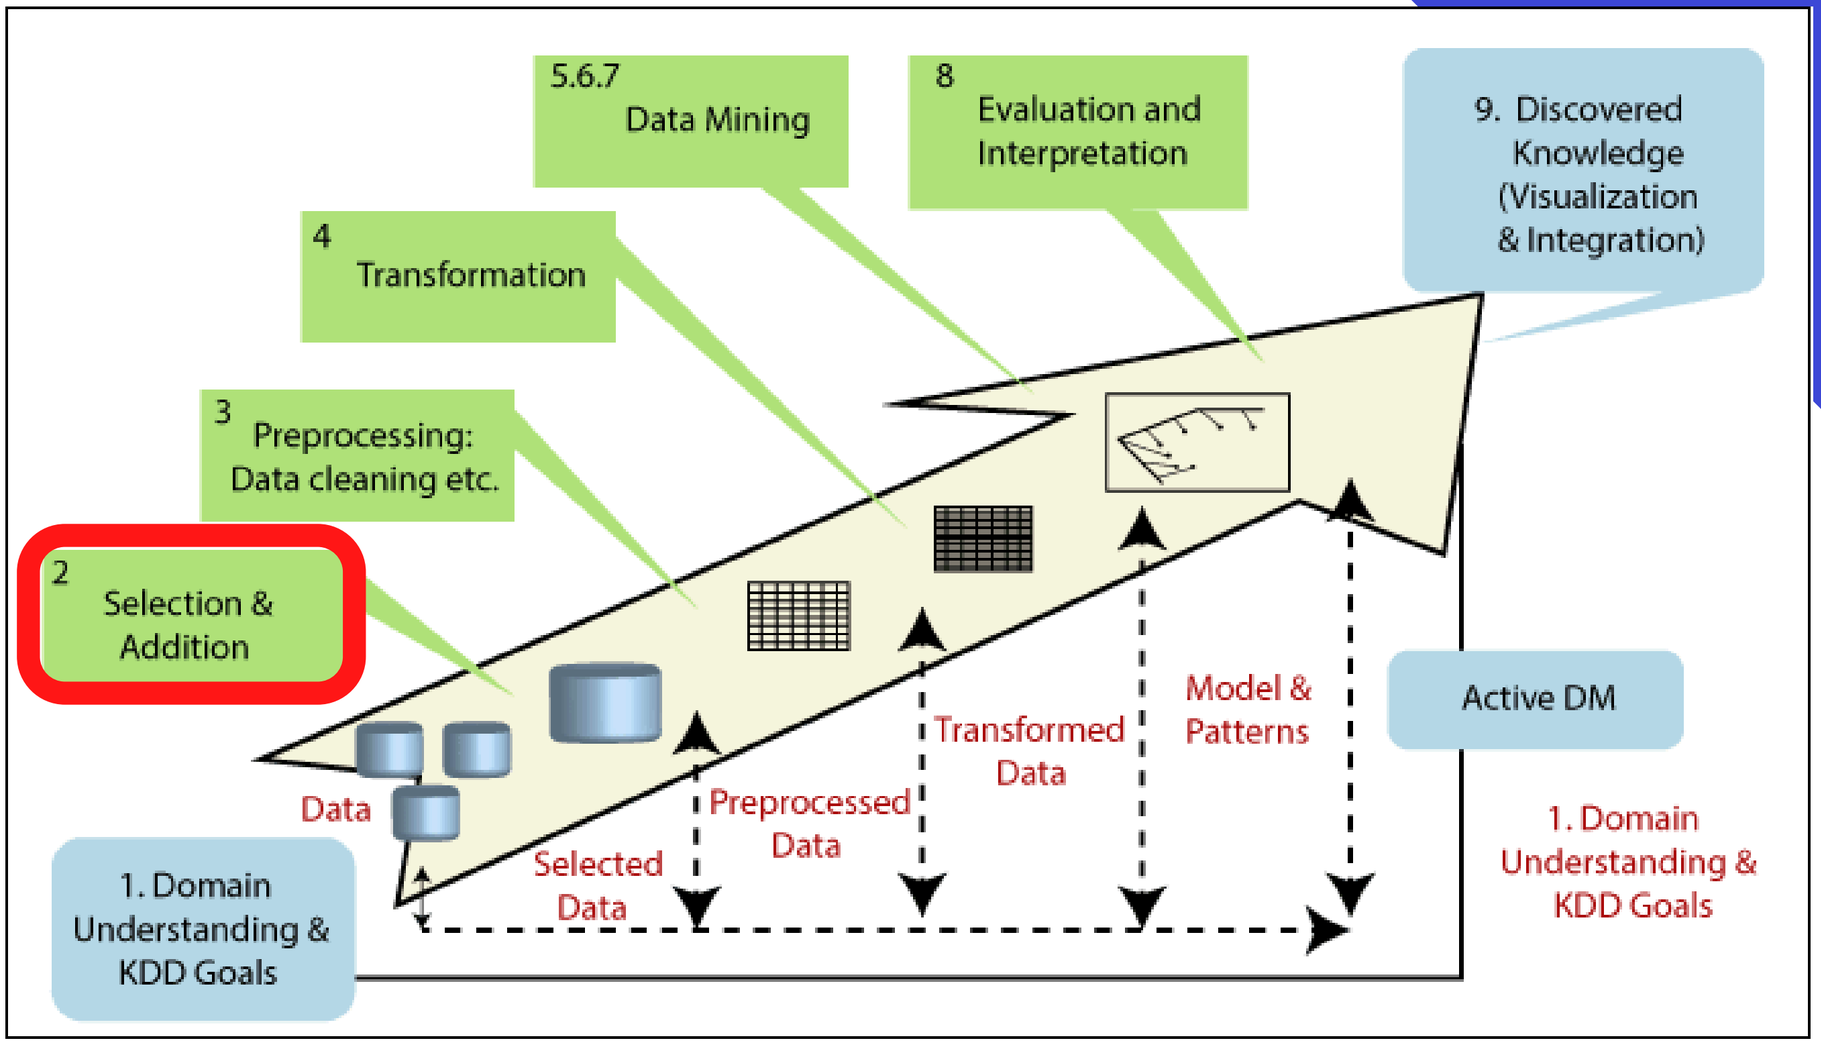
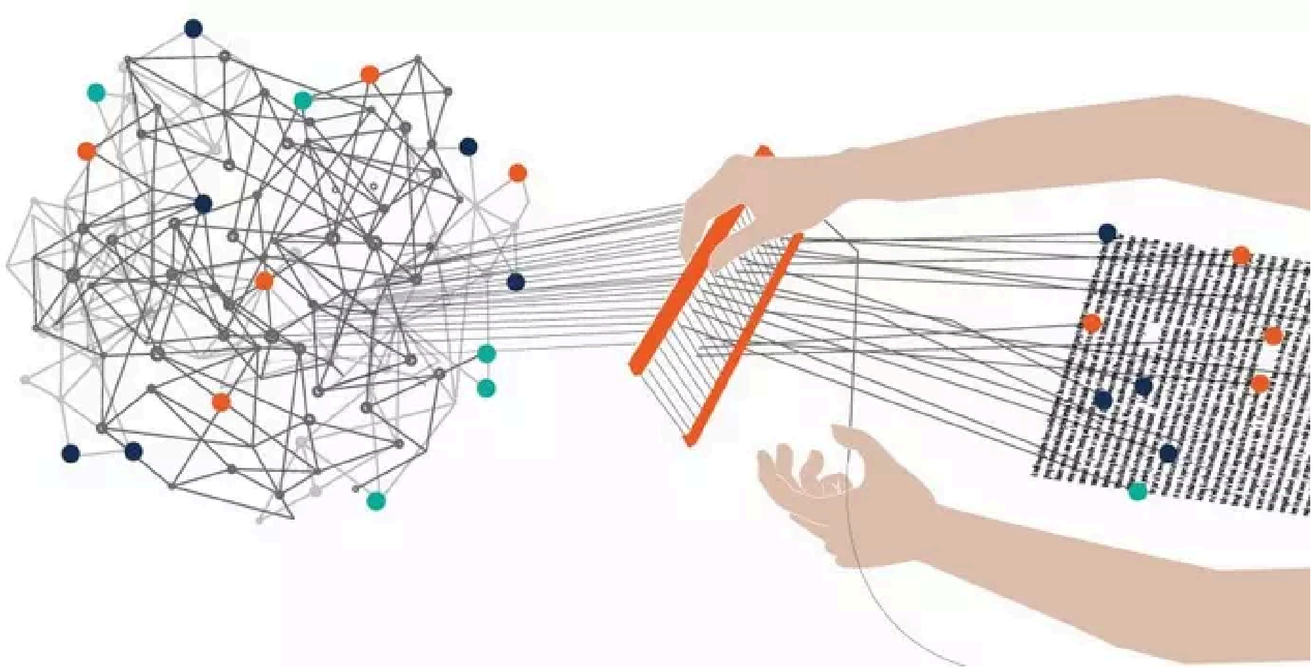


Imagen: https://www.javatpoint.com/kdd-process-in-data-mining

ESTRUCTURADOS VS NO ESTRUCTURADOS



Estructurados vs No Estructurados

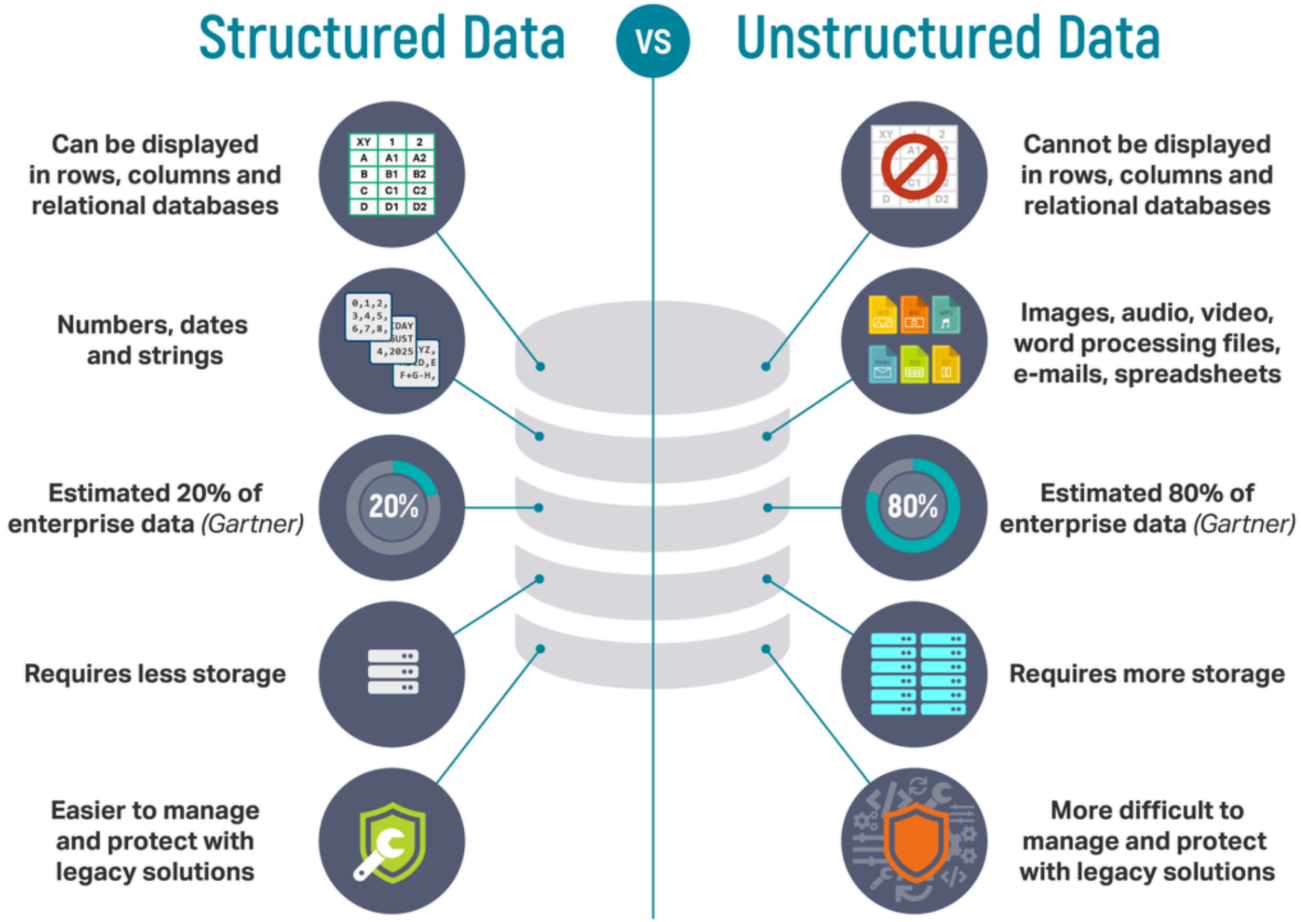


Imagen: imagen de Lawtomated

TIPOS DE VARIABLES



Tipos de Variables

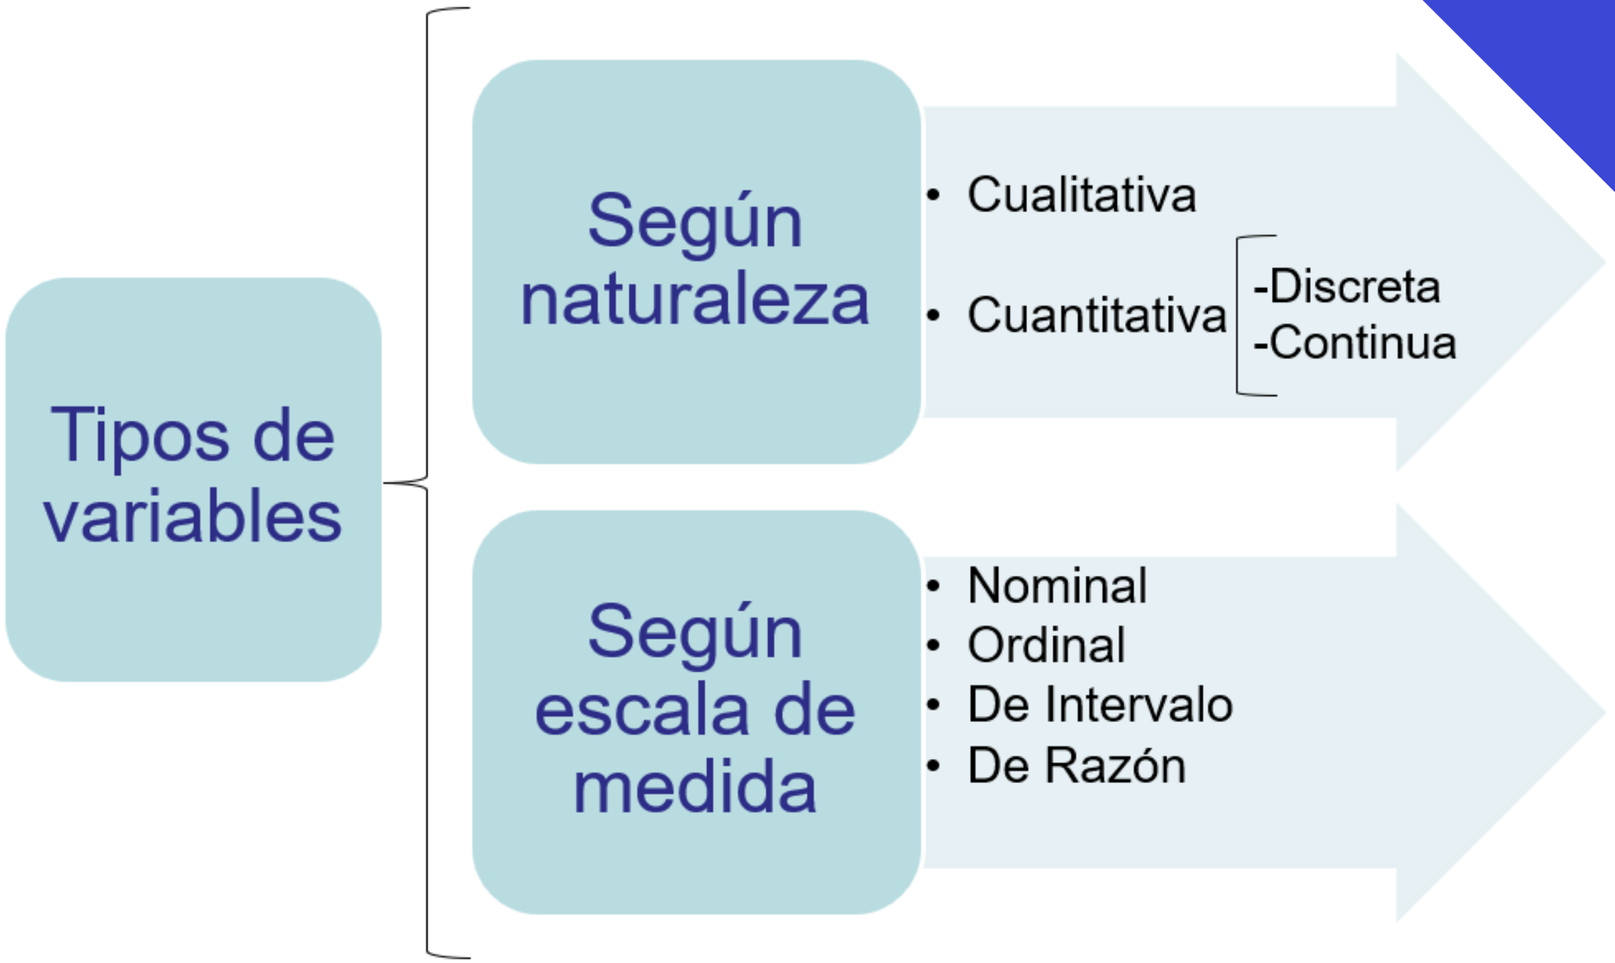


Imagen: Elaboración propia

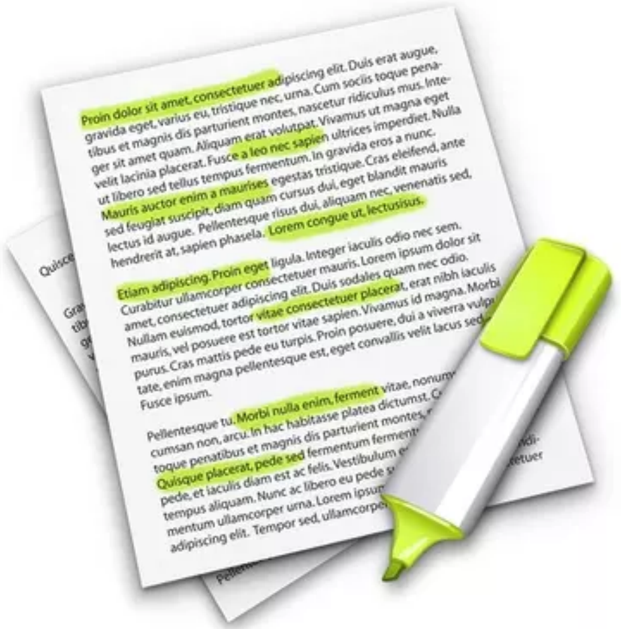
… en Python

In Python, the data type is set when you assign a value to a variable:

Example	Data Type	Try it
`x = "Hello World"`	str	Try it »
`x = 20`	int	Try it »
`x = 20.5`	float	Try it »
`x = 1j`	complex	Try it »
`x = ["apple", "banana", "cherry"]`	list	Try it »
`x = ("apple", "banana", "cherry")`	tuple	Try it »
`x = range(6)`	range	Try it »
`x = {"name" : "John", "age" : 36}`	dict	Try it »
`x = {"apple", "banana", "cherry"}`	set	Try it »
`x = frozenset({"apple", "banana", "cherry"})`	frozenset	Try it »
`x = True`	bool	Try it »
`x = b"Hello"`	bytes	Try it »
`x = bytearray(5)`	bytearray	Try it »
`x = memoryview(bytes(5))`	memoryview	Try it »

Imagen: https://www.w3schools.com/python/python_datatypes.asp

MEDIDAS DE RESUMEN



Medidas de Resumen



Imagen: Elaboración propia

Tendencia Central

- **Media** ($\bar{x}$) :

Se le conoce como el promedio de los datos. Se define y se calcula mediante la suma de los datos dividido entre la cantidad existente de datos.

$$\bar{x} = \frac{\sum_{i=1}^{n} x_i}{n}$$

- **Mediana** (Me) :

Es el valor de la variable que divide al total de las “n” observaciones debidamente ordenadas en dos partes de igual tamaño.

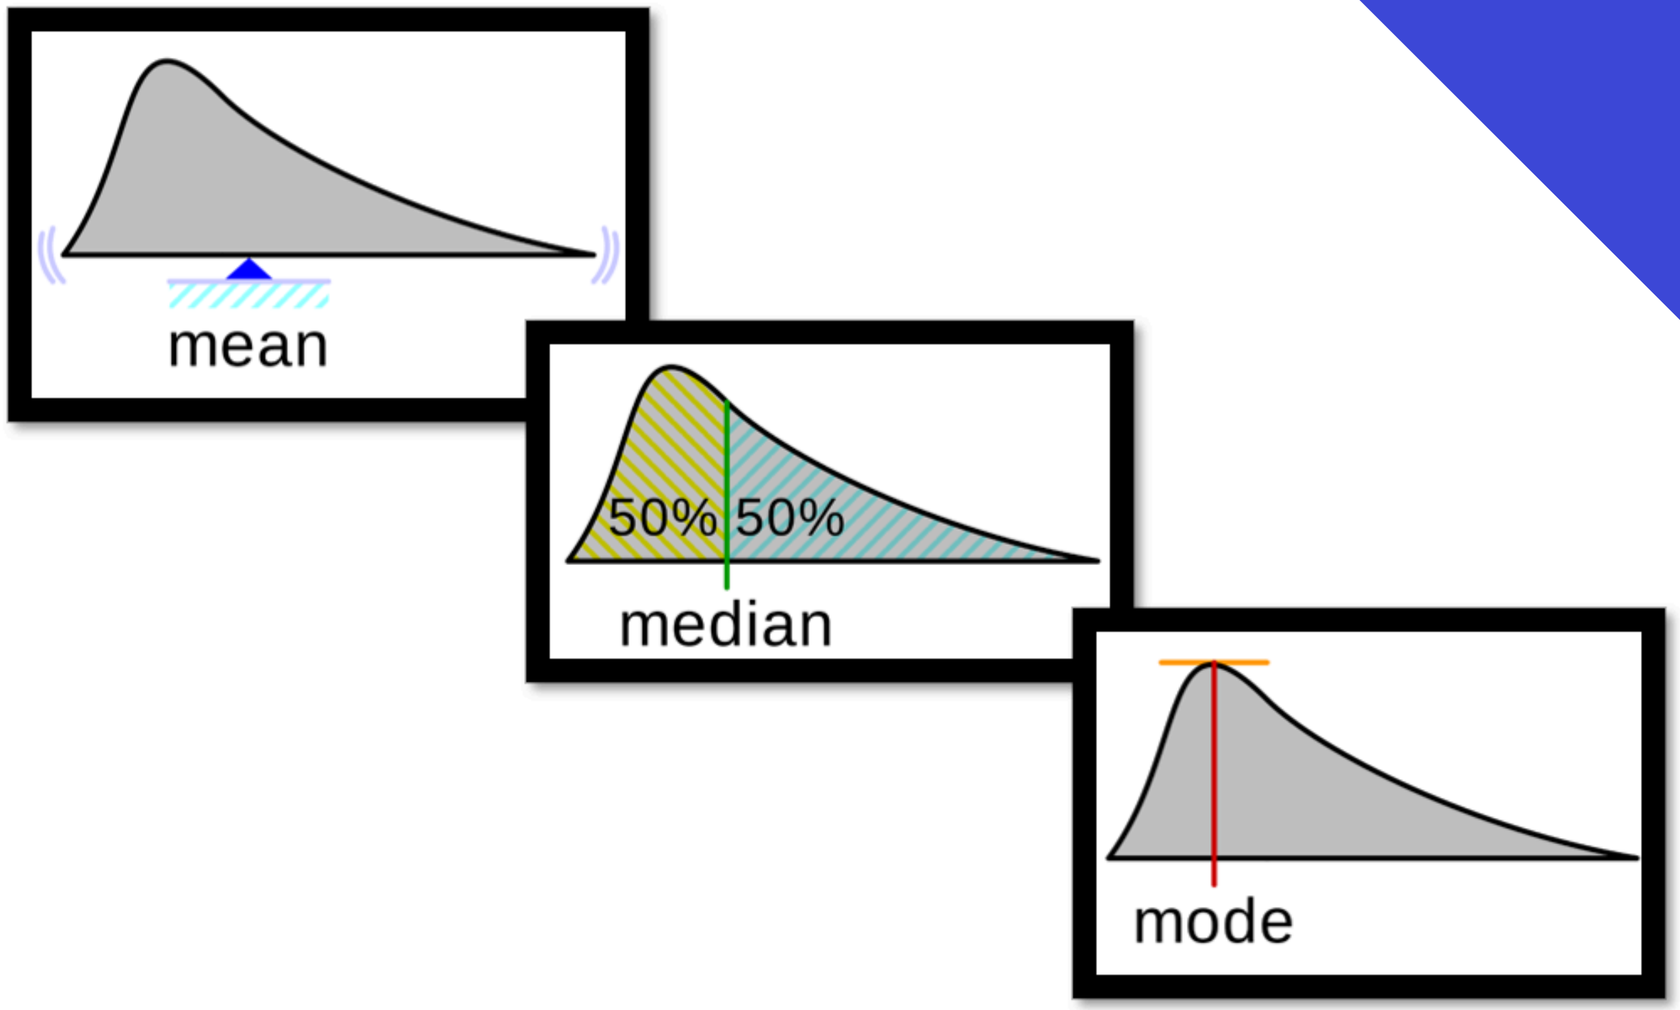
$$X_{((n+1)/2)} \quad , \quad n \text{ es impar}$$

$$\frac{X_{(n/2)} + X_{(n/2+1)}}{2} \quad , \quad n \text{ es par}$$

- **Moda** (Mo):

Es el valor más frecuente de la variable

Tendencia Central



Tendencia Central

- **Cuantiles:**

Son estadísticos de posición que dividen al total de las observaciones, debidamente ordenadas de menor a mayor, en “m” partes iguales.

$$\text{Cuantil}_i = \frac{i * n}{m}$$

- **Cuartil:** valor que divide las observaciones en 4 partes iguales

$$\text{Q}_i = \frac{i * n}{4}$$

- **Decil:** valor que divide las observaciones en 10 partes iguales

$$\text{D}_i = \frac{i * n}{10}$$

Variabilidad

- **Rango Intercuartil (ICR) :**

Diferencia o distancia entre el cuartil 3 y el cuartil 1 de la variable en estudio.

$$\mathrm{R} = Q_3 - Q_1$$

- **Varianza (s^2) :**

Es el promedio de las diferencias de cada observación respecto a la media de la variable.

$$s^2(x) = \frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1}$$

- **Desviación Estándar (s) :**

Es la raíz cuadrada de la varianza

$$s(x) = \sqrt[2]{\frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1}}$$

Variabilidad

- **<u>Coeficiente de variación</u> (CV):**

Se define como el cociente entre la desviación estándar y la media aritmética. Este estadístico se expresa en unidades independientes de la naturaleza de la variable.

$$CV(x) = \frac{s}{\bar{x}}$$

Se emplea para comparar dos o más distribuciones cuando las variables se encuentran expresadas en diferentes unidades o diferentes escalas de medida.

Una variable “x” es más homogénea (presenta menos dispersión) si tiene el menor Coeficiente de Variación.

Asimetría

- **Coeficiente de Asimetría (AS) :**

Mide la simetría o asimetría de la distribución de una determinada variable, si presenta una deformación hacia la izquierda o hacia la derecha.

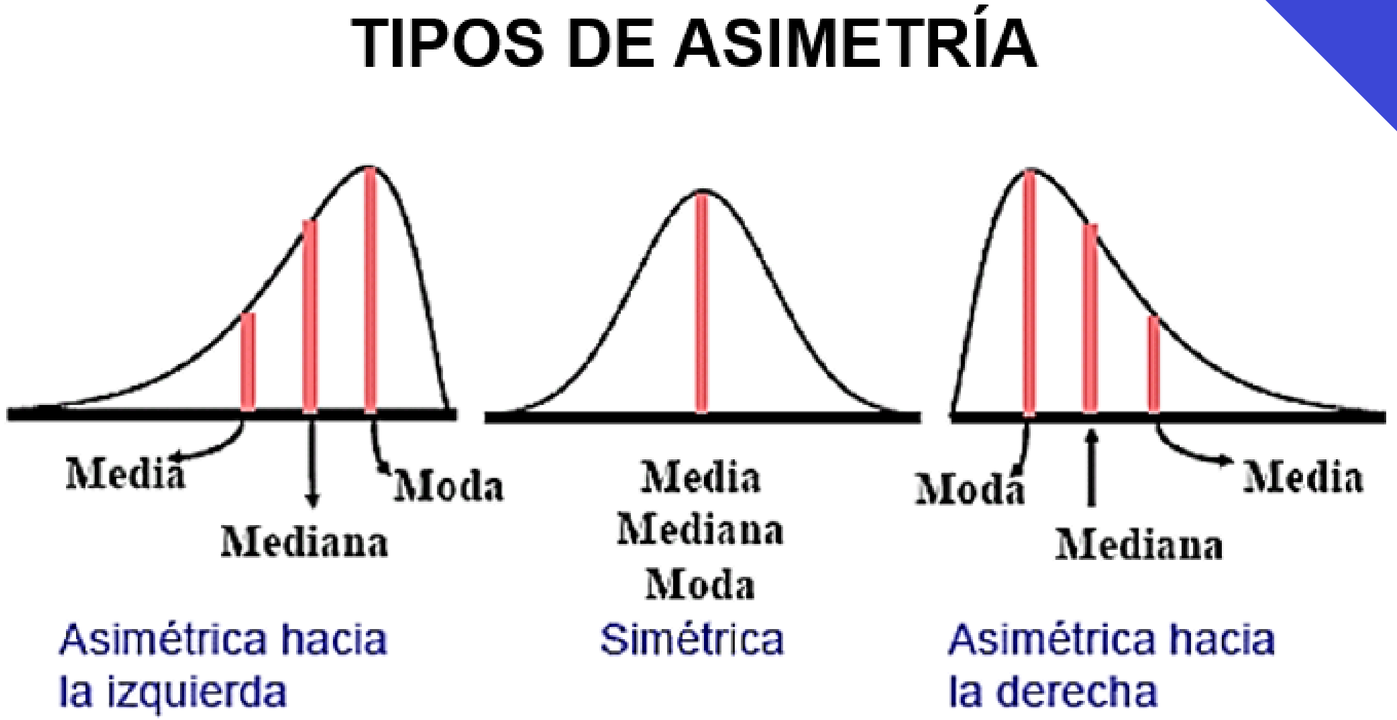
$$AS = \frac{3 * (\bar{Y} - Me)}{s}$$

Otras formas de calcular la asimetría:

$$AS = \frac{\bar{Y} - Mo}{s}$$

$$AS = \frac{Q_3 - 2Q_2 + Q_1}{Q_3 - Q_1}$$

Asimetría



Asimetría Negativa
AS < 0

AS = 0

Asimetría Positiva
AS > 0

Curtosis

- **Coeficiente de Curtosis (K) :**

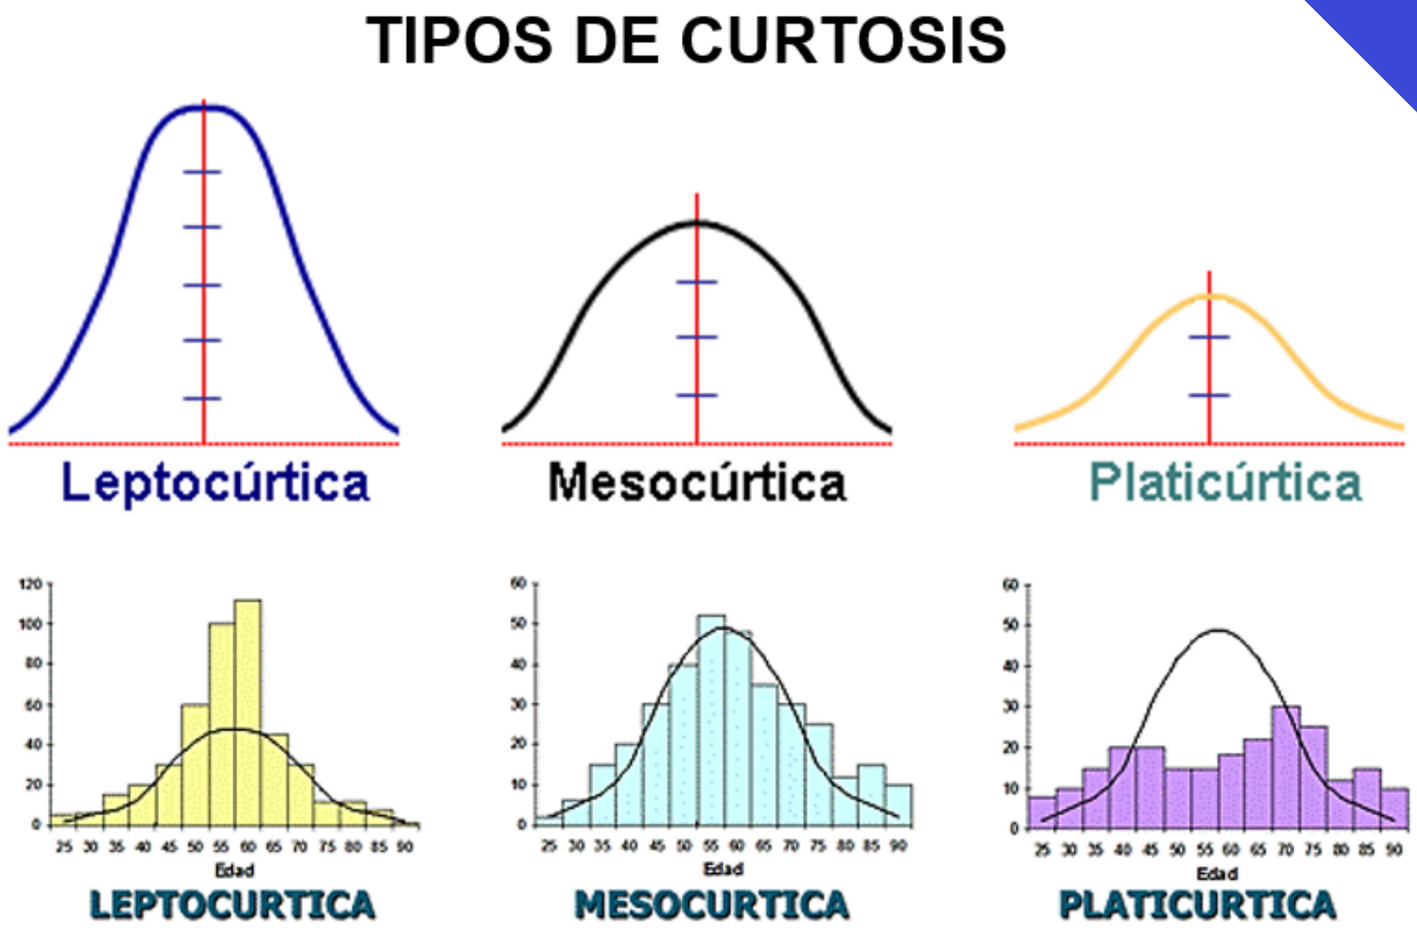
Mide el grado de apuntamiento o de deformación vertical de la distribución de una variable.

$$Curtosis = a_4 = \frac{\left(\frac{\sum_{i=1}^{m}(X_i - \bar{X})^4 n_i}{n}\right)}{s^4}$$

Otra forma de calcular el apuntamiento:

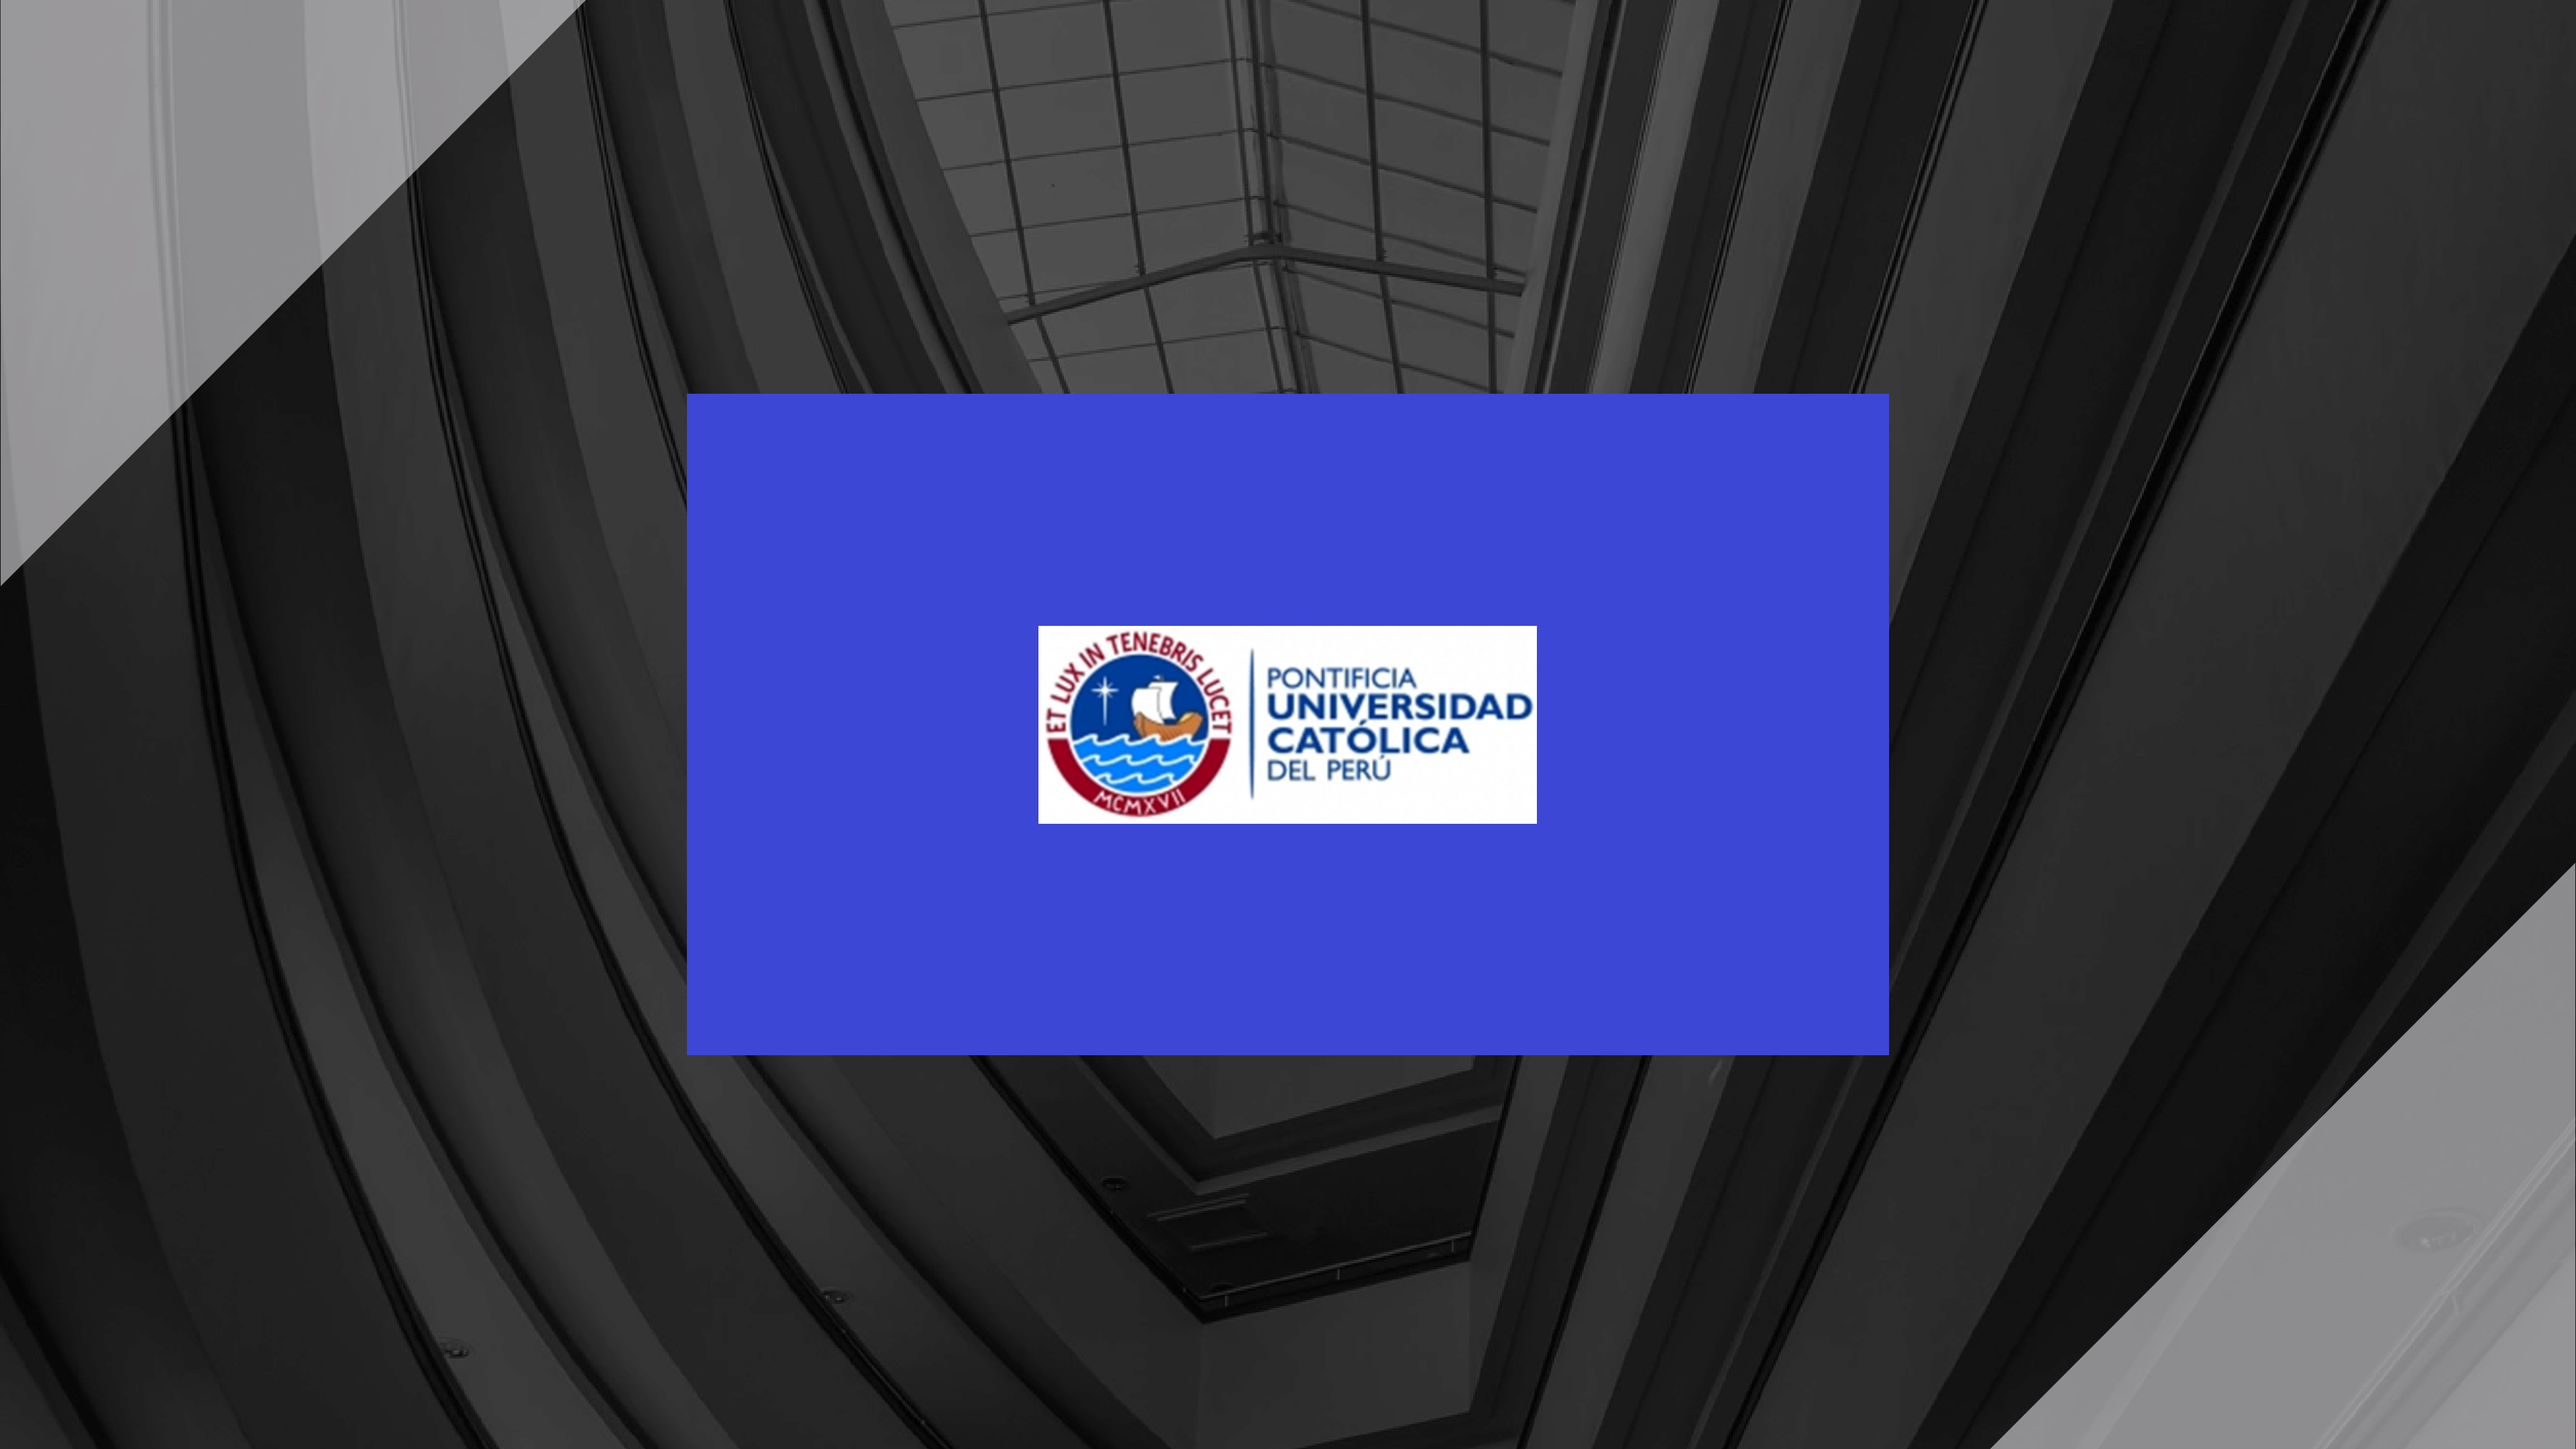
Coeficiente Percentil de Curtosis: $K = \frac{\left(\frac{Q_3 - Q_1}{2}\right)}{P_{90} - P_{10}}$

Curtosis


TIPOS DE CURTOSIS
Leptocúrtica
Mesocúrtica
Platicúrtica
Edad
LEPTOCURTICA
Edad
MESOCURTICA
Edad
PLATICURTICA

OUT PUT

"REPORTE DE SELECCIÓN Y ENTENDIMIENTO DE DATOS"


ET LUX IN TENEBRIS LUCET
MCMXVII
PONTIFICIA
UNIVERSIDAD
CATÓLICA
DEL PERÚ