PONTIFICIA UNIVERSIDAD CATÓLICA DEL PERÚ

1INF03 - Análisis de datos
2026-2

SEMANA 2:

STEP 3
"PRE-PROCESAMIENTO: LIMPIEZA DE DATOS"

Profesora: Stéfany Neciosup Vera
stefany.neciosup@pucp.edu.pe

9 STEPS

Fuente: Fayyad, Piatetsky-Shapiro, & Smyth (1996)

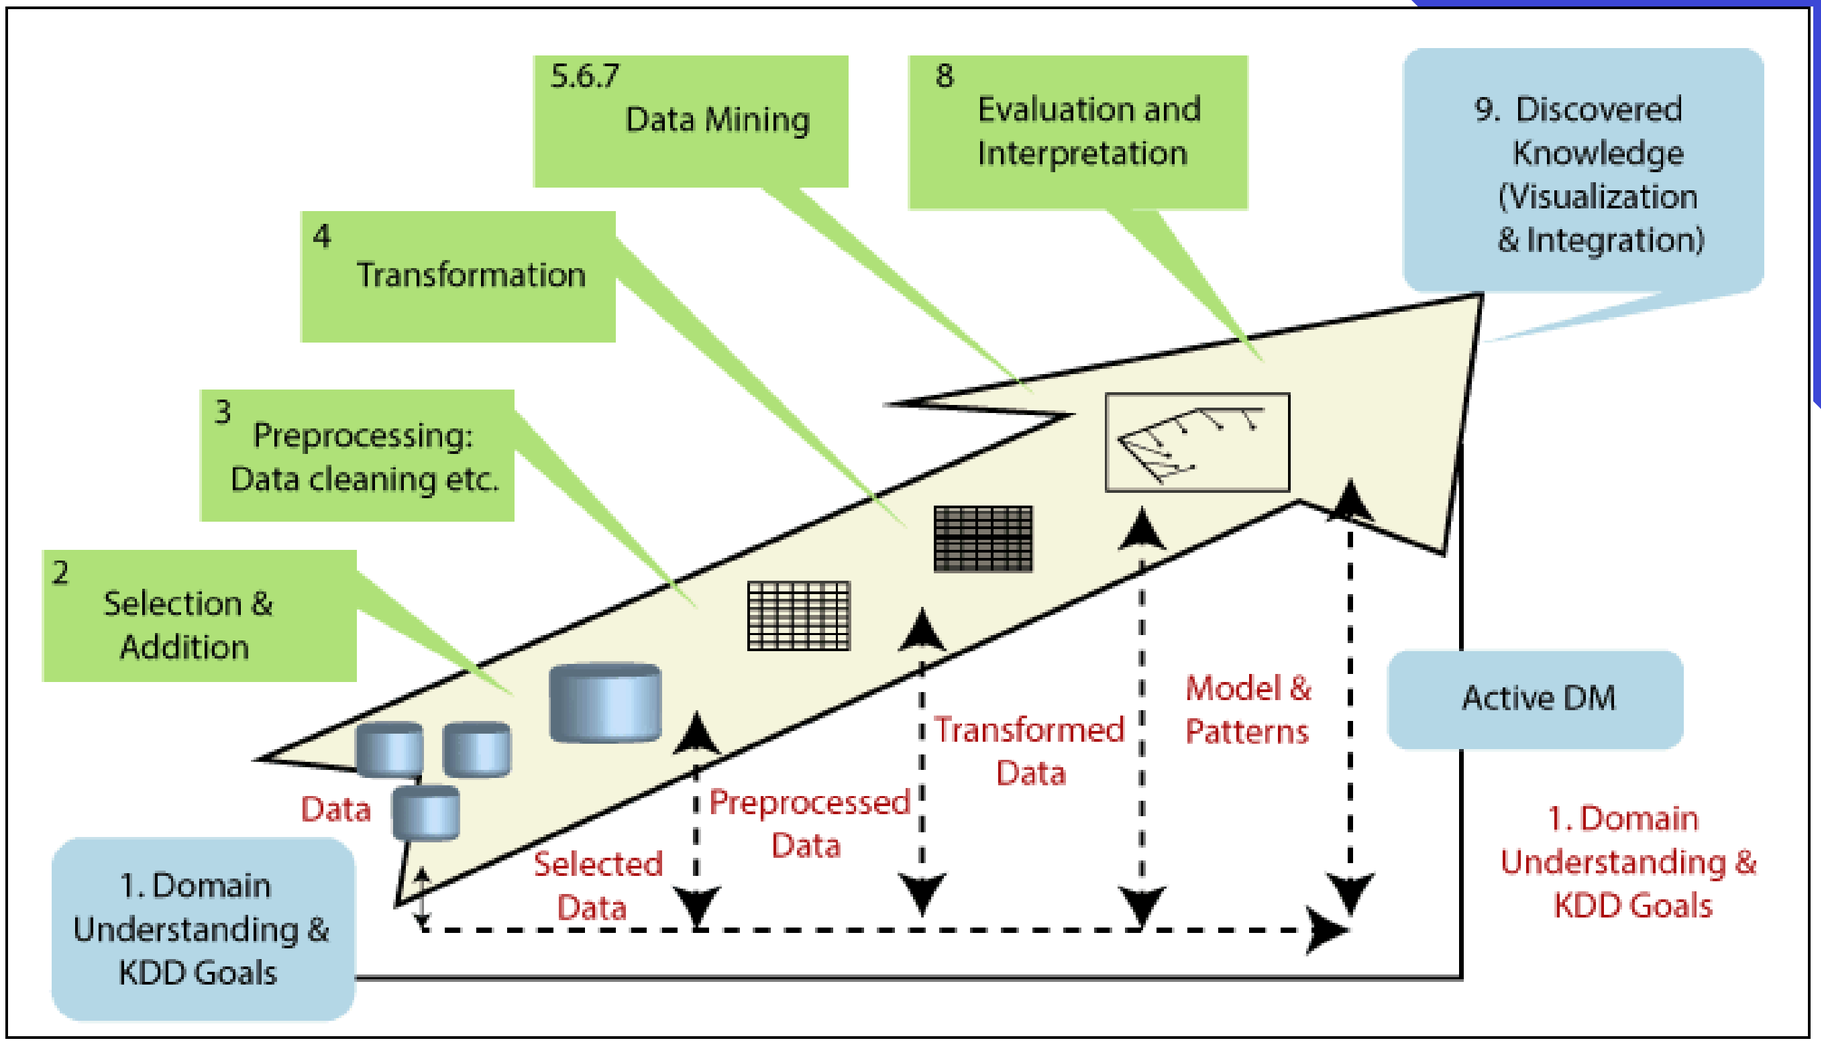


Imagen: https://www.javatpoint.com/kdd-process-in-data-mining

9 STEPS

Fuente: Fayyad, Piatetsky-Shapiro, & Smyth (1996)

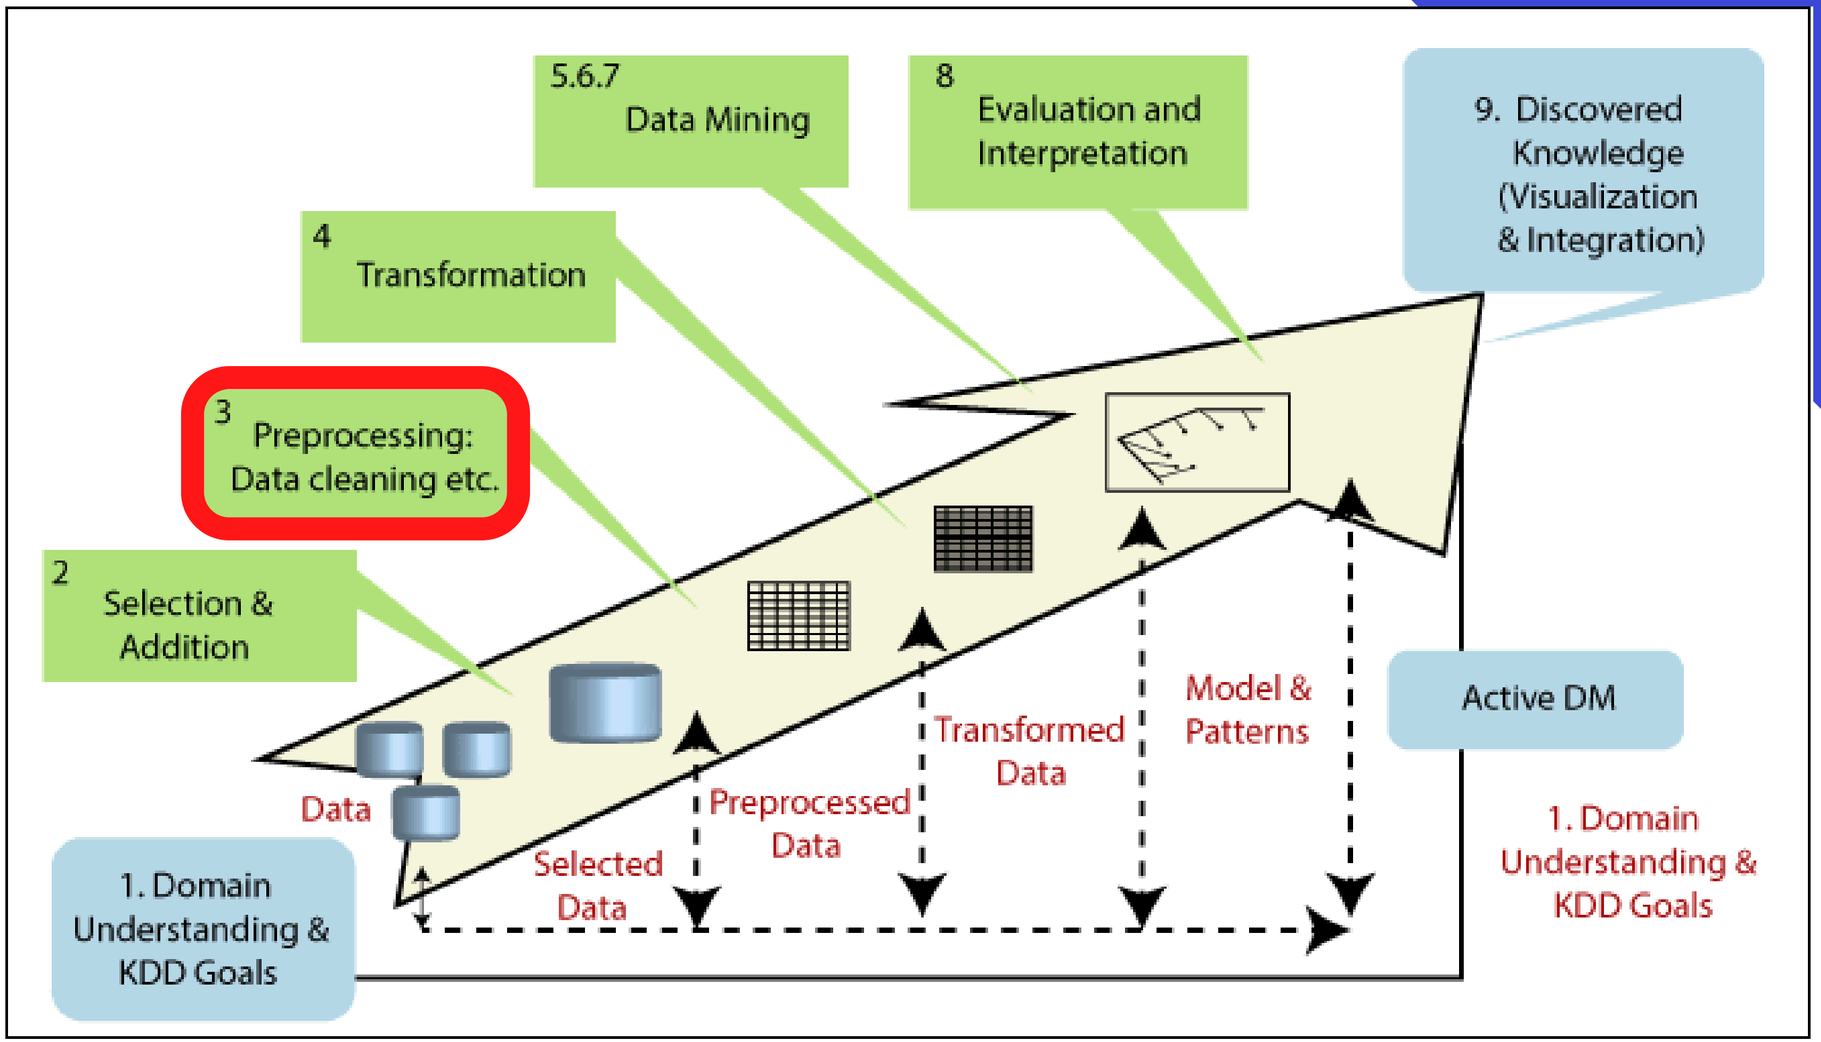
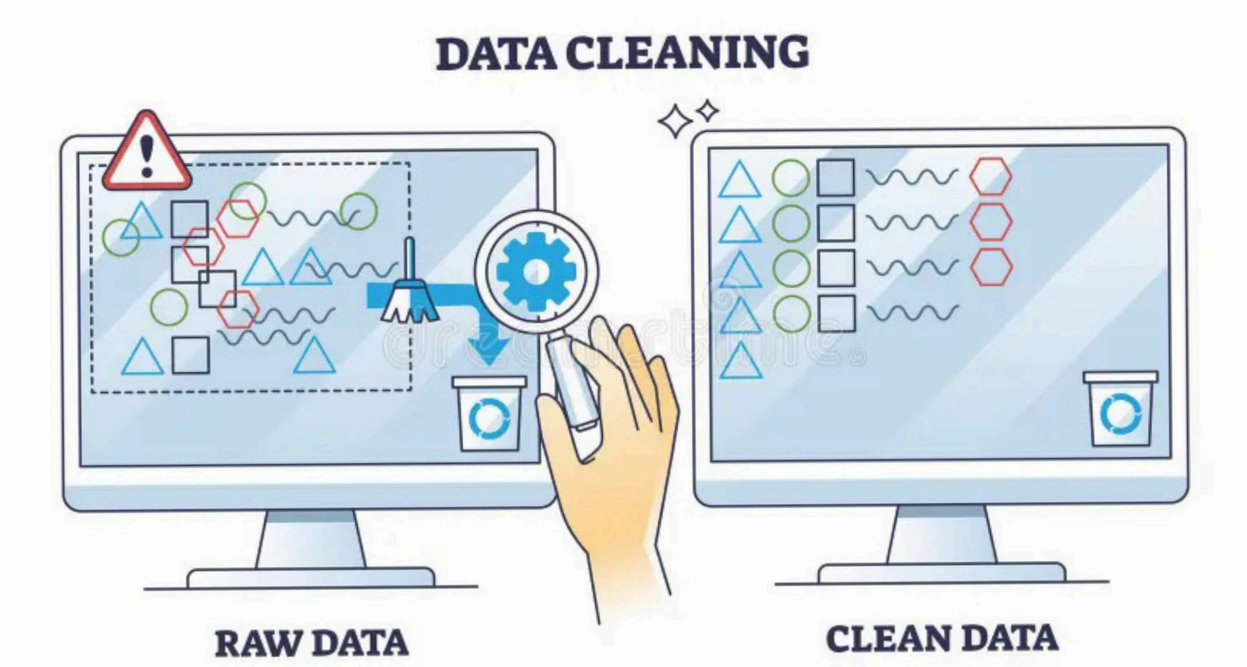


Imagen: https://www.javatpoint.com/kdd-process-in-data-mining

DATA CLEANING: ¿POR QUÉ ES IMPORTANTE?



DATOS DUPLICADOS

- Duplicados completos

  Son filas completamente iguales en todas las columnas.

  `df.duplicated()`

- Duplicados parciales

  Son filas solo duplicadas en una o más columnas clave, como ID y fecha

  `df.duplicated(subset=['ID', 'fecha'])`

DATOS VACÍOS

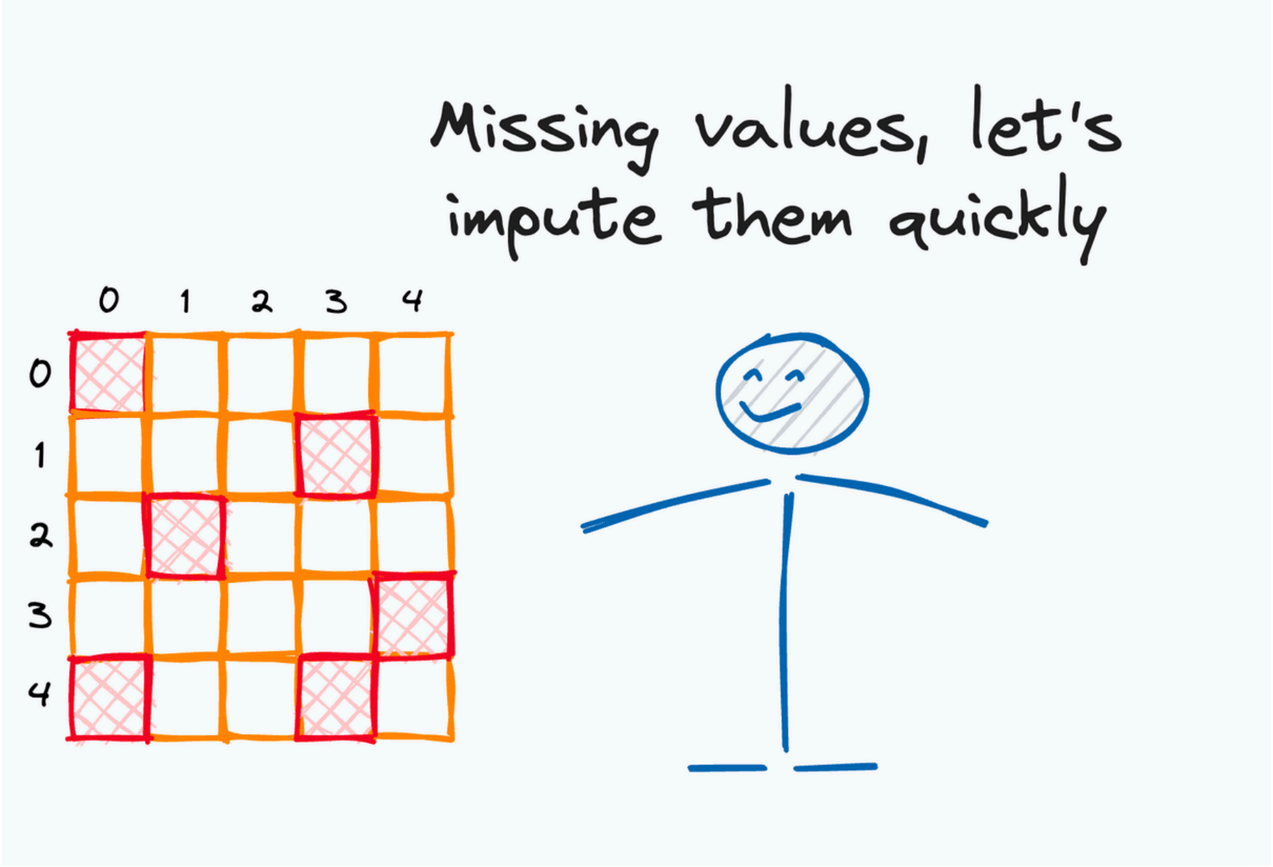
Datos vacíos: Empty data

Celdas vacías visualmente, pueden contener un espacio en blanco, una cadena vacía "", o pueden no tener nada. Deben convertirse a NA o NaN.

" " : espacio en blanco

"" : cadena vacía

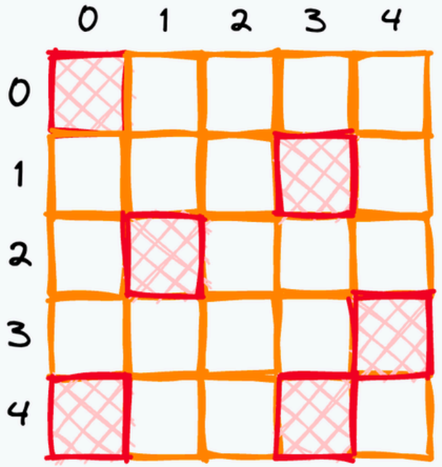
NA / NaN : sin dato



https://blog.dailydoseofds.com/p/3-types-of-missing-values



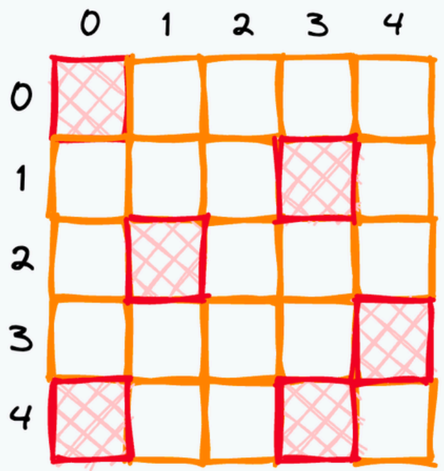
Missing values, let's impute them quickly







I must understand WHY do I have missing values before imputing them





https://blog.dailydoseofds.com/p/3-types-of-missing-values

Datos faltantes: Missing data

- MCAR -> Missing Completely at Random

  El dato falta completamente al azar, sin relación con otras variables ni con el valor perdido.

- MAR -> Missing at Random

  El dato faltante depende de otras variables observadas, pero no del valor que falta.

- MNAR -> Missing Not at Random

  El hecho de que el dato falte sí depende del valor que falta (no observable). Muy problemático.

Missing completely at random (MCAR)

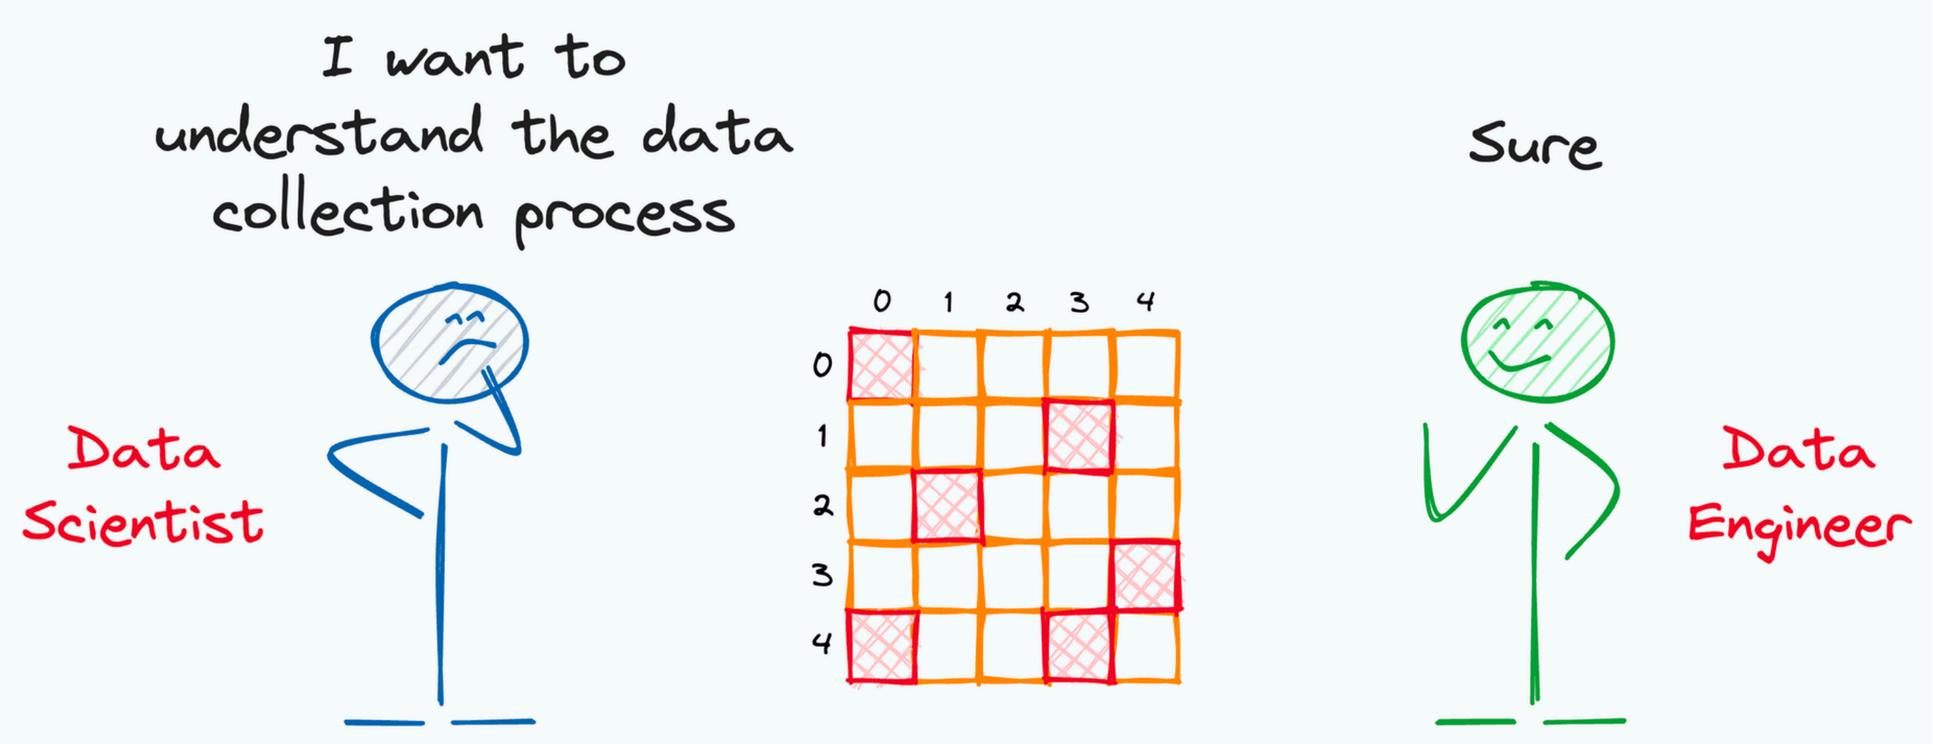
El dato falta completamente al azar, sin relación con otras variables ni con el valor perdido.



https://blog.dailydoseofds.com/p/3-types-of-missing-values

Missing completely at random (MCAR)

El dato falta completamente al azar, sin relación con otras variables ni con el valor perdido.



https://blog.dailydoseofds.com/p/3-types-of-missing-values

Missing completely at random (MCAR)

Causa ----> Soluciones

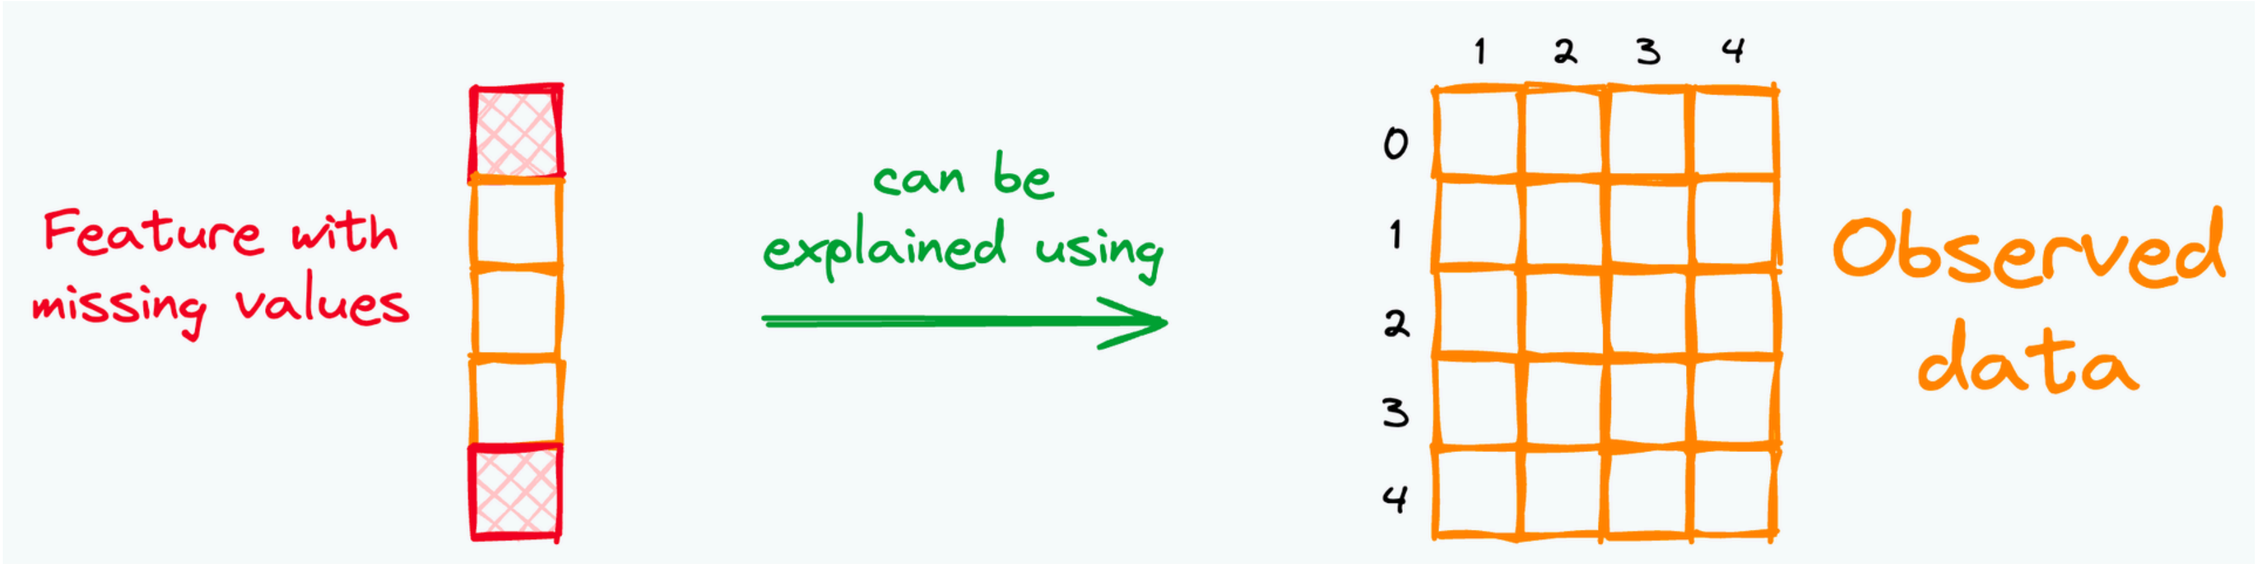
MCAR

- Eliminar filas
- Eliminar columnas
- Imputación simple o univariada

https://blog.dailydoseofds.com/p/3-types-of-missing-values

Missing at random (MAR)

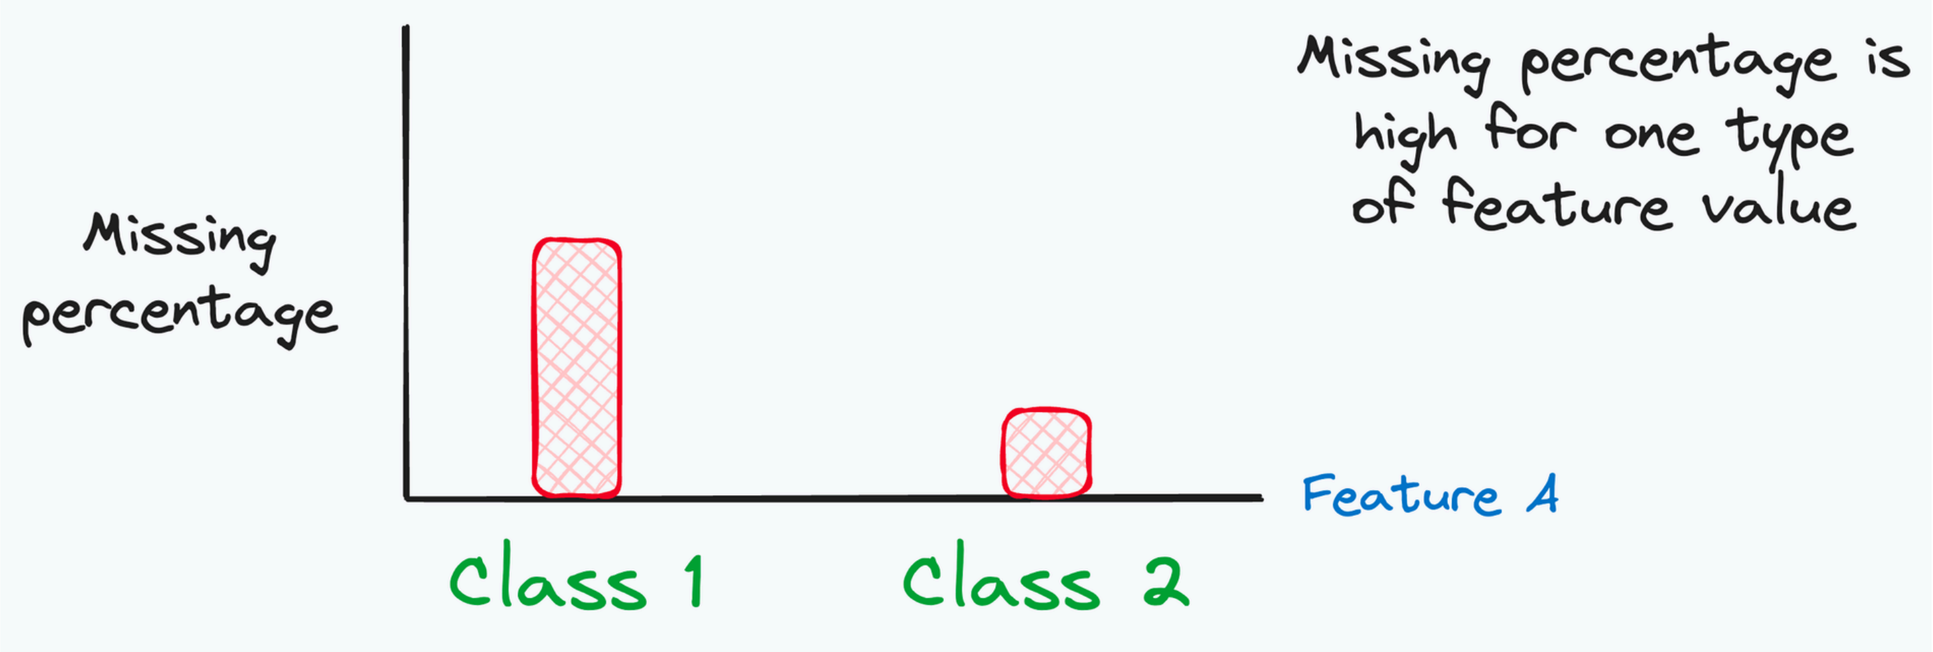
El dato faltante depende de otras variables observadas, pero no del valor que falta.



https://blog.dailydoseofds.com/p/3-types-of-missing-values

Missing at random (MAR)

El dato faltante depende de otras variables observadas, pero no del valor que falta.



https://blog.dailydoseofds.com/p/3-types-of-missing-values

Missing at random (MAR)

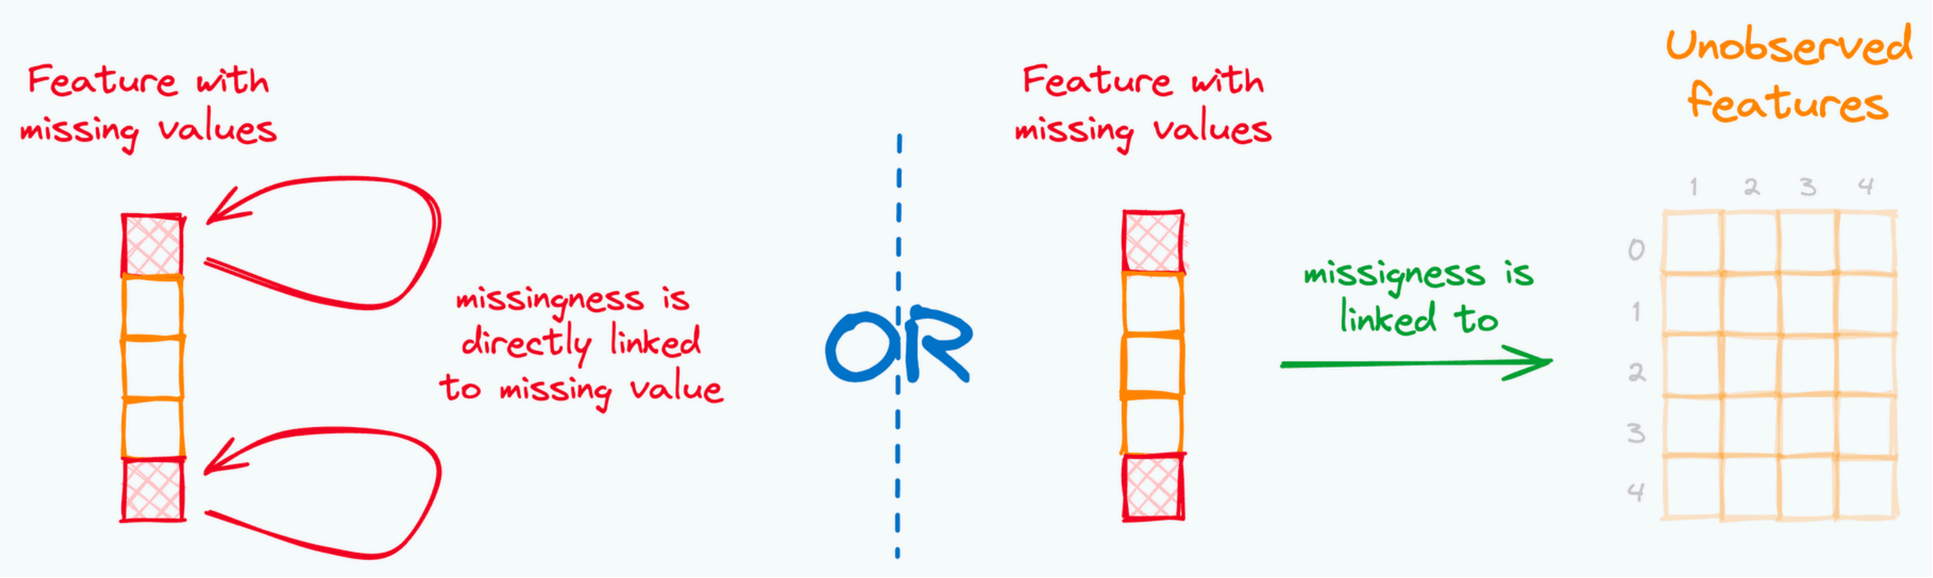
Causa ----> Soluciones

MAR

- Imputación condicional
- Imputación multivariada
- Modelos bayesianos o EM

Missing not at random (MNAR)

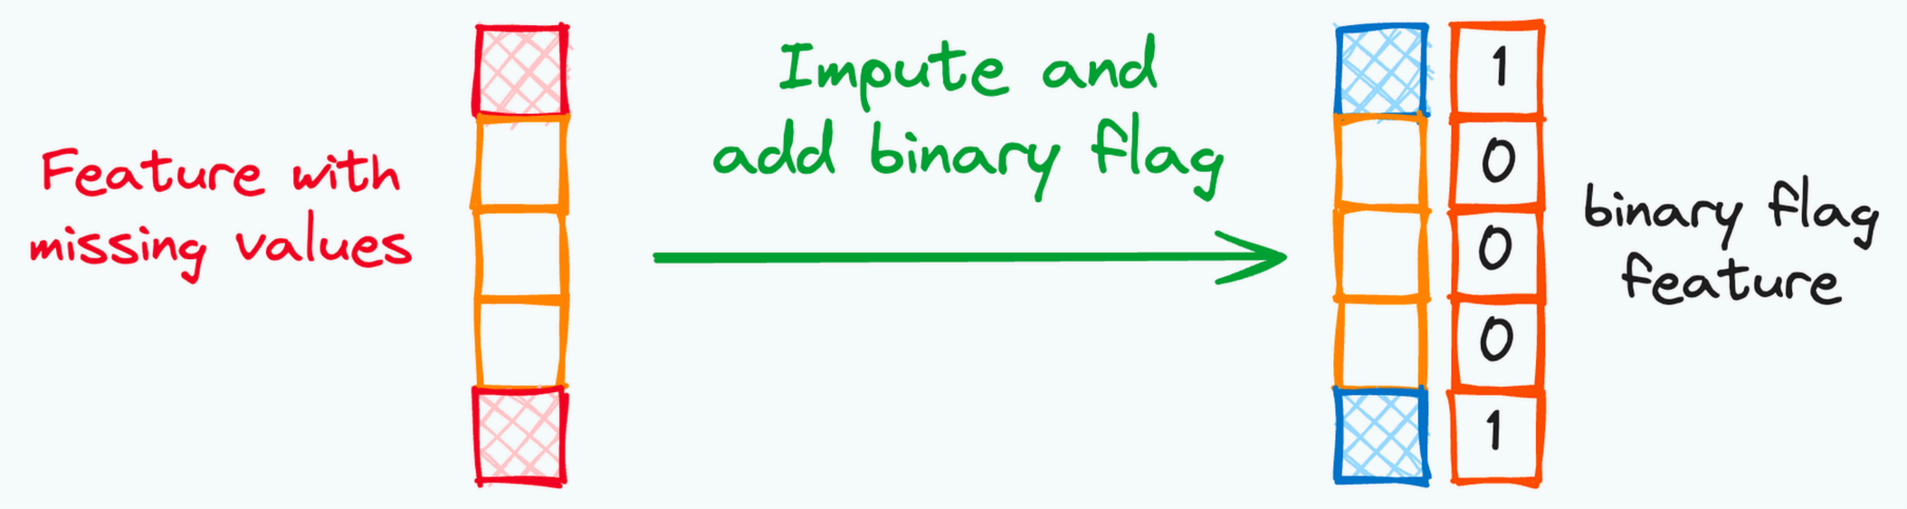
El hecho de que el dato falte sí depende del valor que falta (no observable). Muy problemático.



https://blog.dailydoseofds.com/p/3-types-of-missing-values

Missing not at random (MNAR)

El hecho de que el dato falte sí depende del valor que falta (no observable). Muy problemático.



https://blog.dailydoseofds.com/p/3-types-of-missing-values

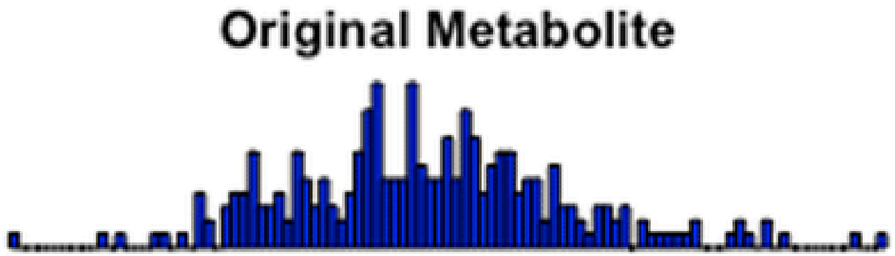
Missing not at random (MNAR)

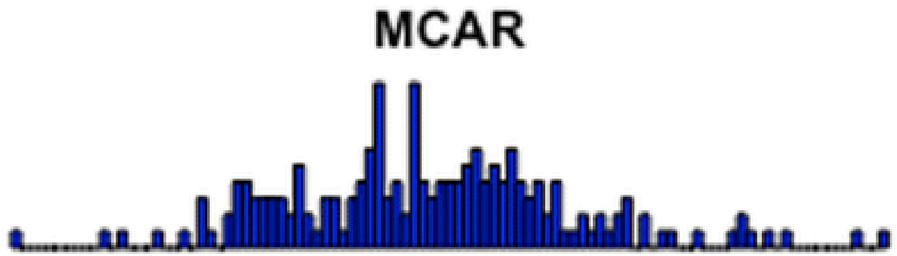
Causa ----> Soluciones

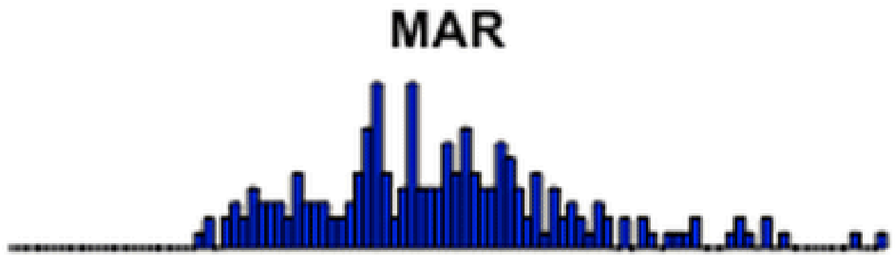
MNAR

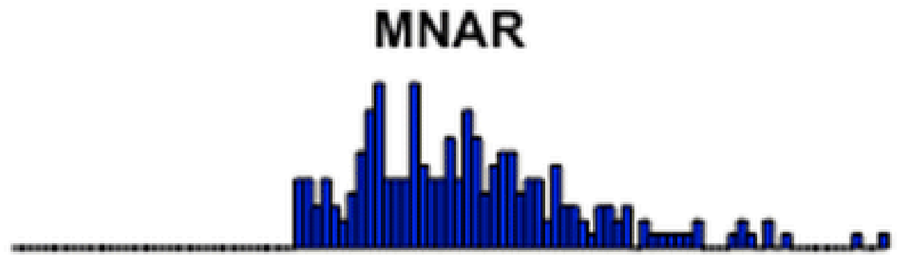
- Recuperar valores de fuentes externas
- Heckman imputation
- Mejorar mecanismos de recolección de datos

Simulation of missing values









https://www.researchgate.net/figure/Distribution-based-examples-of-the-simulated-missing-mechanisms-Simulation-of-missing_fig5_336471983