

1INF03 - Análisis de datos
2026-2

SEMANA 4:

STEP 4
"REDUCCIÓN DE DIMENSIONES"

Profesora: Stéfany Neciosup Vera
stefany.neciosup@pucp.edu.pe

9 STEPS

Fuente: Fayyad, Piatetsky-Shapiro, & Smyth (1996)

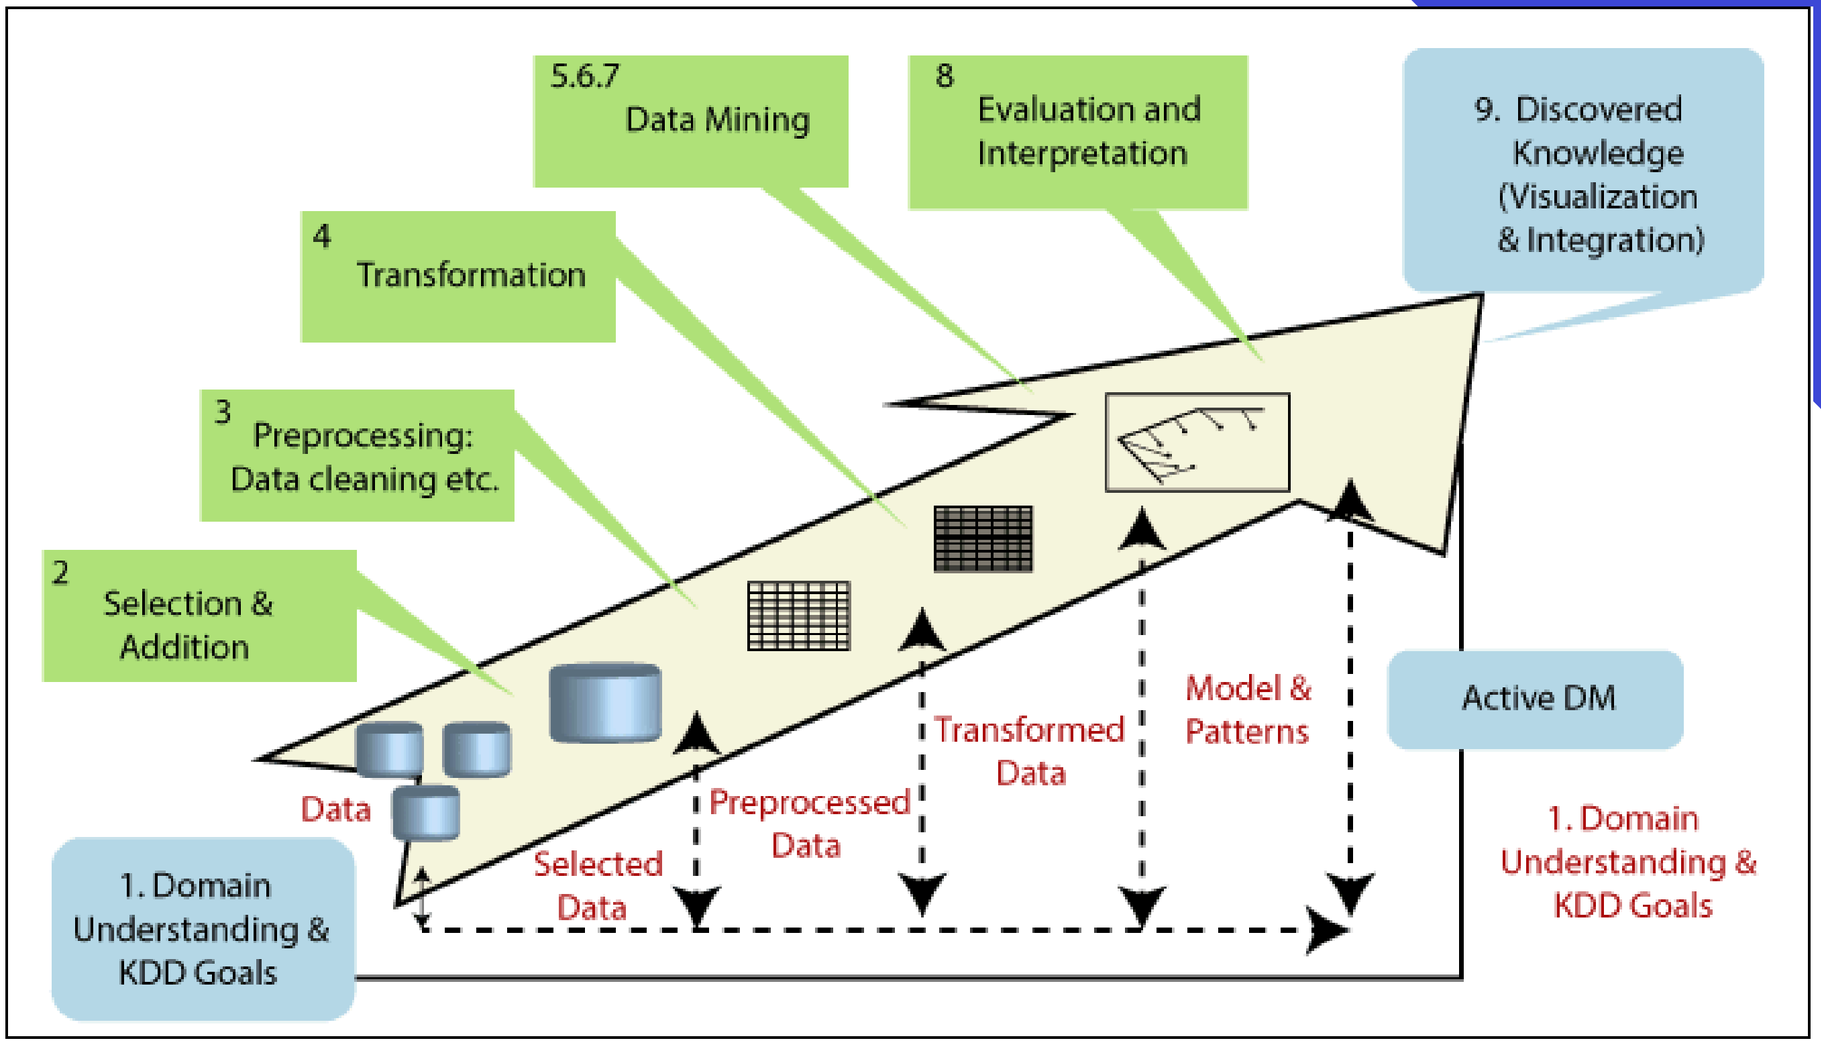


Imagen: https://www.javatpoint.com/kdd-process-in-data-mining

9 STEPS

Fuente: Fayyad, Piatetsky-Shapiro, & Smyth (1996)

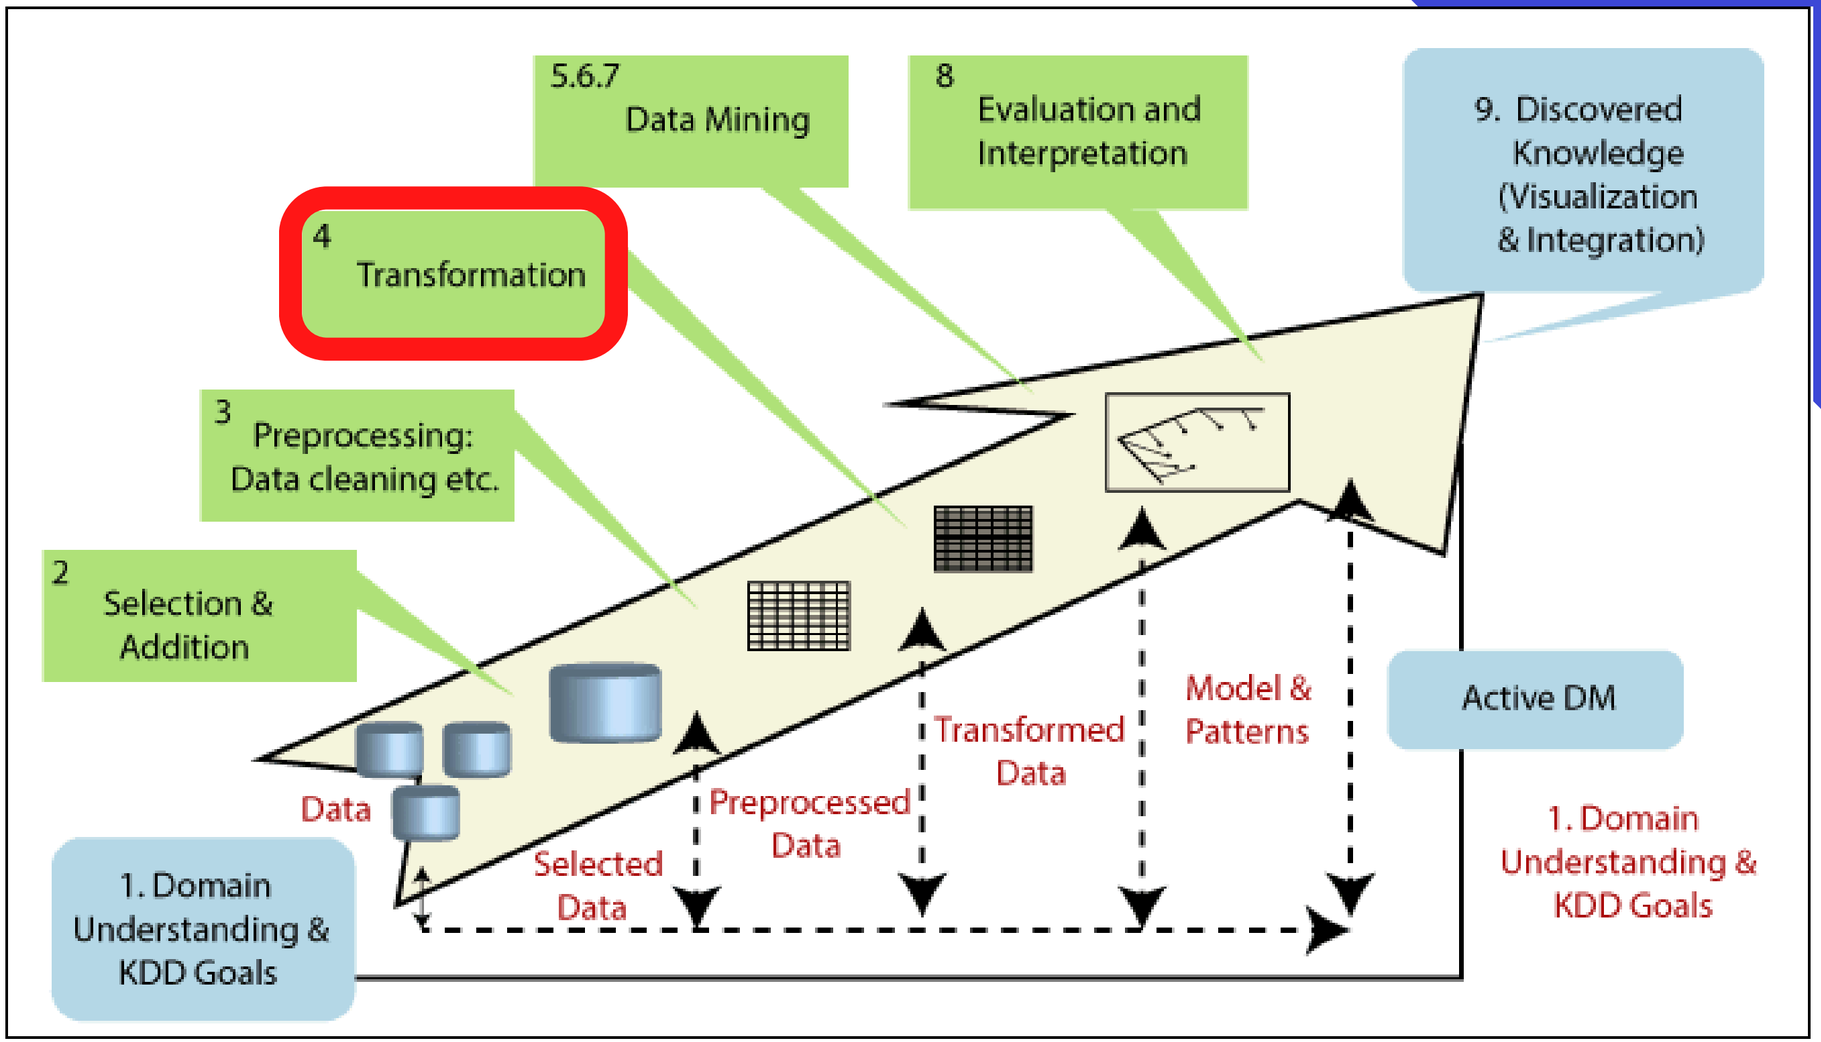


Imagen: https://www.javatpoint.com/kdd-process-in-data-mining

ANÁLISIS DE COMPONENTES PRINCIPALES (PCA)

Análisis de Componentes Principales

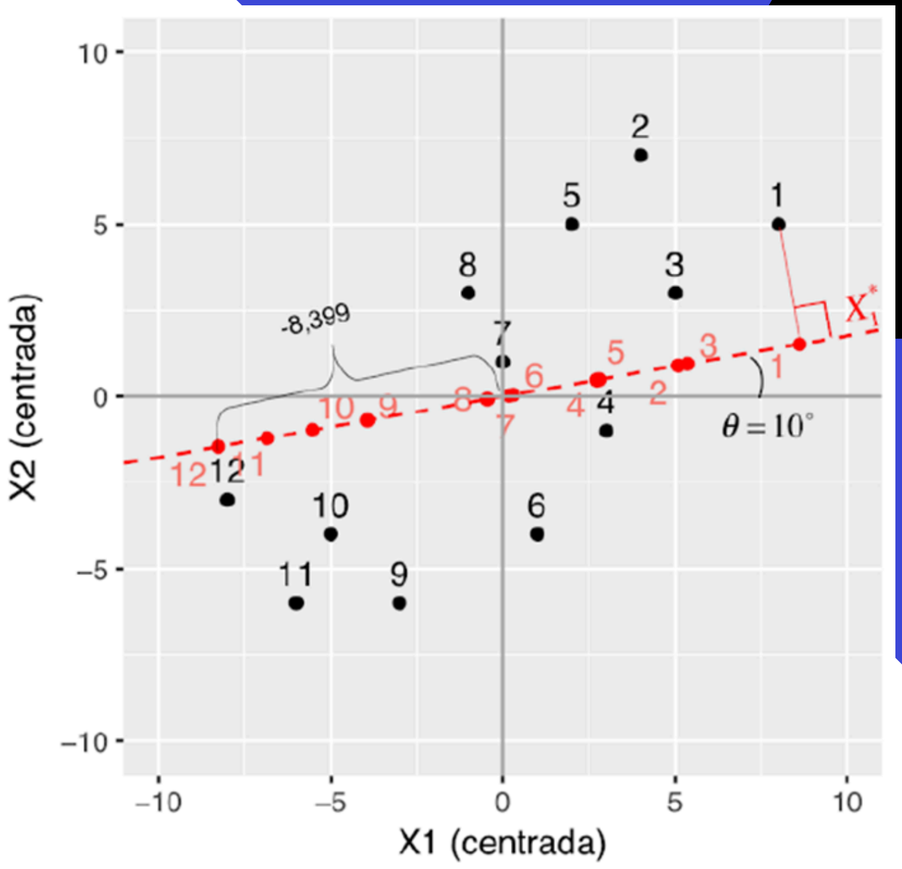
- Nació como método de reducción de dimensiones
- Sirve por tanto para reducir un conjunto importante de variables a un subconjunto menor.
- Ejemplo. Un análisis de regresión con pocas observaciones (n) con relación al número de variables (k) i.e. situación de overfitting donde el R^2 es **artificialmente** alto pero el $\bar{R}^2$ es bajo o negativo.
- Ejemplo. Un análisis de regresión con muchas variables altamente correlacionadas - multicolineales
- Método adaptado a variables métricas (de razón o intervalo) aunque puede extenderse su uso (abuso?) a variables ordinales mediante considerarlas de intervalo

Análisis de Componentes Principales

Interpretación gráfica

Tenemos 12 observaciones de 2 variables (x1 y x2) representadas a continuación y deseamos reducirlas a una sola

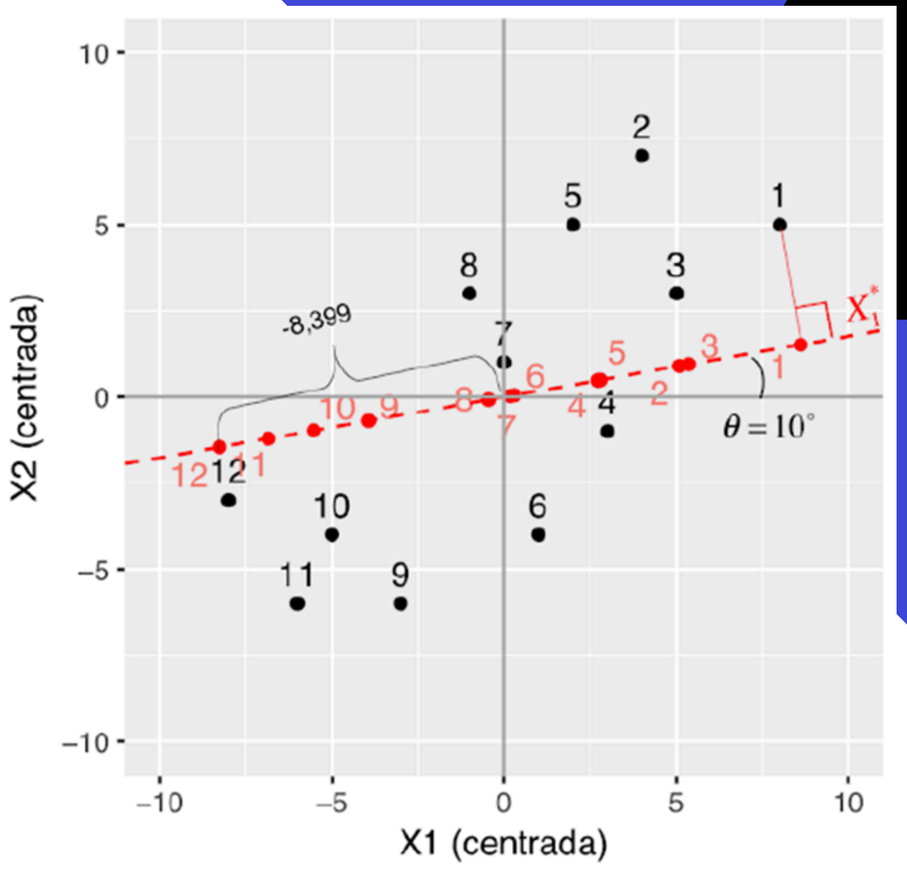
- Noten que las variables x1 y x2 representan ambas a una dimensión con interpretación clara (ventas, gasto en marketing, costos, consumo de energía, etc!)
- Cuando pretendemos reducir ambas a una sólo, no nos referimos a eliminar x1 o x2, si no a **crear una nueva dimensión** que resulte de la combinación de ambas!



Análisis de Componentes Principales

La dimensión ideal

- La linea en rojo representa esa nueva dimensión 'fantasma' que atraviesa el espacio de x1 y x2 (para un ángulo arbitrario de 10 grados)
- Pero ¿qué ángulo es el ideal?
- Aquel que permite atravesar el espacio de x1 y x2 tal que permita recoger la máxima variabilidad de ambas variables definida como la suma de varianzas de x1 y x2
- Se puede demostrar que esto occurre cuando la recta en rojo atraviesa la nube de puntos como lo haría una recta de regresión en este caso particular (ángulo de 43 grados aprox.)
- A esta nueva dimensión que extrae la máxima varianza de los datos se denomina **Componente principal**



Análisis de Componentes Principales

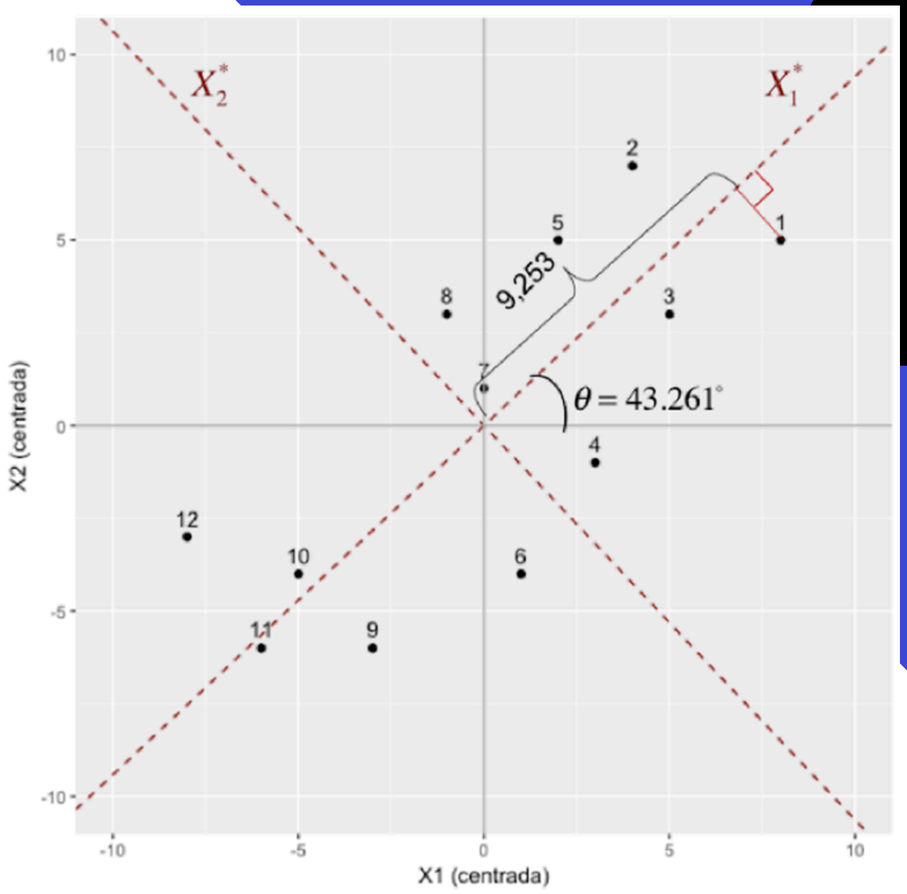
Tantas dimensiones como variables

En principio es posible extraer tantas dimensiones (componentes) como variables aunque esto no tiene utilidad práctica pues se trata de un método de reducción de dimensiones. - Para maximizar la extracción de información la segunda componente principal debe estar **no correlacionada** con la primera, es decir debe ser ortogonal (perpendicular) a las otras

- Los datos pueden ser representados en un nuevo plano cartesiano generado por las 2 nuevas dimensiones (componentes principales) X_1^* y X_2^*

Análisis de Componentes Principales

- Ambos ejes o componentes X_1^* y X_2^* se pueden representar como vectores. Especificamente autovectores de la matriz de correlaciones o de covarianzas.
- Asi como en el análisis de clústers se **recomienda** evaluar cada situación y utilizar las variables estandarizadas (z) de manera a compatibilizar las unidades de medida de las diferentes variables, en el PCA se recomienda entender X_1^* y X_2^* como autovectores de la **matriz de correlaciones** en lugar de utilizar **la matriz de varianzas** : La matriz de correlaciones es adimensional.
- La matriz de correlaciones es igual a la matriz de varianzas de las variables estandarizadas.



Análisis de Componentes Principales

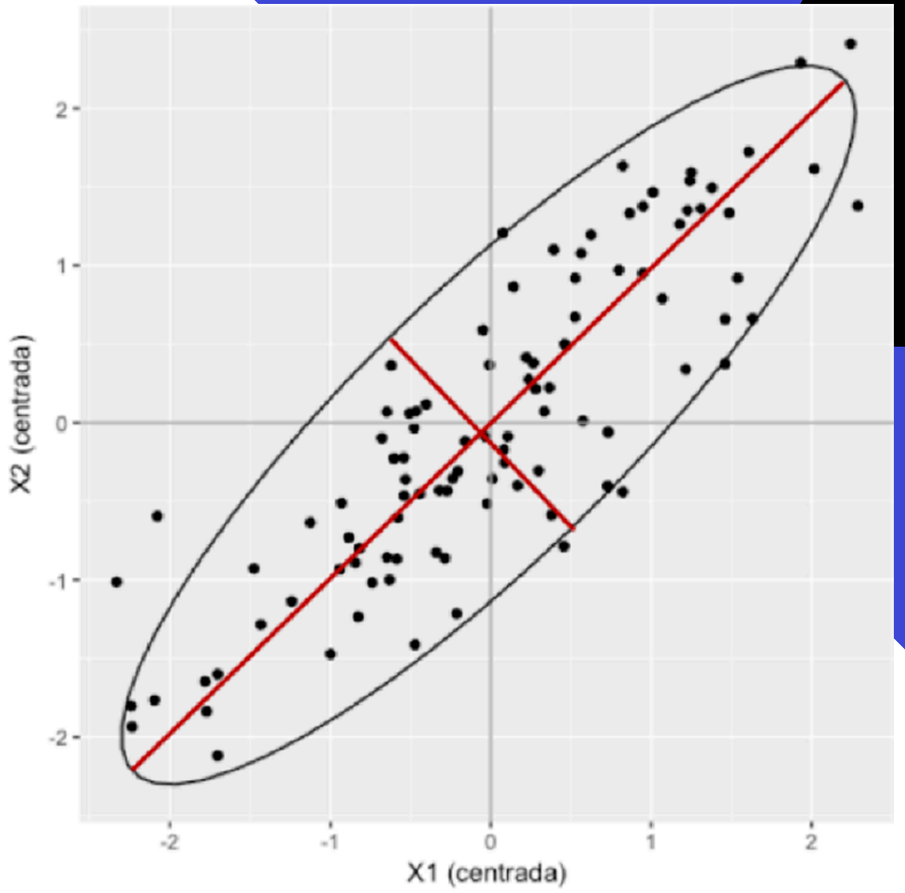
Utilizando la matriz de varianzas:

- La longitud de cada autovector se denomina **autovalor** y es igual a la varianza de cada **componente principal**
- Se cumple la siguiente identidad para la varianza total :

$$V(X_1) + V(X_2) \equiv A(X_1^*) + A(X_2^*)$$

Donde $A(X_i^*)$ representa el autovalor del i-ésimo componente principal o varianza de X_1^*

La identidad de varianzas-autovalores en este caso es :
$23.091 + 21.091 \equiv 38.576 + 5.606$



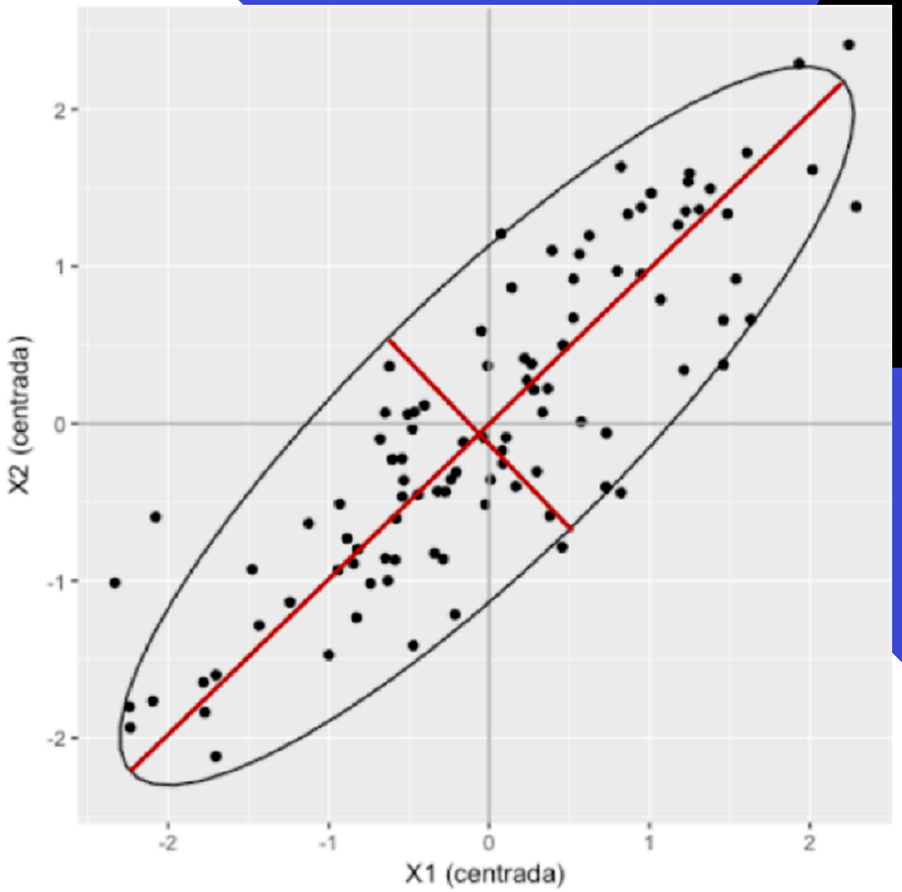
Análisis de Componentes Principales

Utilizando la matriz de correlaciones (recomendado):

- Esto es equivalente a estandarizar cada variable para eliminar las unidades de medida $(x - \bar{x})/\sigma_x$. Nota: la matriz de correlaciones es igual a la matriz de varianzas de las variables estandarizadas.
- Se cumple la siguiente identidad para la matriz de varianzas (estandarizadas) total :

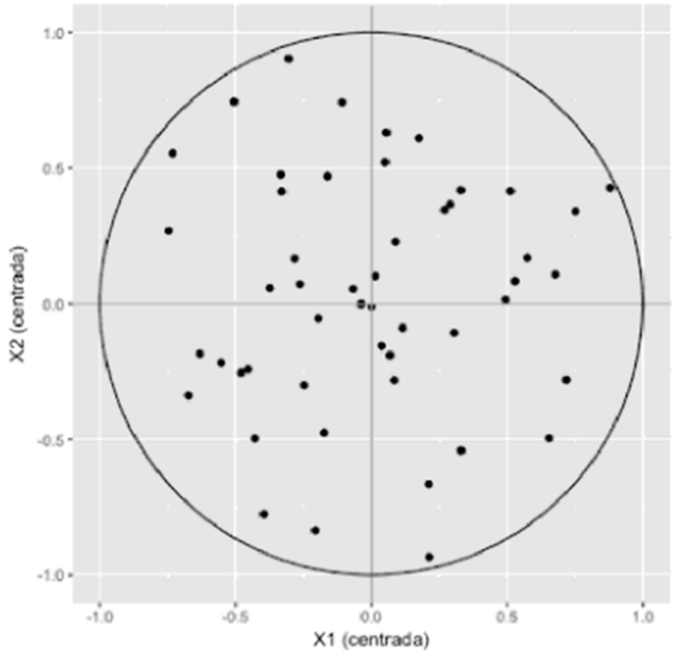
$$2 = 1_1 + 1_2 = A(X_1^*) + A(X_2^*)$$

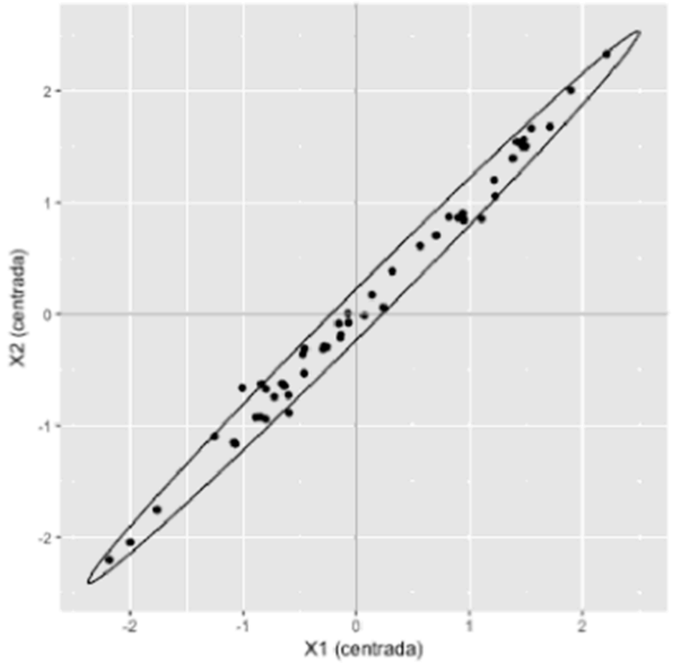
Donde $A(X_i^*)$ representa el autovalor del i-ésimo componente principal X_1^*. Si dividimos el lado derecho entre 2, tendremos las proporciones de la varianza explicada por cada componente.



Análisis de Componentes Principales

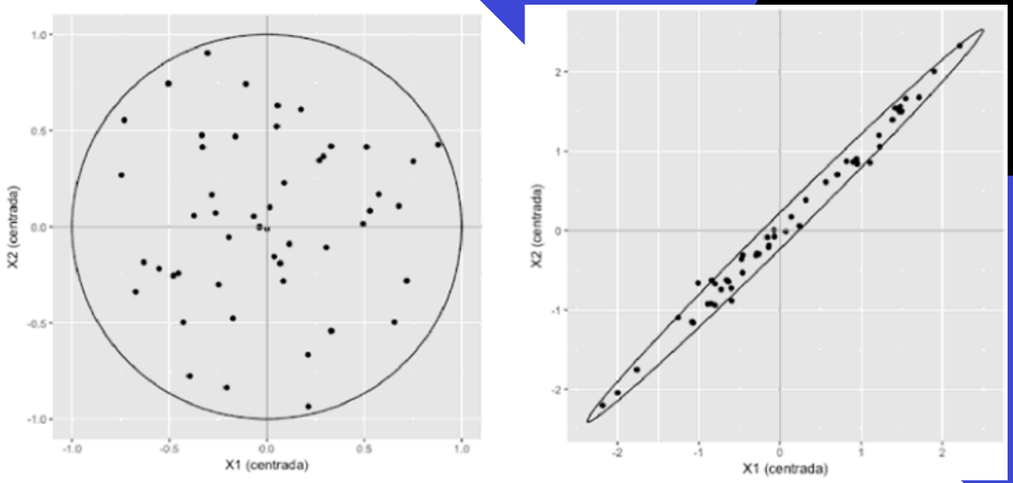
Observe ambas configuraciones de datos ¿Cuál es la correlación en cada una?¿alta, baja? ¿En cuál es mas sencillo identificar visualmente las dimensiones/componentes principales?





Análisis de Componentes Principales

- La gráfica derecha presenta una correlación alta entre sus variables. La nube de puntos hace sencillo identificar la componente más importante como una recta de 45 grados aproximadamente. Comparada a la 2da componente, la primera explica casi toda la nube de puntos i.e. el primer autovalor es claramente mayor al segundo.
- La gráfica izquierda presenta una correlación aparentemente nula y no hay una dirección en la que se pueda identificar una componente principal, menos una secundaria.
- Por tanto, la identificación de componentes requiere de correlaciones entre las variables. Si la matriz de correlaciones es la Matriz Identidad, el PCA es inviable.



Análisis de Componentes Principales

Identificación de componentes

- Para verificar la **no esfericidad** de los datos se implemente la **prueba de Bartlet** cuya hipótesis nula es que todas las correlaciones son 0 i.e. la matriz de correlaciones es la identidad.
- En el caso a 2 variables obviamente sólo es relevante reducir a una dimensión/componente, por tanto no hay elección mas que juzgar si la proporción de varianza extraída satisface al investigador (asumiendo que la prueba de Bartlet rechaza H_0)

Identificación de componentes con K-dimensiones

- Con una cantidad numerosa de variables (K) el investigador experto deseará retener un número de dimensiones que explique una proporción suficiente de la variabilidad de sus datos. **Suele ser el criterio más utilizado**

Identificación de componentes con K-dimensiones

Elección 'subjetiva'

- Alternativamente podría pretender retener un número **fijo** de dimensiones que le permitan implementar algún otro tipo de análisis e.g. Si se tienen 100 variables explicativas $(x_1, x_2, ..., x_{100})$ con $n = 20$ observaciones y se pretende correr una regresión lineal con las 100 (imposible) entonces podríamos reducir las 100 variables a 2 (3, 4, arbitrario) variables tal que el R2 ajustado de nuestro modelo sea satisfactorio:

$$y = \beta_0 + \beta_1 x_1^* + \beta_2 x_2^* + \varepsilon$$

- **Atención** la reducción de dimensiones implica pérdida de información y por tanto, menor poder explicativo (menor R2)

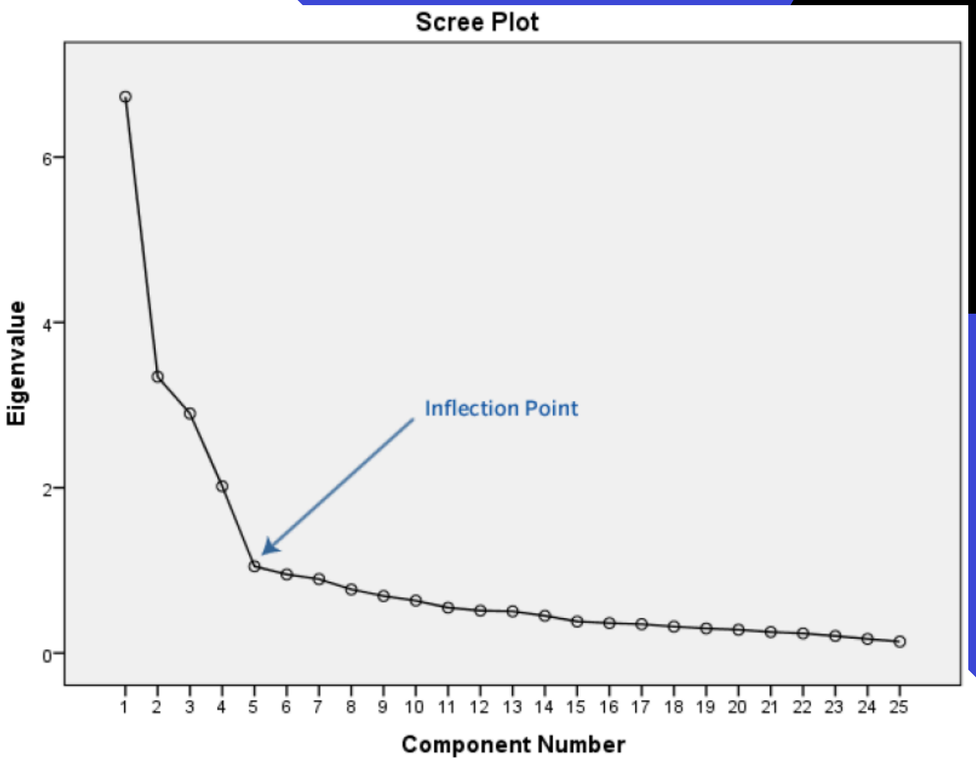
Identificación de componentes con K-dimensiones

Criterios 'objetivos'

- Seleccionar la menor cantidad de componentes principales - principio de parsimonía o de la navaja de Ockham...

tal que:

- La añadidura de nuevos componentes agregue súbitamente una menor cantidad de varianza explicada. Para ellos podemos graficar los autovalores en orden decreciente y descartar (gráfico de sedimentaciòn o scree plot) los últimos componentes que no agregan varianza explicativa como los primeros i.e. **criterio del punto de inflexión** (esto puede ser subjetivo al ser visual)



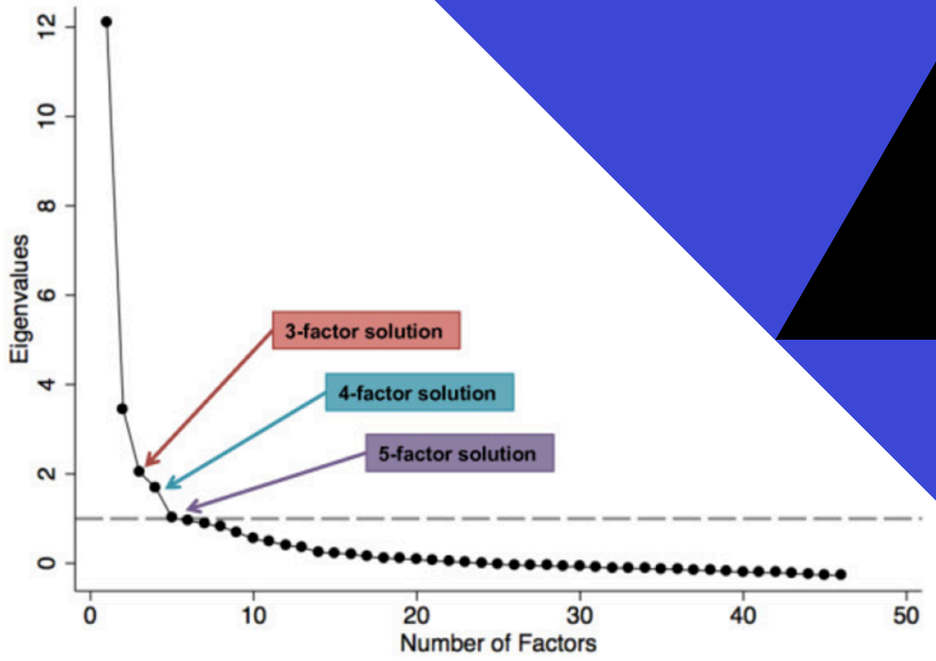
Identificación de componentes con K-dimensiones

Criterios 'objetivos'

- Alternativamente, seleccionar la menor cantidad de componentes principales tal que los elegidos tengan al menos un autovalor de 1 (cuando se utiliza el criterio de matriz de correlación). Generalizando la identidad de 2 variables a K variables:

$$k = \sum_{i}^{k} 1_i = A(X_i^*)$$

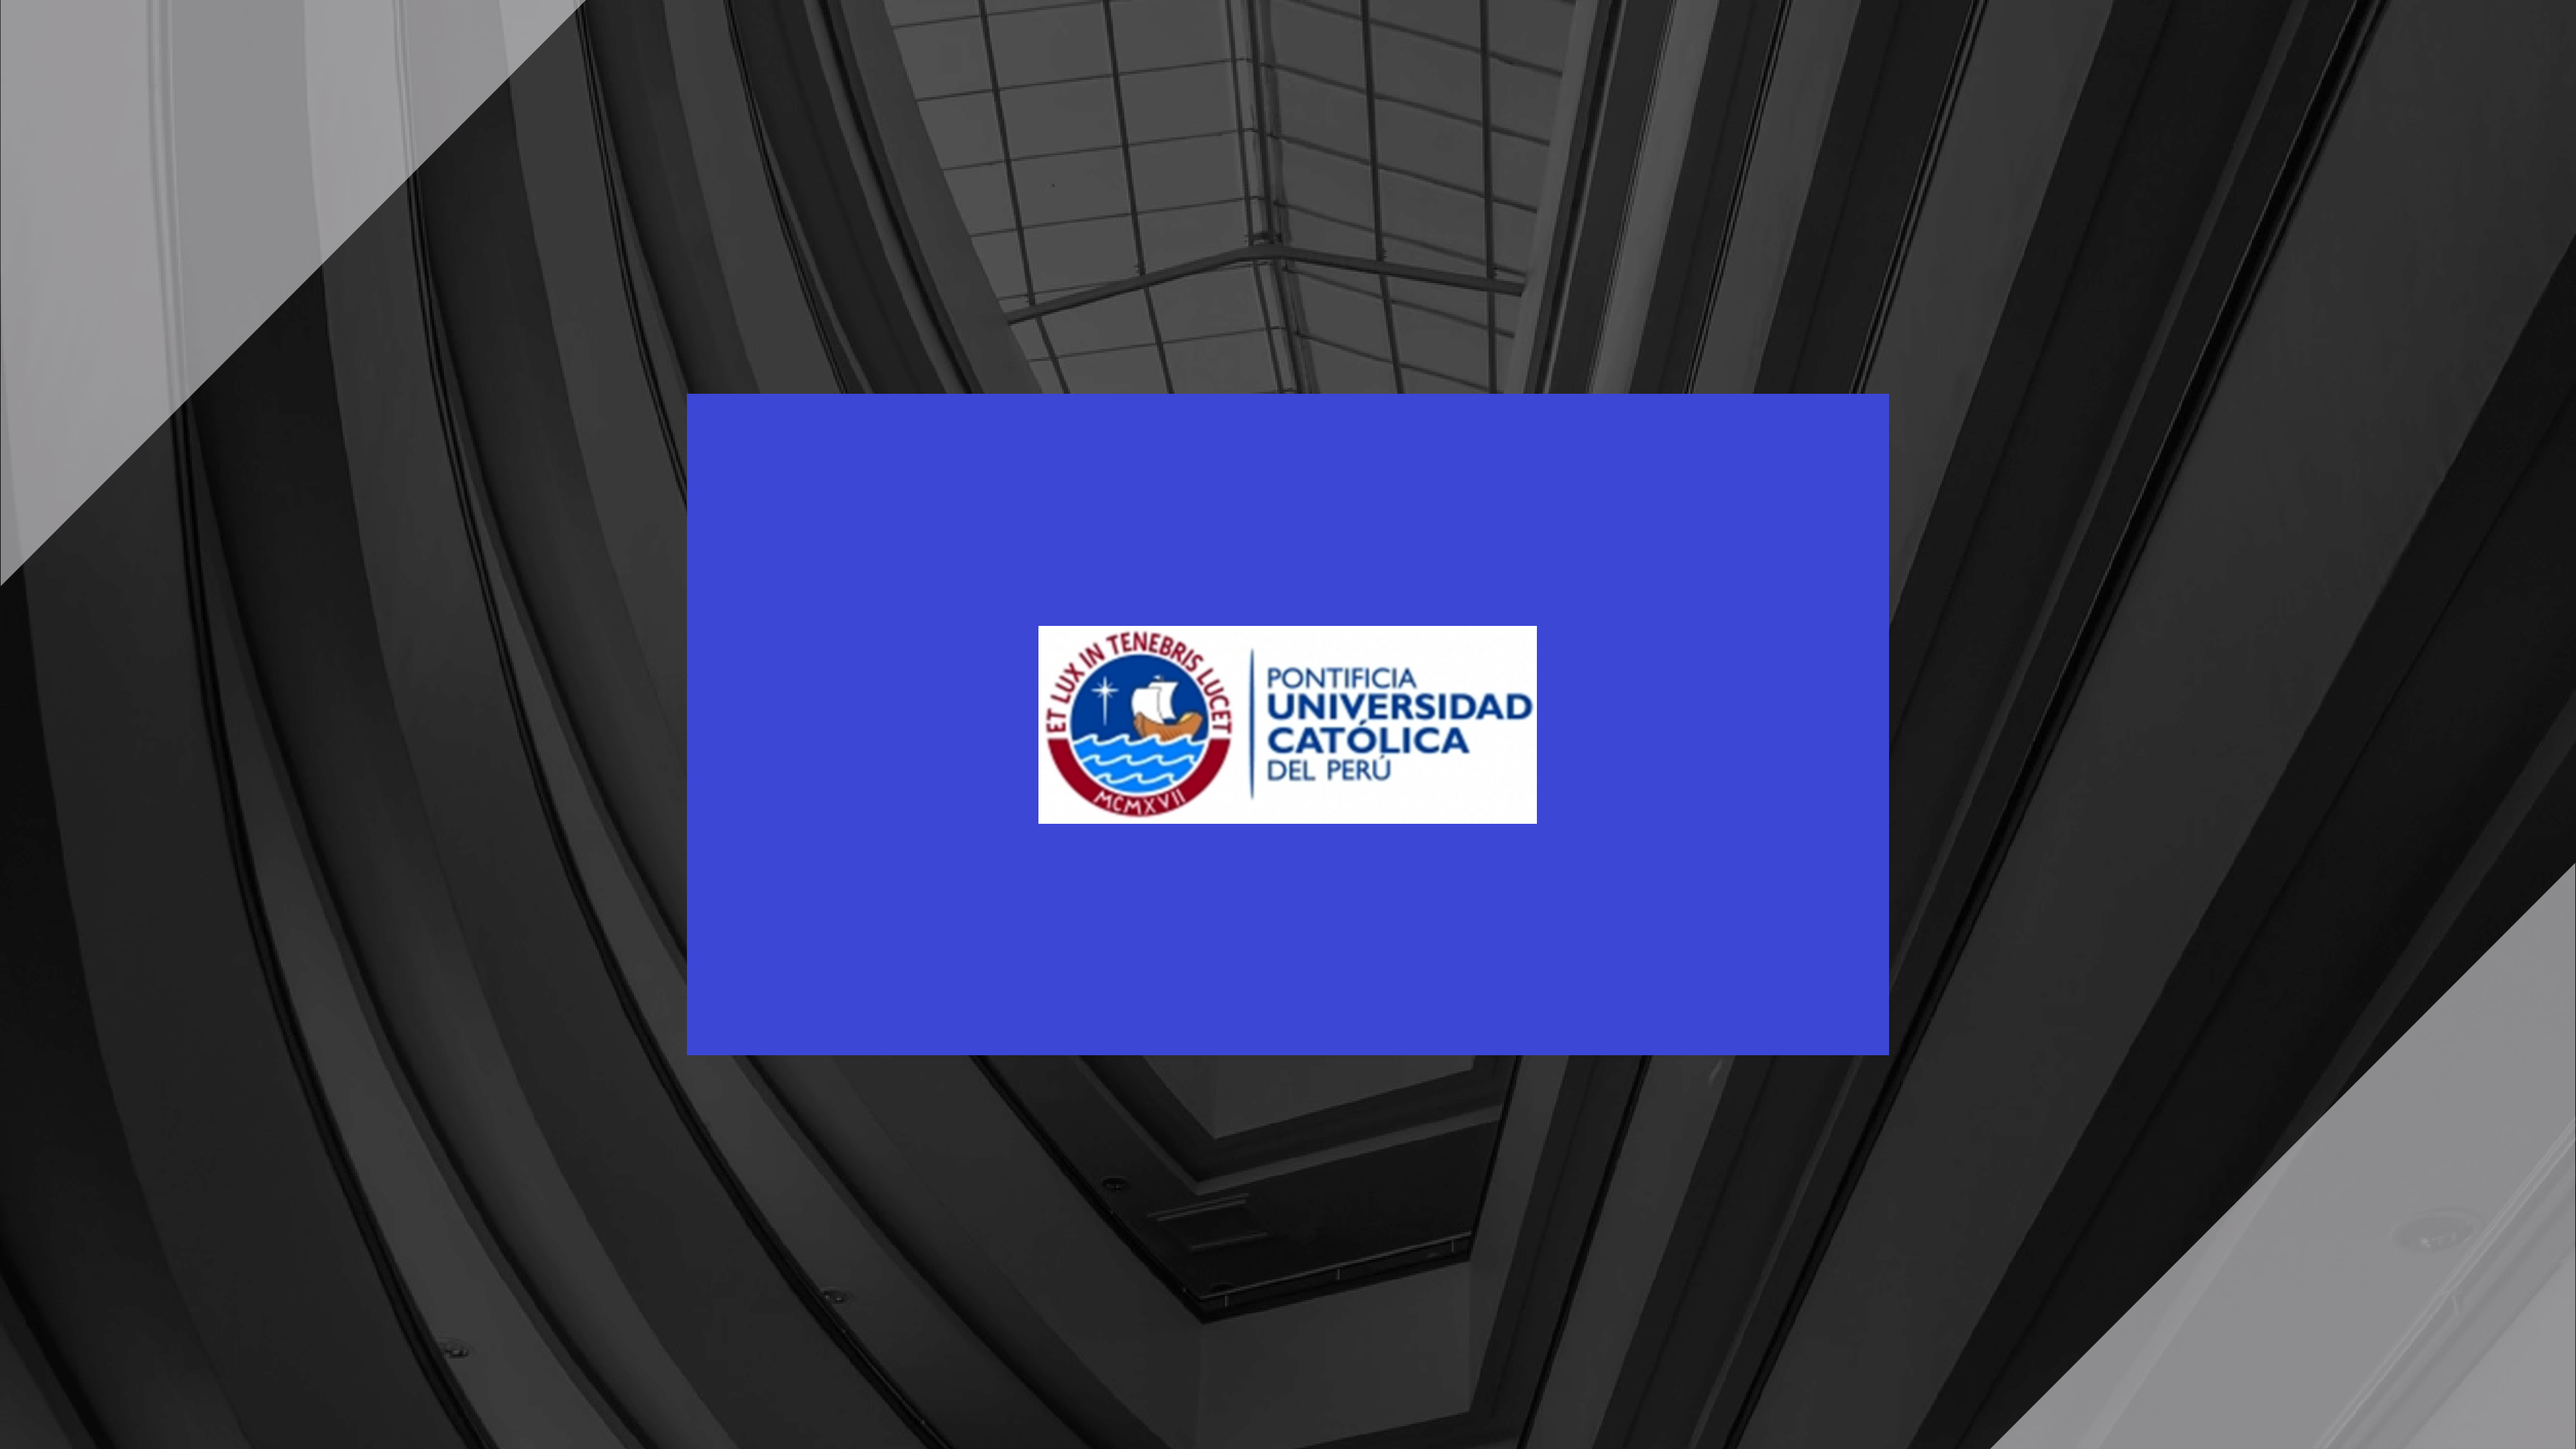
Aquellos componentes más representativos pueden ser aquellos cuyo autovalor es al menos superior al 'promedio' i.e. explican al menos una proporción $1/k$ de la varianza total. **En caso se dificulte la interpretación del scree plot, este es un criterio a utilizar.**



Se pueden calcular correlaciones para poder identificar qué variable da mayor significado a cada dimensión o componente. Esta matriz se denomina matriz de componentes o Matriz de cargas

OUT PUT

"ARCHIVO DE DATOS CON LAS “P" COMPONENTES PRINCIPALES IDENTIFICADAS"


ET LUX IN TENEBRIS LUCET
MCMXVII
PONTIFICIA
UNIVERSIDAD
CATÓLICA
DEL PERÚ