


# Análisis Factorial Exploratorio

PONTIFICIA UNIVERSIDAD CATÓLICA DEL PERÚ

# Análisis Factorial Exploratorio

## Variables NO OBSERVABLES o variables LATENTES en las ciencias sociales

- Las ciencias sociales se desenvuelven en contextos donde muchas de las variables de interés no son mesurables directamente.
- En psicología: Los diferentes sentimientos (miedo, pasión, amor, ira, ... y podriamos continuar )
- En marketing: Actitudes del consumidor (satisfacción, motivación a adquirir un producto, intención de compra, etc.)
- En negocios en general: Actitudes del emprendedor (Tendencia a la internacionalización, al emprendimiento social, etc.),...?

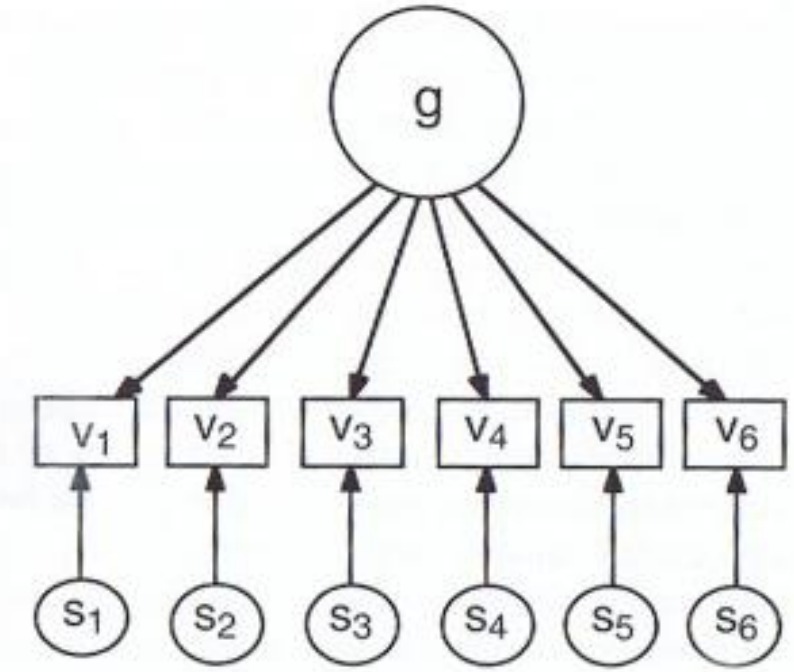





# Análisis Factorial Exploratorio

## Medición de la Inteligencia – Spearman (1904)

- Concibe a la inteligencia como una **dimensión** (Factor G) que no es observable directamente pero que subyace/atraviesa el espacio de otras dimensiones observables al investigador.
- A este tipo de dimensión subyacente se la denomina, **variable latente**, **constructo** o **factor** de ahí las denominaciones de análisis factorial, o análisis de variables latentes, etc. que
- El círculo central representa la variable latente (inteligencia general o Factor G)
- los cuadrados variables observadas (respuestas a un test de inteligencia)
- y los círculos pequeños los errores de medición de cada variable.



# Análisis Factorial Exploratorio

## Medición de la Inteligencia – Spearman (1904)

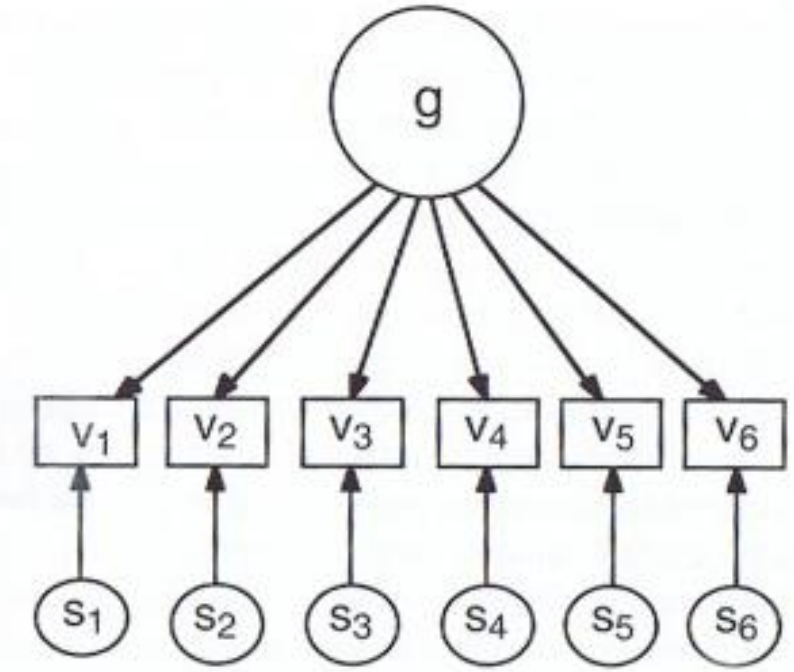
Matematicamente:

$$\begin{aligned} v_1 &= \lambda_1 g + s_1 \\ v_2 &= \lambda_2 g + s_2 \\ &\vdots \\ v_6 &= \lambda_6 g + s_6 \end{aligned}$$

En notación matricial:

$$v = \Lambda g + s$$

Donde $\Lambda$ es un vector columna con elementos $[\lambda_1\ \lambda_2 \ldots \lambda_6]$. Cada coeficiente $\lambda$ mide la fuerza de la relación entre las variables observadas y el constructo



# Análisis Factorial Exploratorio

En el Análisis Factorial Exploratorio (EFA) tenemos un conjunto de variables para las cuales **no sabemos** cuantos constructos subyacen a los datos.

EFA con $m$ variables latentes y $p$ variables observadas (p>m)

$$
\begin{aligned}
x_1 &= \lambda_{11}\xi_1 + \lambda_{12}\xi_2 \ldots + \lambda_{1m}\xi_m + \varepsilon_1 \\
x_2 &= \lambda_{21}\xi_1 + \lambda_{22}\xi_2 \ldots + \lambda_{2m}\xi_m + \varepsilon_2 \\
&\vdots \\
x_p &= \lambda_{p1}\xi_1 + \lambda_{p2}\xi_2 \ldots + \lambda_{pm}\xi_m + \varepsilon_p
\end{aligned}
$$

$$x = \Lambda\xi + \varepsilon$$

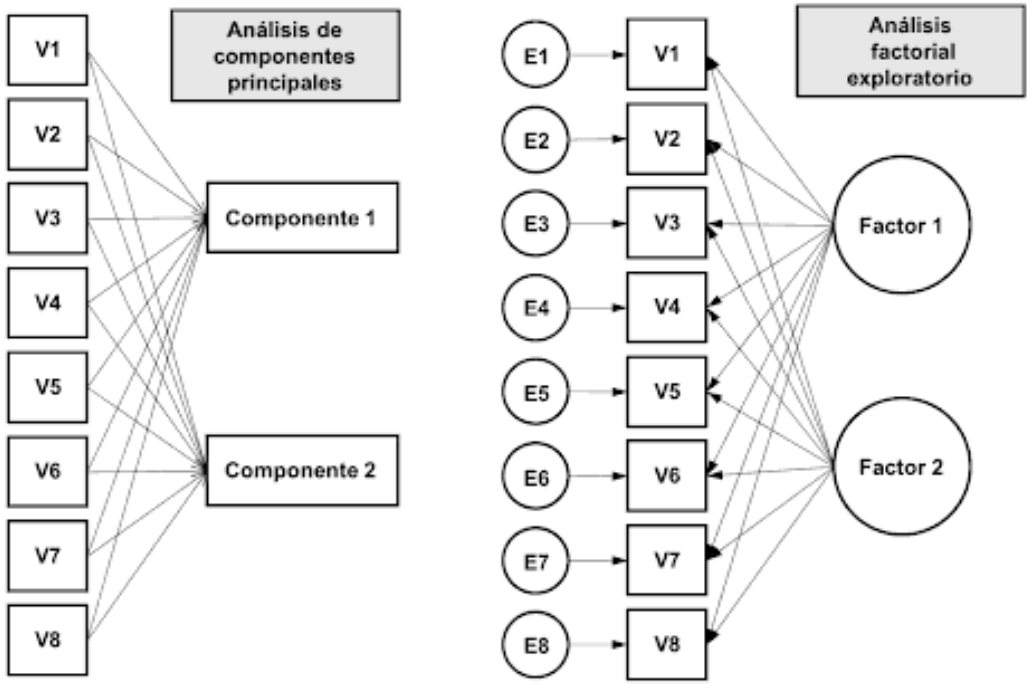
Donde $\xi$ es una letra griega que designa al vector de variables latentes (y se pronuncia 'ksi' )

# Análisis Factorial Exploratorio

## El sentido de las relaciones (flechas) y el error de medida

- En el PCA, los componentes son una función de las variables observadas. en el EFA, ocurre lo opuesto, las variables observadas son función de las variables latentes.

**Figura 12.1.:** Visión conceptual diferencial del PCA y del EFA



# Análisis Factorial Exploratorio

El dictamen... nunca quiere decir **nunca**

Puede seguirse a Osborne y Banjanovic (2016) para una aproximación al debate abierto sobre el uso de una u otra herramienta que ellos intentan sintetizar con la opinión de Widaman (1993, p. 263) "...[el] PCA nunca debería ser utilizado si un investigador quiere parámetros que reflejen variables latentes o factores" y concluyen que, aunque siga siendo la opción por defecto en muchos programas estadísticos para la reducción de datos, no es —en su opinión, remarcan— la opción conceptualmente más deseable y no tiene una ventaja clara que puedan destacar.

La explicación del empleo del PCA en EFA

Aunque luego entraremos en cuestiones de fondo, el PCA es una versión computacionalmente más sencilla del EFA. El EFA fue desarrollado previamente al PCA (Hotelling, 1933) gracias a los trabajos de Spearman (1904). Pero en esta época previa a los ordenadores, el planteamiento del EFA era demasiado exigente para los cálculos manuales que se realizaban y el PCA se generó como una alternativa menos costosa en términos de esfuerzo de cálculo (Gorsuch, 1990).

# Análisis Factorial Exploratorio

The real Milli Vanilli (The real EFA)



# The real EFA

Estructura

$$x = \Lambda\xi + \varepsilon$$

- el vector $\xi$ tiene media 0 y varianza 1. Los factores pueden estar correlacionadas entre si (a diferencia del PCA puro donde los componentes son ortogonales!). Sin embargo, en el planteamiento más elemental asumiremo que son incorrelacionados. Su matriz de varianzas es la identidad:

$$V(\xi) = I_m$$

- los errores de medida $\varepsilon$ tienen media 0, están incorrelacionados entre si y tienen varianza $\varepsilon_i^2$. Por tanto la matriz de varianzas es sólo diagonal: $V(\varepsilon) = \Psi$

# Análisis Factorial Exploratorio

## The real EFA

- Por simplicidad, asumamos que las $x$ estan **estandarizadas** (lo usual). Su matriz de covarianzas es igual a la de correlacion : $V(x) = R_p$ :

$$R_p = \Lambda \Lambda' + \Psi$$

**$R_p$ es conocido a partir de la muestra. Deseamos hallar $\Lambda$ y $\Psi$ para poder deducir $\xi$ !!!!**

$$\begin{bmatrix} 1 & \rho_{21} & \cdots & \rho_{p1} \\ \rho_{21} & 1 & \cdots & \rho_{p2} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{p1} & \rho_{p2} & \cdots & 1 \end{bmatrix} =$$

$$\begin{bmatrix} \lambda_{11} & \lambda_{12} & \cdots & \lambda_{1m} \\ \lambda_{21} & \lambda_{22} & \cdots & \lambda_{2m} \\ \vdots & \vdots & \vdots & \vdots \\ \lambda_{p1} & \lambda_{p2} & \cdots & \lambda_{pm} \end{bmatrix} \begin{bmatrix} \lambda_{11} & \lambda_{21} & \cdots & \lambda_{p1} \\ \lambda_{12} & \lambda_{22} & \cdots & \lambda_{p2} \\ \vdots & \vdots & \vdots & \vdots \\ \lambda_{1m} & \lambda_{2m} & \cdots & \lambda_{pm} \end{bmatrix} +$$

$$+ \begin{bmatrix} \varepsilon_1^2 & 0 & \cdots & 0 \\ 0 & \varepsilon_2^2 & \cdots & 0 \\ \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & \cdots & \varepsilon_p^2 \end{bmatrix}$$

# The real EFA - Identificabilidad

La relación anterior muestra valores conocidos del lado izquierdo (correlaciones entre items) y desconocidos del lado derecho (componentes de $\Lambda$ y $\Psi$). Tenemos por tanto un sistema de ecuaciones:

- **Número de ecuaciones**: Tantas como correlaciones $p(1+p)/2$
- **Número de incógnitas**: Tantas como elementos en $\Lambda$ y $\Psi$ i.e. $p \times m + p = p(1+m)$



Existe solución **exacta** al EFA sólo cuando $p(1+p)/2 = p(m+1)$ (modelo identificado)

# The real EFA - Identificabilidad

- Con menos ecuaciones que incógnitas se tiene una infinidad de soluciones $p(1+p)/2 < p(m+1)$ es **imposible** encontrar solo una solución (modelo no identificado)
- Con más ecuaciones que incógnitas $p(1+p)/2 > p(m+1)$ podríamos escoger la solución que **aproxime** a cero al conjunto de ecuaciones i.e. **hay esperanza** (modelo sobreidentificado)

# Análisis Factorial Exploratorio

## EFA – via PCA (fake Milli Vanilli)

- Elegir el camino fácil i.e. PCA : $R_p = V\,LV' = \Lambda\,\Lambda' + \psi$ , por tanto

$$\Lambda = V\sqrt{L}$$

Donde $L$ representa a la matriz diagonal con los autovalores de la matrix R, mientras que $V$ representa a sus autovectores

## EFA – via Máxima Verosimilitud (Real Milli Vanilli)

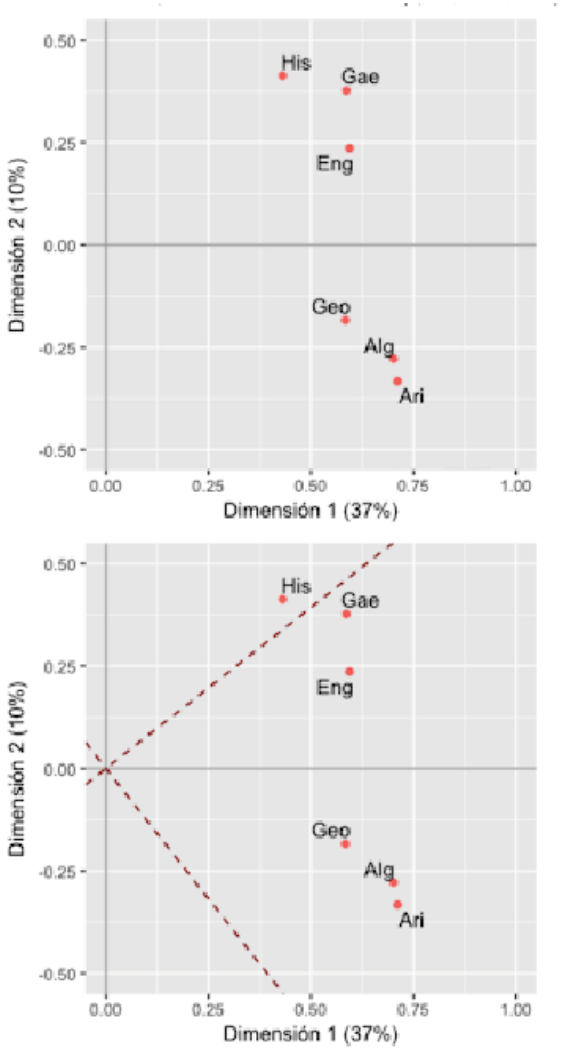
- Integrar al EFA el hecho de que $\varepsilon$, al ser un error de medida, debe seguir una distribución de probabilidad i.e. enfoque paramétrico del EFA, pero sigue siendo un EFA real !

# Análisis Factorial Exploratorio

## Factores / Constructos rotados

- En un EFA y en ausencia de teoría, todo los constructos latentes pueden relacionarse con todas las variables observadas.
- Podemos alterar ligeramente las dimensiones latentes i.e. rotar ligeramente estos ejes abstractos, para que se correlacionen cada uno con un sub-grupo de variables $x$ en lugar de con todas:

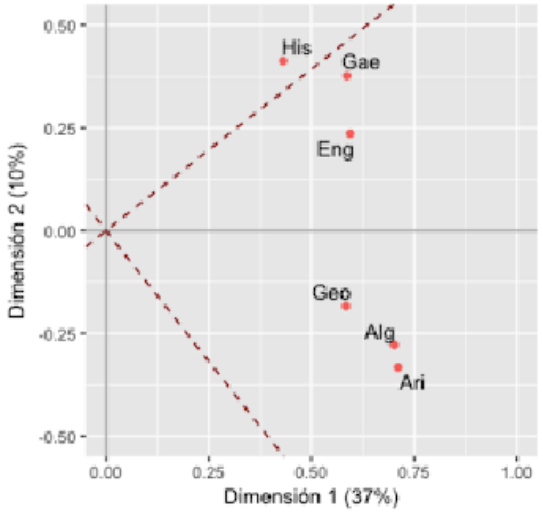
# Análisis Factorial Exploratorio

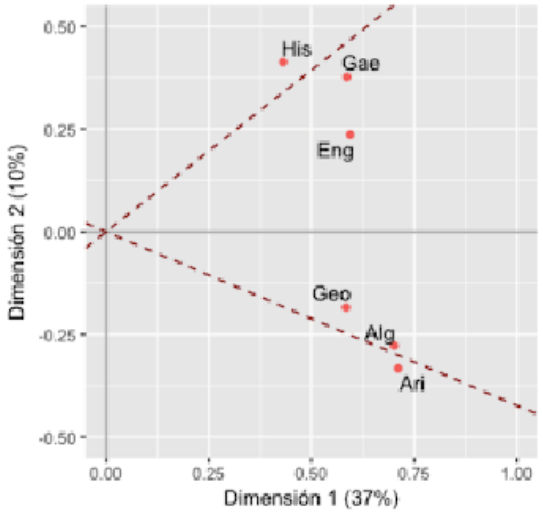



## Factores / Constructos rotados

- Rotación ortogonal (Varimax): Mantiene la ausencia de correlación entre constructos pero los rota de manera a que cada uno se correlacione mejor con algún subgrupo de variables $x$
- Las cargas ($\Lambda$) o correlaciones de cada constructo con cada variable x, deben ajustarse en consecuencia

# Análisis Factorial Exploratorio




## Factores / Constructos rotados

- Rotación Oblicua (Oblimin): No preserva la ortogonalidad de los constructos pero permite una mejor asociación de cada constructo con subgrupos especificos de variables.
- Las cargas ($\Lambda$) deben ajustarse en consecuencia.

# Análisis Factorial Exploratorio

## Número de Factores a retener

Al igual que en el PCA, podemos basarnos en criterios :

- Gráfico de sedimentación (scree plot) criterio de punto de inflexión
- Número de 'factores' cuyo autovalor sea mayor a 1.

Al igual que en el PCA, superar la prueba de Bartlet es esencial para pretender identificar $\Lambda$ y los factores (constructos)

# Análisis Factorial Exploratorio

## Calidad de ajuste de los datos al supuesto de ortogonalidad de factores

- Adicionalmente implementaremos la medida de adecuación Keyser-Meyer y Olkin (KMO). Permite estimar el porcentaje de la varianza de las variables que pueden explicarse por los factores. Valores menores a 0.5 indican que el EFA no permite identificar ni el 50% de la varianza (variabilidad) total de los datos (items)
- Es recomendable evaluar la matriz de correlaciones anti-imagen para verificar si es necesario descartar alguna variable y mejorar la calidad de ajuste.
- Si un modelo factorial es adecuado la mayoría de los elementos no diagonales de la matriz de correlaciones deben ser pequeños.

# Análisis Factorial Exploratorio

## Calidad de ajuste de los datos al supuesto de ortogonalidad de factores

- Con esta matriz se construye una medida de adecuación muestral (MSA) para cada variable. Esta medida es similar a la medida KMO, pero para cada variable individualmente considerada, por lo que también deben tener un valor próximo a 1.

| | |
|---|---|
| $\geq 0{,}9$ | marvelous |
| $[0{,}8; 0{,}9)$ | meritorious |
| $[0{,}7; 0{,}8)$ | middling |
| $[0{,}6; 0{,}7)$ | mediocre |
| $[0{,}5; 0{,}6)$ | miserable |
| $< 0{,}5$ | unacceptable |

# EFA - Comunalidades

Una vez estimada la matriz de cargas $\Lambda$ podemos interpretar el sistema original a partir de las comunalidades y cargas:

$$
\begin{aligned}
x_1 &= \lambda_{11}\xi_1 + \lambda_{12}\xi_2 \ldots + \lambda_{1m}\xi_m + \varepsilon_1 \\
x_2 &= \lambda_{21}\xi_1 + \lambda_{22}\xi_2 \ldots + \lambda_{2m}\xi_m + \varepsilon_2 \\
&\vdots \\
x_p &= \lambda_{p1}\xi_1 + \lambda_{p2}\xi_2 \ldots + \lambda_{pm}\xi_m + \varepsilon_p
\end{aligned}
$$

# EFA - Comunalidades

La comunalidad de la variable j $h_j^2$ es el % de la varianza que los factores explican de $x_j$, i.e.

$$h_j^2 = \sum_i^m \lambda_{ji}^2$$

Donde cada $\lambda_{ji}$ es la carga factorial o correlación entre la variable $x_j$ y el factor $i$

# Análisis Factorial Exploratorio

## Pasos a seguir en el EFA

# Análisis Factorial Exploratorio

## Paso 1: Verificar la adecuación muestral

- No existe un criterio único para establecer el **tamaño de muestra** con relación al número de variables. Todo depende del número de factores a extraer, de la fuerza de su relación con las variables observables y del tamaño de muestra.
- Sin embargo, se puede decir que una matriz de correlaciones debería tener valores no bajos (mayores a 0.30?) para poder extraer algunos factores comunes.
- Objetivamente, deseamos un criterio de KMO $> 0.5$ y rechazar $H_0$ en la prueba de esfericidad de Bartlett.
- También es aconsejable verificar que los coeficientes de adecuación muestral para cada variable sean cercanos a uno (algunos autores proponen un punto de corte de 0.4 o 0.5)

# Análisis Factorial Exploratorio

## Paso 2: Extracción de factores

- **PCA** (fake EFA). A evitar! solo con fines de replicación de otros estudios o para implementar un PCA
- **Máxima Verosimilitud-MV** (EFA). Método que garantiza la mayor precisión en la estimación bajo la hipótesis de normalidad
- **Mínimos cuadrados-MC** (EFA). No impone normalidad, por tanto se puede utilizar en cualquier situación. Las estimaciones pierden precisión.

Se recomienda utiliza MV por defecto y en caso de duda verificar los resultados con MC.

# Análisis Factorial Exploratorio

## Paso 3: Criterios para elegir el número de factores

La extracción de factores requiere de el empleo de múltiples criterios.

3.1. El criterio de autovalor >1; de extracción de un % mínimo de la varianza (50?) y gráfico de sedimentación son referenciales

3.2. Condición necesaria (grados de libertad): $p(1+p)/2 \geq p(m+1)$ i.e. $p \geq 2\,(m+1) - 1$

$p$ es el número de variables (o items) y $m$ el de factores

```
m = c(1:5)
p = 2 * (m + 1) - 1
rbind(m, p)
```

```
##   [,1] [,2] [,3] [,4] [,5]
## m    1    2    3    4    5
## p    3    5    7    9   11
```

- Si se desea un sólo factor 1, se necesitan al menos 3 variables; si 2, entonces al menos 5, etc.

# Análisis Factorial Exploratorio

## Paso 3: Criterios para elegir el número de factores

- Introduzca el número de variables en esta fórmula, para tener un **límite superior** de factores a **explorar** : $m \leq (p+1)/2 - 1$

```
p = c(3:10)
m_rounded = round((p + 1)/2 - 1.1, 0)
rbind(p, m_rounded)
```

```
##           [,1] [,2] [,3] [,4] [,5] [,6] [,7] [,8]
## p            3    4    5    6    7    8    9   10
## m_rounded    1    1    2    2    3    3    4    4
```

3.3. Si utilizan otro software (R, Lisrel, Mplus, etc.), se recomienda el análisis paralelo. Produce un criterio de autovalor mínimo que supera el criterio de autovalor unitario.

3.4. Finalmente, **la teoría** detrás de la definición de las variables **suele** brindar información acerca del número de dimensiones a considerar

# Análisis Factorial Exploratorio

## Paso 4: Rotación

El analista/investigador debe plantear si los factores a identificar pueden o no estar correlacionados. Esto depende de la naturaleza de los constructos a identificar. Típicamente en un EFA basado en datos originales (inéditos) y sin marco teórico, el analista/investigador no tiene muchos elementos a-priori para imponer o no esta restricción.

Se recomienda por tanto alternar entre ambas rotaciones, ortogonal (varimax) y oblicua (oblimin) para encontrar aquella que de resulte en la mayor interpretabilidad de los factores

# Análisis Factorial Exploratorio

## Paso 4: Rotación

- En oblimin. La matriz patrón provee las cargas factoriales ($\lambda$), mientras que la de estructura provee las correlaciones entre cada factor y variable.
- Para evaluar la agrupación de factores se utiliza la matriz patrón

¿Cómo visualizar la agrupación de variables en factores? En SPSS : opciones/suprimir coeficientes con valor absoluto menor a ...10%, 30$, 50%, etc.

- Atribuir una variable a un sólo factor en función de su carga factorial e interpretación

# Análisis Factorial Exploratorio

## Paso 5: Etiquetado: Conceptualización de factores

- Una vez agrupadas las variables en factores, debemos etiquetar cada factor. Las variables asociadas deben asistirnos a definir una etiqueta o un concepto general para cada factor.

## Paso 6: Puntuaciones Factoriales

- Una vez alcanzada la solución factorial final, suele ser de interés obtener una estimación de las puntuaciones de los individuos en cada uno de los factores resultantes de la extracción a fin de valorar la situación relativa de cada sujeto en esas "variables latentes" que resumen la información contenida en las variables observadas.


ET LUX IN TENEBRIS LUCET
PONTIFICIA
UNIVERSIDAD
CATÓLICA
DEL PERÚ