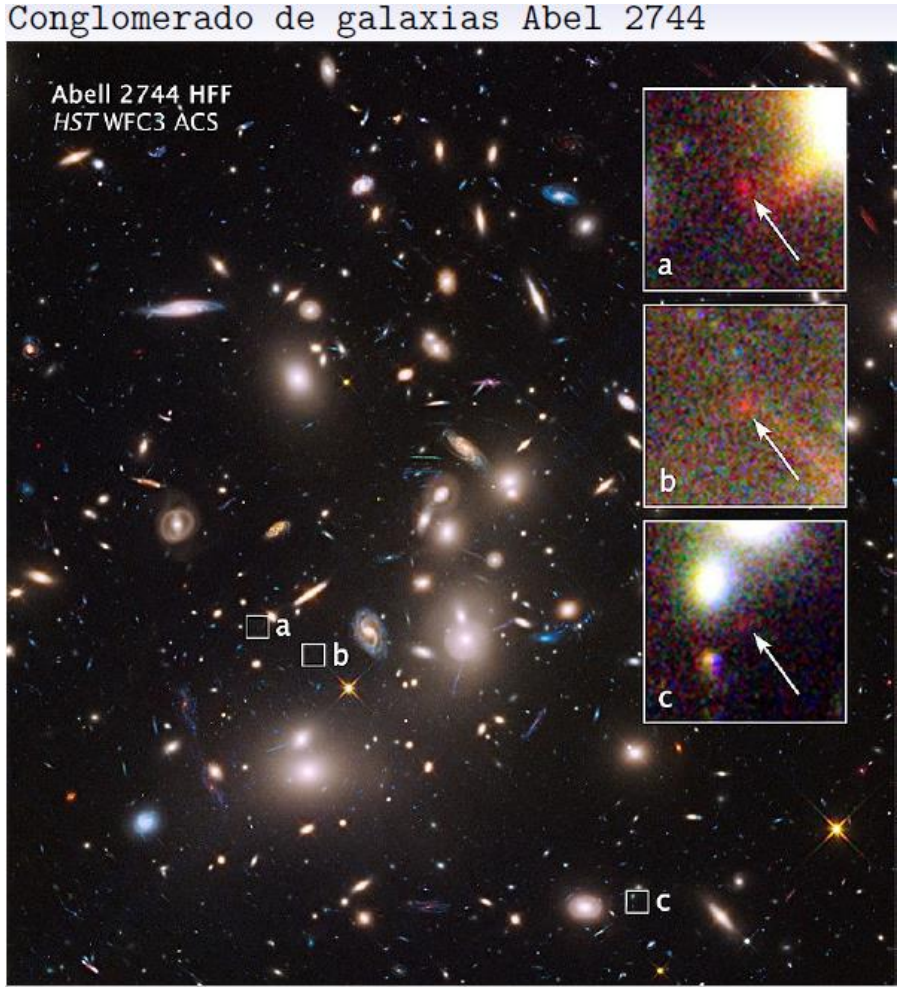


Análisis de Conglomerados

PONTIFICIA UNIVERSIDAD CATÓLICA DEL PERÚ

Análisis de Conglomerados



Principio general

Las diferentes observaciones de una fuente de datos (estrellas, fauna, consumidores) son agrupadas de acuerdo a su proximidad en conglomerados o **clusters**. La proximidad puede ser espacial o no.

- **Cúmulos de Estrellas:** se identifican cúmulos de estrellas en función de su distancia con respecto a un punto central común en el espacio
- Las estrellas pueden agruparse fácilmente en cúmulos denominados **galaxias** En este caso la proximidad espacial se explica por la presencia de un agujero negro en el centroide.
- **Conglomerados de fauna** un tipo particular (especie) de fauna puede encontrarse concentrado en algunas regiones debido al habitat favorable común.

Análisis de Conglomerados

- El objetivo es combinar individuos u observaciones en grupos de modo que cada grupo sea homogéneo y distinto a los demás grupos.
- Se suele utilizar los nombres de clasificación no supervisada o segmentación.

Para determinar la distancia entre observaciones se utiliza una medida de disimilaridad

Euclideana	Manhattan	Gower
Minkowski	Canberra	Chebychev

Análisis de Conglomerados

DISTANCIAS

- Euclideana: $d(x,y) = \sqrt{\sum_{i=1}^{M}(y_i - x_i)^2}$
- Minkowski: $d(x,y) = \left[\sum_{i=1}^{M}(y_i - x_i)^p\right]^{\frac{1}{p}}$
- Manhattan: $d(x,y) = \sum_{i=1}^{M}|y_i - x_i|$
- Canberra: $d(x,y) = \sum_{i=1}^{M}\frac{|x_i - y_i|}{|x_i + y_i|}$
- Chebychev: $d(x,y) = \max_{1\leq i\leq}|x_i - y_i|$
- Gower: $d(x,y) = \sum_{i=1}^{M} w_i\,|y_i - x_i|$

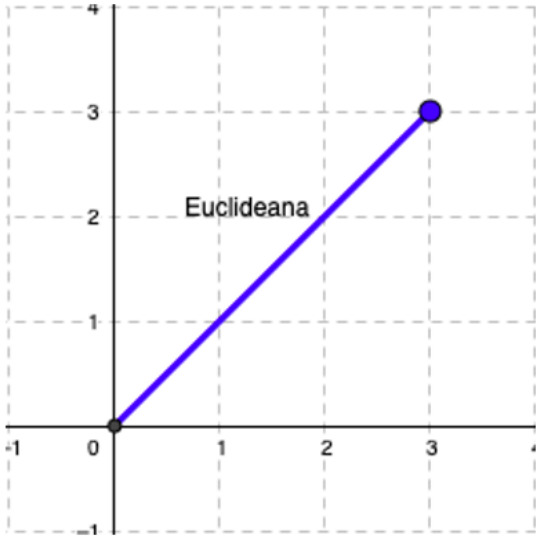
donde, si el i-ésimo atributo es nominal $|y_i - x_i| = 0$ cuando ambos valores son iguales, $|y_i - x_i| = 1$ si son distintos y $w_i = \frac{1}{M}$. Si el i-ésimo atributo es continuo entonces $w_i = \frac{1}{M \times \text{rango}(i - \text{ésimo atributo})}$

DISTANCIAS

Distancia Euclidiana

Sean X(i) y X(j) dos instancias con M dimensiones:

$$D(i,j) = \sqrt{(X_{i1} - X_{j1})^2 + (X_{i2} - X_{j2})^2 + ... + (X_{im} - X_{jm})^2}$$

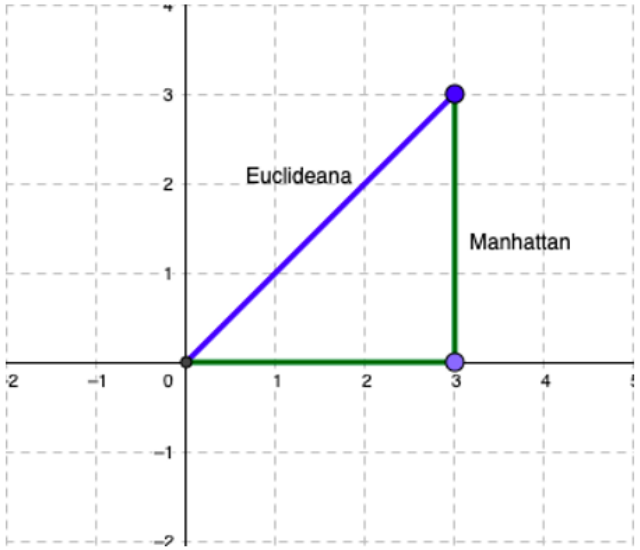


DISTANCIAS

Distancia Manhattan

Sean X(i) y X(j) dos instancias con M dimensiones:

$$D(i,j) = |X_{i1} - X_{j1}| + |X_{i2} - X_{j2}| + \ldots + |X_{im} - X_{jm}|$$



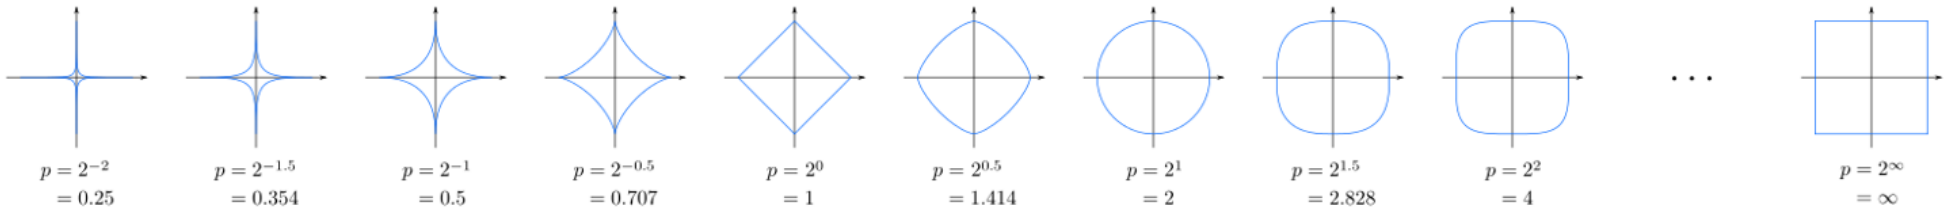
Análisis de Conglomerados

DISTANCIAS

Distancia Minkowski

Sean X(i) y X(j) dos instancias con M dimensiones, para un parámetro p, se define la distancia Minkowski como:

$$D(i,j) = \sqrt[p]{\left|X_{i1} - X_{j1}\right|^p + \left|X_{i2} - X_{j2}\right|^p + ... + \left|X_{im} - X_{jm}\right|^p}$$



Análisis de Conglomerados

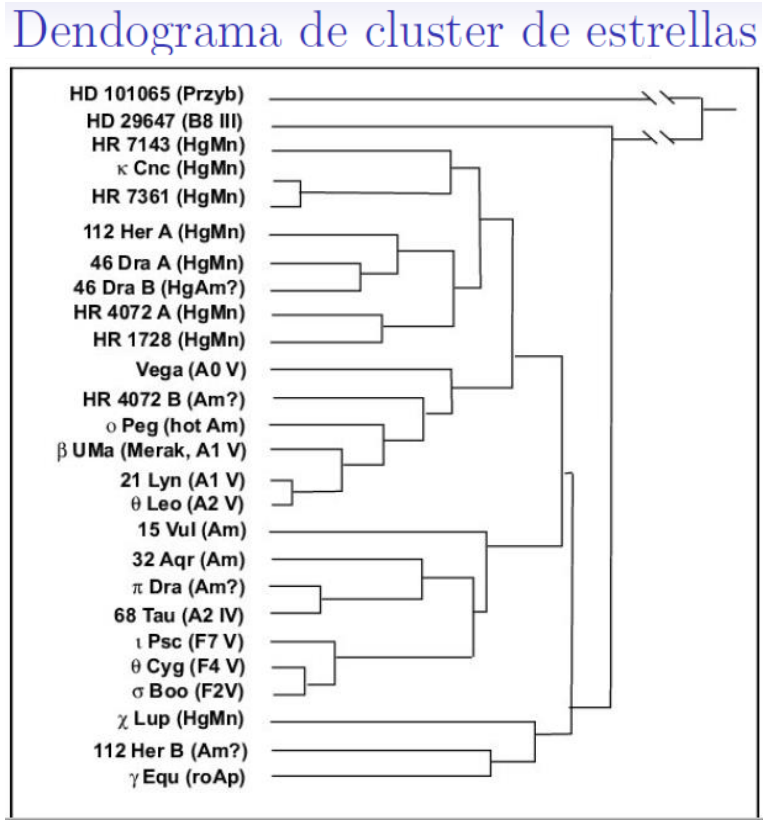
- Métodos Jerárquicos
- Métodos de agrupación (o No Jerárquicos)

Análisis de Conglomerados – Jerárquicos

Métodos Jerárquicos

- En estos algoritmos se generan sucesiones ordenadas (jerarquías) de conglomerados. Puede ser juntando conglomerados pequeños en mas grandes o dividiendo grandes conglomerados en otros mas pequeños.
- La estructura jerárquica es representada en forma de un árbol y es llamada Dendograma.
- Se dividen en dos tipos:
  - Algoritmos jerárquicos aglomerativos. Inicialmente cada observación es un conglomerados.
  - Algoritmos jerárquicos divisivos. Inicialmente todas las observaciones están en un solo conglomerado.

Análisis de Conglomerados – Jerárquicos

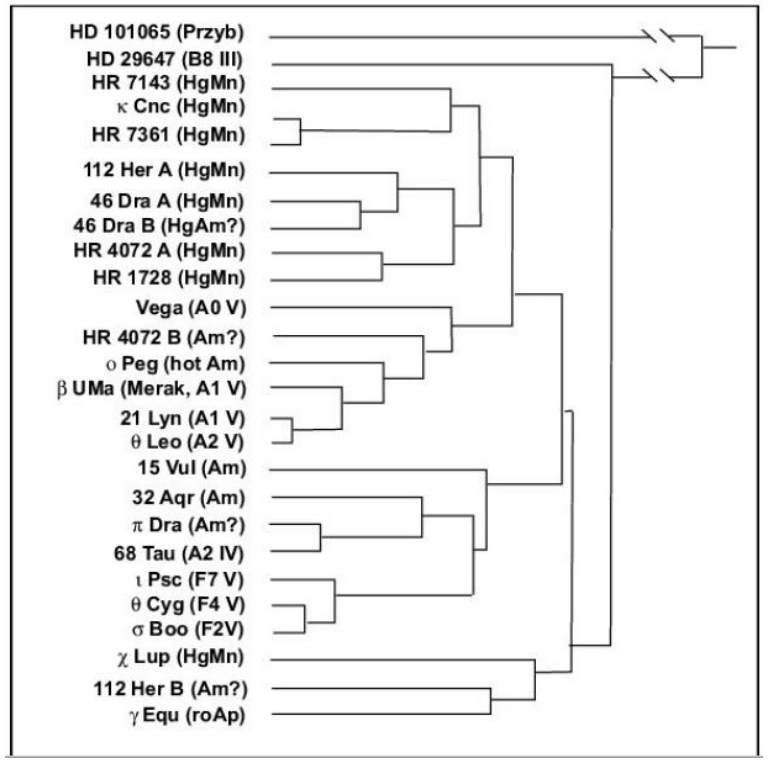


Dendograma

Es una representación gráfica (diagrama de árbol) que representa el orden de agrupación de los **pares de objetos**. En un extremo (el inicial) se tienen los objetos **originales** sin agrupar. En el otro se muestra la agrupación de todos a partir de dos subgrupos. Entre el extremo inicial y final, se representan las ramas de agrupación por pares que se suceden hasta agrupar todos los objetos.

Análisis de Conglomerados – Jerárquicos

Dendograma de cluster de estrellas



Dendograma

1. Calcular las distancias entre los distintos objetos (matriz de distancias)
2. Considerar a cada objeto como un cluster en si mismo
3. Agregar los 2 objetos más próximos y considerar este par como **un solo objeto** (este objeto tendrá como observaciones los promedios de los objetos fusionados)
4. Repetir el paso 3 con los nuevos objetos
5. Detenerse cuando se hayan agrupado **todos** los objetos

Las agrupaciones se representan en un árbol denominado **dendograma**. En uno de sus ejes se coloca el paso del algoritmo o el valor de la distancia que provocó la aglomeración.

Elección del número de clusters

- La elección del número de clusters (conglomerados) es subjetiva a no ser que se utilicen métodos estadísticos como el análisis de clases latentes (latent class analysis) o de clusters bayesianos
- Se debe tener un criterio externo para el número de clusters, dado por el contexto, la literatura, los objetivos del análisis, etc.

Análisis de Conglomerados – Jerárquicos

Elección del número de clusters

- En algunos casos las bases de datos no serán de gran tamaño y los investigadores pueden desear utilizar la técnica para hacer análisis estadísticos al interior de cada grupo. Esto implica que el número de clústers deber ser tal que se tengan suficientes observaciones al interior de cada uno.
- En otros casos el número de clusters estará dado por la literatura y el investigador tratará simplemente de identificar qué observaciones se clasifican en cada cluster e.g. la mayor parte de las investigaciones de mercados distinguen entre 3 a 10 niveles de consumidores socio-económicos.

Análisis de Conglomerados – Jerárquicos

Contextos No-Espaciales y Elección del tipo de distancia

- Estos métodos se han aplicado para clasificar observaciones en todas las ciencias sociales (psicologia, ciencias económicas y de la administración, etc.)
- El principal reto es la naturaleza no espacial de las características. Ejemplo: Deseamos agrupar empresas de acuerdo a su **tamaño**, donde el tamaño se puede entender tanto por la magnitud de los activos como por la cantidad de trabajadores. Imaginen que las empresas tienen un promedio de 5 millones de soles en activos y 50 trabajadores. Resulta obvio que la distancia euclideana daría mucho peso a los activos dada su escala.

Análisis de Conglomerados – Jerárquicos

Contextos No-Espaciales y Elección del tipo de distancia

Estandarización

- En este caso particular en el que ambas variables son totalmente incompatibles, resultaría apropiado transformar ambas variables a un score z (estandarizado) que cancele las unidades de medida y centre ambas en 0 :

$$z = \frac{x_i - \bar{x}}{\sigma_x}$$

Métodos Jerárquicos

- Suponiendo que tenemos datos de n individuos.
- Se empieza con n conglomerados.
- En cada paso se juntan los conglomerados más cercanos usando una medida de distancia entre conglomerados (linkage).

Sea $d(x, y)$ la distancia entre la observación x y la observación y. La distancia entre los conglomerados S y T puede ser calculada como:

- Linkage Simple: $\delta(S, T) = \min_{\{x \in S, y \in T\}} d(x, y)$
- Linkage Completo: $\delta(S, T) = \max_{\{x \in S, y \in T\}} d(x, y)$

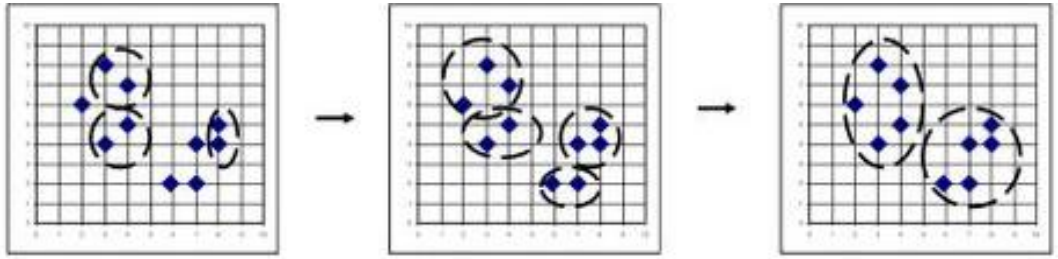
Métodos Jerárquicos

- Linkage Promedio: $\delta(S,T) = \frac{1}{|S||T|} \sum_{\{x \in S, y \in T\}} d(x,y)$
- Linkage Centroide: $\delta(S,T) = d(\bar{x},\bar{y})$
  Donde $\bar{x}$ y $\bar{y}$ representan los centroides de S y T respectivamente.
- Linkage Mediana: $\delta(S,T) = \text{mediana}_{\{x \in S, y \in T\}} d(x,y)$
- Linkage de Ward: $\delta(S,T) = \sum_{x \in S} d(x,\bar{x})^2 + \sum_{y \in Y} d(y,\bar{y})^2$ **Método de Ward**

  Se juntan el par conglomerados que produzcan la varianza más pequeña en el nuevo grupo.

Análisis de Conglomerados – Jerárquicos

AGNES (Agglomerative Nesting)



- El coeficiente de aglomeración permite medir la estructura de conglomerados de un conjunto de datos.
- Para cada observación i, denotemos por $m(i)$ la disimilaridad con el primer cluster con el cual fue unida, dividida por la disimilaridad de la última unión. Por lo tanto $0 \leq m(i) \leq 1$.
- El coeficiente de aglomeración se define como

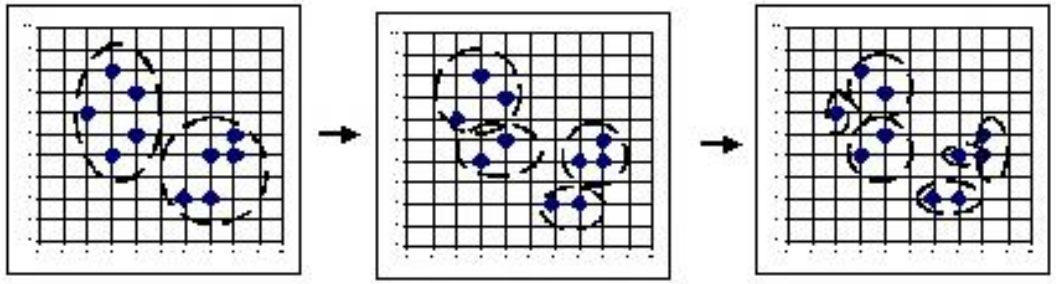
$$AC = \frac{1}{n}\sum_{i=1}^{n}(1 - m(i))$$

AGNES (Agglomerative Nesting)

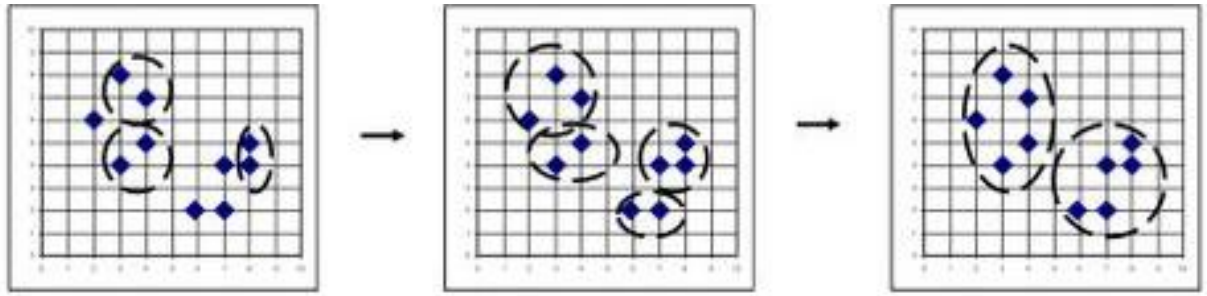
- Cuando el conjunto de datos posee una clara estrucutra de conglomerados, se espera que las disimilaridades entre conglomerados sean mucho más grandes que las disimilaridades dentro de los conglomerados. Por lo tando, se espera que los valores de $m(i)$ sean bajos lo que hace que el valor de AC se acerque a su valor máximo 1.
- Se sabe que el coeficiente de aglomeración tiende a tener valores grandes a medida que el valor de n se incrementa, por lo tanto no debe ser usado para comparar conjutos de datos de diferentes tamaños.

Análisis de Conglomerados – Jerárquicos

DIANA (Divisive Analysis)



AGNES (Agglomerative Nesting)

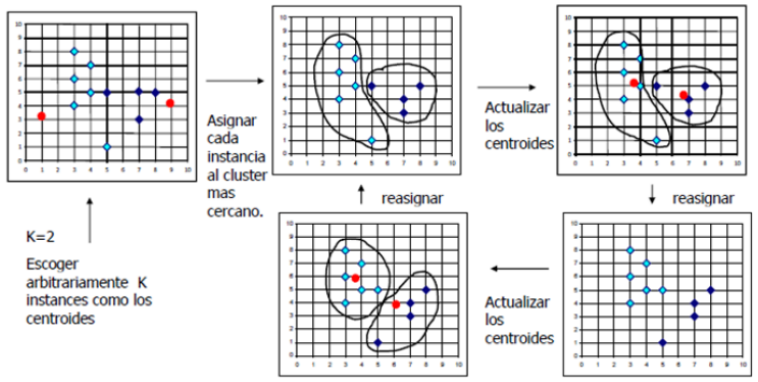


Métodos No Jerárquicos

- El conjunto de datos es particionado en un número de conglomerados k previamente especificado.
- Luego, iterativamente se va reasignando las observaciones a los conglomerados hasta que algún criterio de parada (función a optimizar) se satisface (suma de cuadrados dentro de los conglomerados sea la más pequeña).

Análisis de Conglomerados – No Jerárquicos

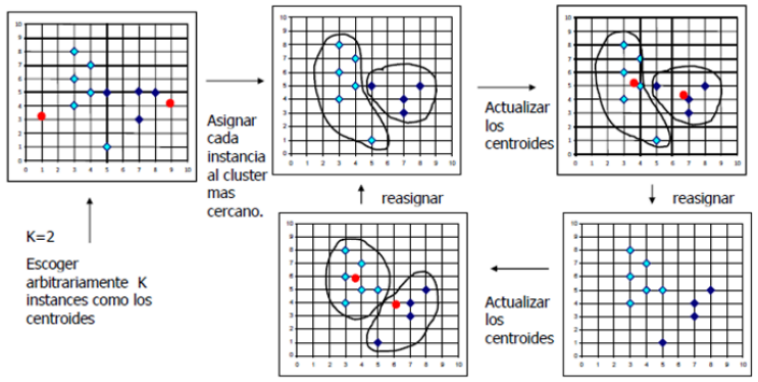
K-medias



- Se debe especificar el número k de conglomerados a ser encontrados.
- El objetivo es minimizar la disimilaridad de los elementos dentro de cada conglomerado y maximizar la disimilaridad de los elementos que caen en diferentes conglomerados.
- No se satisface el criterio de optimización globalmente, solo produce un óptimo local.
- El algoritmo de K-medias es computacionalmente rápido.
- Es sensible a la elección de los centroides iniciales.
- Es sensible a .ºutliers".

Análisis de Conglomerados – No Jerárquicos

K-medias

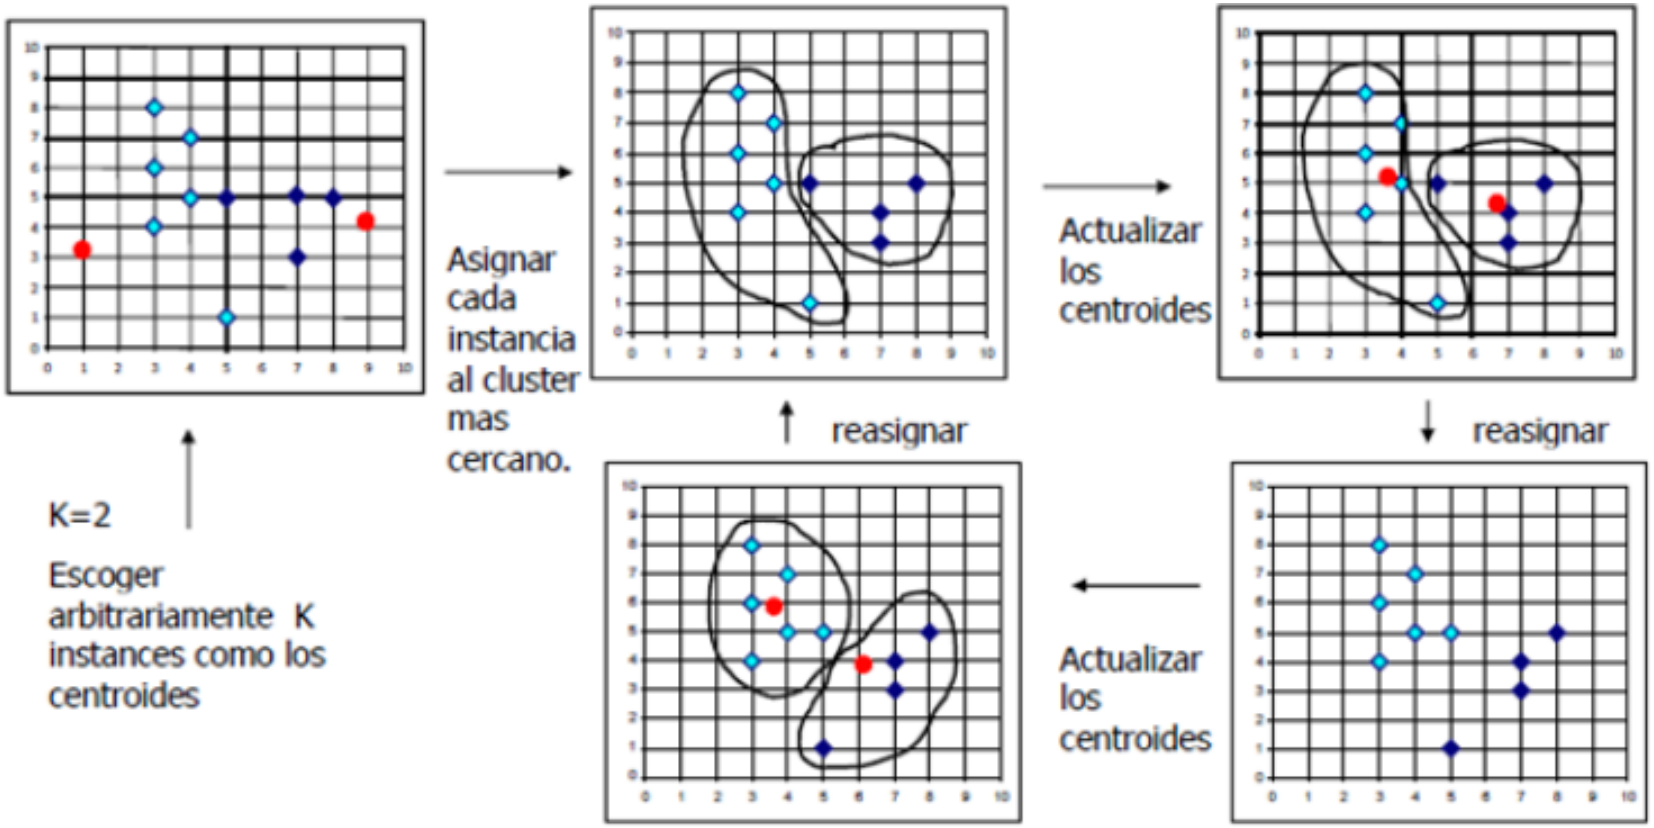


1. Seleccionar los centroides iniciales de los k conglomerados: $c_1, c_2, ..., c_n$.
2. Asignar cada observación x_i al conglomerado C_i cuyo centroide c_i este más cerca de x_i.
3. Para cada uno de los conglomerados se recalcula su centroide basado en los elementos contenidos en el conglomerado.
4. Ir al paso 2 hasta que se consiga convergencia.

El centroide en este caso es calculado como el vector de medias

Análisis de Conglomerados – No Jerárquicos

K-medias



Silueta

- El ancho de la silueta de la i-ésima observación es definida por:

$$sil_i = \frac{b_i - a_i}{max(a_i, b_i)}$$

- Donde, a_i denota la distancia promedio entre la observación i y todas las otras que están en el mismo conglomerado de i, y b_i denota la distancia promedio minima de i a las observaciones que están en otros conglomerados.
- El valor de la silhouette varia entre -1 y $+1$.
- La medida de silueta será dada por $\bar{s} = \frac{1}{n} \sum_{i=1}^{n} sil_i$

PAM (Partitioning Around Medoids)

- El algoritmo de Particionamiento alrededor de medioides (PAM) se basa en buscar k observaciones representativas entre todas las observaciones del conjunto de datos.
- Estas observaciones son denominadas de medioides.
- Una vez encontrados los medioides se construyen los k conglomerados asignando cada observación al medioide más cercano

PAM (Partitioning Around Medoids)

- El algoritmo PAM (Partitioning Around Medoids) tiene como objetivo encontrar medioides de modo que la disimilaridad total de todos las observaciones con respecto a su medioide más cercano sea mínima.
- Esto es, el obetivo es encontrar $\{m_1, ..., m_k\} \subset \{1, ..., n\}$ que minimice la función objetivo

$$\sum_{i=1}^{n} \min_{t=1,...,k} d(i, m_t)$$

PAM (Partitioning Around Medoids)

- Luego, cada objeto es asignado al congolomerado correspondiente al medioide más cercano.
- Esto es la observación i es incluida en el conglomerado v_i cuando el medioide m_{v_i} es el más cercano a i que cualquier otro medioide m_w, esto es

$$d(i, m_{v_i}) \leq d(i, m_w) \forall w = 1, ..., k$$

PAM (Partitioning Around Medoids)

El algoritmo PAM considera dos pasos:

1. BUILD

   Contruir los k medoides iniciales
   - m_1 es la observación con la menor $\sum_{i=1}^{n} d(i, m_1)$
   - m_2 minimiza la función objetivo lo más posible

     $\vdots$
   - m_k minimiza la función objetivo lo más posible

2. SWAP

   Considera todos los pares de objetos (i, j) donde

   $$i \in \{m_1, ..., m_k\} \text{ y } j \notin \{m_1, ..., m_k\}$$

   y se intercambia $i \leftrightarrow j$ que disminuya la función objetivo lo más posible.

CLARA (Clustering Large Applications)

- El algoritmo PAM necesita construir la matriz de dismilaridades completa, por lo que para conjuntos de datos grandes se puede volver impráctico.
- Para evitar este problema se propuso el algoritmo CLARA (Clustering Large Applications) que no considera la matriz de dismilaridades completa.

CLARA (Clustering Large Applications)

El algoritmo CLARA considera los siguientes pasos:

1. Repetir s veces
   - Extraer una muestra de tamaño r
   - Aplicar PAM para encontrar los medioides $\{m_1, ..., m_k\}$
   - Calcular la función objetivo $\sum_{i=1}^{n} \min_{t=1,...,k} d(i, m_t)$
   - Guardar $\{m_1, ..., m_k\}$ si la función objetivo $<$ actual mejor valor obtenido de la función obejtivo
2. Asignar las n observaciones a los $\{m_1, ..., m_k\}$ medioides genera la partición final.

FANNY (Fuzzy Analysis)

- Los algoritmos PAM y CLARA asignan cada observación a único conglomerado. Por ejemplo, un observación que este exactamente entre dos conglomerados será asignada solamente a uno de ellos.
- in embargo, con el método fuzzy divide cada objeto entre los conglomerados. Esta idea está implementada en el algoritmo FANNY (Fuzzy Analysis).

FANNY (Fuzzy Analysis)

- Para cada observación i y cada cluster v existirá un valor u_{iv} que indicará que tan fuertemente el objeto i pertenece al conglomerado v, estos valores deben cumplir
  - $u_{iv} \geq 0 \; \forall i = 1, ..., n$ y $\forall v = 1, ..., k$
  - $\sum_{v=1}^{k} u_{iv} = 1, \; \forall i = 1, ..., n$

FANNY (Fuzzy Analysis)

- Luego, los valores u_{iv} serán estimados por la minimización de la función objetivo

$$\sum_{v=1}^{k} \frac{\sum_{i,j=1}^{n} u_{jv}^2 u_{iv}^2 d(ij)}{2 \sum_{j=1}^{n} u_{jv}^2}$$

- En esta expresión las disimilaridades $d(i,j)$ son conocidas y los u_{iv} son desconocidos.
- La minimización es llevada a cabo a través de un algoritmo iterativo, tomando en cuenta las restricciones mediante el uso de multiplicadores de Lagrange.

Análisis de Conglomerados – No Jerárquicos

FANNY (Fuzzy Analysis)

- Cuando cada observación tiene la misma pertenencia a todos los conglomerados, estos es todos son $1/k$, se dice que el analisis de conglomerados es difuso completamente.
- Por otro lado si cada observación pertenece solamente a un conglomerado, se dice que el analisis de conglomerados es una partición.

FANNY (Fuzzy Analysis)

- Para medir este comportamiento se usa el indice de Dunn dado por

$$F_k = \sum_{i=1}^{n} \sum_{v=1}^{k} u_{iv}^2 / n$$

que toma su valor mínimo $1/k$ si la solución es completamente difusa y su valor máximo 1 si tenemos una partición.

- Se suele utilizar su versión normalizada

$$F_k' = \frac{kF_k - 1}{k - 1}$$

que toma valores entre 0 y 1.


ET LUX IN TENEBRIS LUCET
PONTIFICIA
UNIVERSIDAD
CATÓLICA
DEL PERÚ