Laboratorio Dirigido 2

Caso: Plataforma de cómputo en la nube

Como continuación del análisis realizado (Laboratorio Dirigido 1), la empresa desea profundizar en el entendimiento y la calidad de los datos registrados sobre los trabajos de procesamiento ejecutados en su plataforma.

Para ello, se dispone del archivo `1INF03_PD2_datos.csv`, que contiene 200 registros extraídos del sistema. Cada fila corresponde al registro de un trabajo de procesamiento y la variable `job_id` debería identificar de manera única a cada trabajo.

La base contiene información sobre el cliente, tipo de plan contratado, duración del trabajo, uso de CPU y memoria, costo interno, importe facturado, estado de ejecución y número de intentos.

Los datos han sido extraídos directamente del sistema y aún no han pasado por un proceso de limpieza. A partir de esta información, se realizará una exploración inicial de los datos y se identificarán posibles problemas de calidad que deban ser tratados antes de continuar con el análisis.

1. Exploración inicial de los datos

Abra un notebook en Google Colab y cargue el archivo `1INF03_PD2_datos.csv`. Luego responda:

a) Utilizando `pandas`, indique cuántas filas y columnas contiene la base de datos.

b) Muestre las primeras cinco observaciones de la base.

c) Clasifique las variables de la base según su naturaleza.

d) Identifique el tipo de dato de Python asociado a cada variable.

2. Medidas de tendencia central y posición

A partir de la variable `duracion_min`:

a) Calcule la media y mediana.

b) Compare la media y la mediana. ¿Qué observa?

c) Calcule el valor mínimo y máximo.

d) Calcule el primer cuartil (Q_1), segundo cuartil (Q_2) y tercer cuartil (Q_3).

e) Construya e interprete un boxplot para esta variable.

3. Medidas de variabilidad

A partir de la variable `duracion_min`:

a) Calcule el rango intercuartílico (IQR).

b) Calcule la varianza, la desviación estándar y el coeficiente de variación.

c) Compare los coeficientes de variación de todas las variables cuantitativas para las cuales sea posible realizar el cálculo e interprete las diferencias observadas.

4. Asimetría y curtosis

A partir de la variable `duracion_min`:

a) Calcule el coeficiente de asimetría.

b) Interprete el resultado obtenido e indique si la distribución presenta asimetría positiva, negativa o es aproximadamente simétrica.

c) Calcule el coeficiente de curtosis utilizando la definición presentada en clase.

d) Interprete el resultado obtenido e indique si la distribución es leptocúrtica, mesocúrtica o platicúrtica.

5. Datos duplicados y vacíos

A partir de la base de datos original:

a) Identifique si existen registros duplicados completos. Indique cuáles son.

b) Considerando que `job_id` debería identificar de manera única a cada trabajo, identifique los posibles registros duplicados parciales.

c) Identifique las variables que presentan datos vacíos y determine cómo están representados en la base.

d) Convierta los datos vacíos identificados a `NaN` para facilitar su posterior tratamiento.

6. Datos atípicos

A partir de la variable `duracion_min`:

a) Calcule los límites inferior y superior para la detección de valores atípicos utilizando el criterio del rango intercuartílico (IQR).

b) Identifique los valores que se encuentran fuera de los límites calculados.

c) Proponga una alternativa para tratar los valores atípicos identificados y justifique brevemente su elección.

d) Aplique el tratamiento propuesto en el inciso c) a los valores atípicos identificados en la variable `duracion_min`. De ser necesario, guarde en un archivo `.pkl` los parámetros o valores calculados que se hayan utilizado para realizar esta etapa de la limpieza de datos.

7. Datos faltantes

Para cada una de las siguientes situaciones, indique si el mecanismo de datos faltantes corresponde a MCAR, MAR o MNAR. Justifique brevemente su respuesta y proponga una posible forma de tratamiento.

a) Debido a una falla temporal y aleatoria del sistema de registro, se perdió la información de uso de CPU de algunos trabajos.

b) Se observa que la información sobre memoria utilizada falta con mayor frecuencia en los trabajos cuyo estado es “Fallido”.

c) El sistema deja de registrar el uso de memoria cuando este alcanza valores excepcionalmente altos, por lo que la probabilidad de que el dato falte depende del propio valor de memoria que no fue registrado.